

UNIVERSIDAD DE SANTIAGO DE CHILE
Facultad de Ciencia
Departamento de Matemática y Ciencia de la Computación



Modelamiento de Lahares mediante Redes Neuronales
Informadas por la Física (PINNs): Aplicación al evento
eruptivo de 2015 del volcán Villarica, Chile
Subtítulo

Dylan Jara
Johan Triana
Yuvineza Gomez-Leyton

Profesor guía:
Felipe Herrera

Tesis para optar al título de
Analista en Computación Científica

Santiago, Chile
2026

Esta investigación se ha realizado
bajo el proyecto XXXXXXXX - 00000000

Resumen

Los lahares representan uno de los peligros volcánicos más devastadores debido a su alta movilidad y potencial de impacto en comunidades e infraestructura. En Chile, el volcán Villarrica constituye un escenario crítico para el estudio de estos flujos, particularmente aquellos originados por la interacción entre magma y criósfera, como se observó en el evento eruptivo de 2015. Este trabajo presenta el desarrollo de un modelo computacional para la simulación de lahares basado en Redes Neuronales Informadas por la Física (PINNs). La arquitectura propuesta integra ecuaciones diferenciales parciales (PDEs) acopladas bajo la aproximación de flujo somero (shallow water equations), incorporando variables de transporte de concentración sólida y dinámica de presión de poros para capturar la naturaleza multifásica del fenómeno. La metodología aborda la construcción de una PINN entrenada mediante restricciones físicas y condiciones iniciales derivadas de datos históricos del evento de 2015. Un componente central del estudio consiste en el análisis y mitigación de patologías propias del entrenamiento de PINNs en sistemas geofísicos complejos, tales como la convergencia a soluciones triviales, el desbalance de gradientes y la inestabilidad numérica. Los resultados buscan demostrar la viabilidad de las PINNs como una herramienta robusta para la modelación de peligros naturales, integrando las leyes de la física con los avances en inteligencia artificial para fortalecer las capacidades de predicción y gestión de riesgos volcánicos.

Palabras clave: Redes Neuronales Informadas por la Física (PINNs), Ecuaciones Diferenciales Parciales, Volcán Villarrica, Lahares, Peligros Volcánicos

Abstract

Lahars represent one of the most devastating volcanic hazards due to their high mobility and potential impact on communities and infrastructure. In Chile, the Villarrica volcano constitutes a critical scenario for studying these flows, particularly those triggered by the interaction between magma and the cryosphere, as observed during the 2015 eruptive event. This work presents the development of a computational model for lahar simulation based on Physics-Informed Neural Networks (PINNs). The proposed architecture integrates coupled partial differential equations (PDEs) under the shallow water approximation, incorporating solid concentration transport variables and pore pressure dynamics to capture the multiphase nature of the phenomenon.

The methodology addresses the construction of a PINN trained using physical constraints and initial conditions derived from historical data of the 2015 event. A core component of this study consists of analyzing and mitigating training pathologies inherent to PINNs when applied to complex geophysical systems, such as convergence to trivial solutions, gradient imbalance, and numerical instability. The results aim to demonstrate the viability of PINNs as a robust tool for natural hazard modeling, integrating the laws of physics with advancements in artificial intelligence to strengthen volcanic risk prediction and management capabilities.

Keywords: Physics-Informed Neural Networks (PINNs), Partial Differential Equations, Villarrica Volcano, Lahars, Volcanic Hazards mathematics, computer science

Una dedicatoria.

Agradecimientos

Reconocimiento a personas significativas durante el proceso de investigación.

Tabla de contenido

Introducción	1
1. Fundamentos de Redes Neuronales Artificiales	2
1.1. Redes Neuronales Artificiales	2
1.1.1. Neurona Artificial	2
1.1.2. Perceptrón Multicapa	4
1.2. PINNs	6
2. Título del segundo capítulo	7
2.1. Introduccion al capítulo	8
2.2. Lahares	8
2.2.1. Definición y mecanismos de formación	8
2.2.2. Clasificación de los lahares	8
2.2.3. Comportamiento dinámico y reológico	8
2.3. Volcán Villarrica	8
2.3.1. Contexto geográfico y geológico	8
2.3.2. Actividad histórica reciente	8
2.3.3. Justificación como caso de estudio	8
2.4. Riesgo y exposición	8
2.4.1. Zonas de amenaza	8
2.4.2. Antecedentes de gestión del riesgo	8
2.5. Modelamiento computacional de lahares (estado del arte)	8
2.5.1. Enfoques tradicionales	8
2.5.2. Brecha que aborda esta tesis	8
Conclusiones	11
Glosario	12
Referencias	13

Anexos	15
Apéndices	16

Índice de tablas

2.1. Resultados partículas exóticas 9

Índice de figuras

1.1. Esquema de trabajo de una neurona artificial.	3
1.2. Red neuronal <i>feedforward</i> de tres capas con una capa de entrada, una (o más) capa(s) oculta(s) y una capa de salida.	5

Introducción

El Machine Learning ha avanzado significativamente a través de los años. Áreas como la visión por computador, el procesamiento de lenguaje natural y la robótica han experimentado mejoras notables gracias a la aplicación de técnicas de aprendizaje profundo. Estas técnicas permiten a los modelos aprender representaciones complejas de datos, lo que ha llevado a avances en tareas como el reconocimiento de imágenes, la traducción automática y la conducción autónoma. Sin embargo, las redes neuronales no son la bala de plata para todos los problemas. En particular, el modelamiento de fenómenos físicos complejos como la mecánica de fluidos sigue siendo un desafío debido a su naturaleza no lineal y la alta dimensionalidad de los sistemas involucrados. En este contexto, las redes neuronales físicas (PINNs) han surgido como una herramienta prometedora para abordar estos desafíos, integrando principios físicos directamente en el proceso de aprendizaje. El Volcán Villarrica (2,847 m AMSL) es un estratovolcán parcialmente glaciado dentro de la Zona Volcánica del Sur (SVZ) de los Andes de Chile [1].

Capítulo 1

Fundamentos de Redes Neuronales Artificiales

1.1. Redes Neuronales Artificiales

Una red neuronal artificial (RNA) o por sus siglas en inglés ANN (*Artificial Neural Network*) es un modelo matemático que intenta simular la estructura y las funcionalidades de las redes neuronales biológicas. El bloque base de una ANN es una neurona artificial, esto es, un simple modelo matemático (una función). Este modelo contiene tres reglas básicas: la suma ponderada de las entradas, la adición de un sesgo y la aplicación de una función de activación. Las entradas de la neurona multiplicadas por un peso, es decir, cada valor de entrada es ponderado por un peso individual. En el medio de la neurona se encuentra la función que suma todas las entradas ponderadas y los sesgos. Posterior a la suma, en la salida de la neurona se encuentra la función de activación, la cual es una función no lineal que determina si la neurona se activa o no. [2] [3].

1.1.1. Neurona Artificial

La neurona artificial constituye la unidad computacional fundamental de una red neuronal artificial. Su formulación matemática se inspira, de manera simplificada, en el funcionamiento de la neurona biológica: las dendritas que reciben señales se representan mediante entradas ponderadas, el cuerpo celular que integra dichas señales se representa mediante una suma, y el axón que transmite el resultado se representa mediante una función de salida. El primer modelo matemático formal de esta idea fue propuesto por McCulloch y Pitts, quienes introdujeron una neurona binaria capaz de representar operaciones lógicas a partir de la combinación de señales de entrada [4]. Si bien dicho modelo original consideraba únicamente salidas binarias, sentó las bases conceptuales de las neuronas artificiales utilizadas en la actualidad.




Figura 1.1: Esquema de trabajo de una neurona artificial.
Fuente: [2]

Formalmente, sea $\mathbf{x} = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$ el vector de entradas de la neurona. A cada entrada x_i se le asocia un peso sináptico $w_i \in \mathbb{R}$, que pondera su contribución relativa. La neurona calcula primero una combinación lineal de las entradas, conocida como *entrada neta* o *potencial de activación*, definida como

$$z = \sum_{i=1}^n w_i x_i + b, \quad (1.1)$$

donde $b \in \mathbb{R}$ es el sesgo (*bias*), un parámetro adicional que permite desplazar el umbral de activación de la neurona independientemente de los valores de entrada. Es posible escribir la Ecuación (1.1) de forma compacta como $z = \mathbf{w}^\top \mathbf{x} + b$, con $\mathbf{w} = (w_1, \dots, w_n)^\top$.

Posteriormente, la entrada neta z es transformada mediante una función de activación $\varphi : \mathbb{R} \rightarrow \mathbb{R}$, que introduce no linealidad en el modelo y determina el grado de activación de la neurona. La salida de la neurona artificial queda entonces definida por

$$y = \varphi(z) = \varphi \left(\sum_{i=1}^n w_i x_i + b \right). \quad (1.2)$$

La elección de φ es determinante para la capacidad expresiva del modelo: sin una función de activación no lineal, la composición de múltiples neuronas se reduciría a una simple

transformación lineal, independientemente del número de neuronas o capas involucradas. Entre las funciones de activación más utilizadas se encuentran la función sigmoide, la tangente hiperbólica y la unidad lineal rectificada (ReLU), cada una con propiedades distintas en cuanto a suavidad, rango de salida y comportamiento del gradiente durante el entrenamiento; estas se discutirán con mayor detalle en las secciones siguientes, en el contexto de la arquitectura completa de la red [5].

Es importante notar que, si bien la analogía biológica resulta útil como motivación conceptual, la neurona artificial descrita por las Ecuaciones (1.1) y (1.2) es, en esencia, un modelo matemático de aproximación de funciones. Una única neurona posee una capacidad de representación limitada, restringida a separaciones lineales o a transformaciones simples de sus entradas. La potencia de las redes neuronales artificiales surge, en cambio, de la interconexión de múltiples neuronas organizadas en capas, dando lugar al perceptrón multicapa que se describe a continuación.

1.1.2. Perceptrón Multicapa

El perceptrón multicapa (MLP, por sus siglas en inglés) es la arquitectura más común de redes neuronales artificiales. En la mayoría de los casos, las señales son transmitidas de manera unidireccional desde la capa de entrada hasta la capa de salida y el valor de salida de la neurona no afecta a la red. Este tipo de arquitectura se llama *feedforward* y se representa mediante un grafo acíclico dirigido.

Las capas que no se conectan directamente con la entrada o la salida se denominan capas ocultas. La presencia de estas capas permite a la red aprender representaciones intermedias de los datos, capturando patrones complejos y no lineales que serían inalcanzables para un modelo lineal simple. La introducción de múltiples capas es determinada por la complejidad de la función que se desea aproximar y la no-linealidad de esta. En general, a mayor complejidad de la función objetivo, mayor número de capas y neuronas se requerirá para lograr una aproximación satisfactoria. El número de neuronas en la capa de entrada depende de la cantidad de variables independientes que se deseen considerar, mientras que el número de neuronas en la capa de salida depende de la cantidad de variables dependientes que se deseen predecir. Finalmente, tanto el número de capas ocultas como el número de neuronas por capa son dependientes de la complejidad del modelo y son parámetros importantes en el desarrollo del MLP [6].




Figura 1.2: Red neuronal *feedforward* de tres capas con una capa de entrada, una (o más) capa(s) oculta(s) y una capa de salida.

Fuente: [6]

Desde un punto de vista formal, es posible extender la formulación presentada para una única neurona (Ecuaciones (1.1) y (1.2)) a la red completa mediante la composición sucesiva de transformaciones afines y funciones de activación, aplicadas capa a capa. Sea L el número total de capas de la red (sin contar la capa de entrada), y sea $\mathbf{h}^{(l)} \in \mathbb{R}^{n_l}$ el vector de activaciones de la capa l , con $\mathbf{h}^{(0)} = \mathbf{x}$ correspondiente al vector de entrada. La salida de cada capa $l = 1, \dots, L$ se calcula recursivamente como

$$\mathbf{h}^{(l)} = \varphi^{(l)}(W^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}), \quad (1.3)$$

donde $W^{(l)} \in \mathbb{R}^{n_l \times n_{l-1}}$ es la matriz de pesos que conecta la capa $l-1$ con la capa l , $\mathbf{b}^{(l)} \in \mathbb{R}^{n_l}$ es el vector de sesgos de la capa l , y $\varphi^{(l)}$ es la función de activación correspondiente, aplicada componente a componente. Nótese que la Ecuación (1.3) generaliza directamente las Ecuaciones (1.1) y (1.2) de la neurona individual, aplicándolas ahora de manera simultánea a todas las neuronas de una capa.

La salida final de la red, $\hat{\mathbf{y}} = \mathbf{h}^{(L)}$, queda expresada como la composición de L transformaciones sucesivas,

$$\hat{\mathbf{y}} = F_{\theta}(\mathbf{x}) = \varphi^{(L)}(W^{(L)}\varphi^{(L-1)}(\dots\varphi^{(1)}(W^{(1)}\mathbf{x} + \mathbf{b}^{(1)})\dots) + \mathbf{b}^{(L)}), \quad (1.4)$$

donde $\theta = \{W^{(l)}, \mathbf{b}^{(l)}\}_{l=1}^L$ agrupa el conjunto completo de parámetros entrenables de la red. Esta notación compacta, F_θ , será la que se utilice en lo sucesivo para referirse a la red neuronal como aproximador de una función objetivo, y resulta particularmente relevante en el contexto de las PINNs, donde una red de este tipo se emplea directamente para aproximar la solución latente $u(t, x)$ de la ecuación diferencial de interés [5].

Cabe destacar que la capacidad de un MLP para aproximar funciones arbitrarias no es solo empírica, sino que está respaldada teóricamente por el teorema de aproximación universal, el cual establece que una red *feedforward* con al menos una capa oculta y un número suficiente de neuronas puede aproximar cualquier función continua sobre un subconjunto compacto de $\mathbb{R}^n$ con la precisión deseada, bajo condiciones razonables sobre la función de activación [7]. Este resultado es, en última instancia, el que justifica el uso de redes neuronales profundas como aproximadores de soluciones de ecuaciones diferenciales en el marco de las PINNs, como se retomará más adelante en este capítulo.

1.2. PINNs

En este trabajo se adopta una aproximación diferente a lo que suele realizarse en la literatura, empleando redes neuronales profundas gracias a su gran y bien conocida capacidad como aproximadores universales [7]. De esta manera se puede abordar sin problemas la no-linealidad de los sistemas acoplados que aborda este trabajo. En áreas tales como sistemas físicos, biológicos o de ingeniería puede ser difícil o directamente imposible conseguir datos para el entrenamiento de modelos de aprendizaje automático causando un sesgo de entrenamiento y conclusiones incompletas o equívocas.

Consideramos una ecuación diferencial no lineal y parametrizada en su forma general

$$u_t + \mathcal{N}[u; \lambda] = 0, x \in \Omega, t \in [0, T]$$

donde $u(t, x)$ denota la solución latente, $\mathcal{N}$ es un operador diferencial no lineal, λ es un conjunto de parámetros que caracterizan el sistema y Ω es un subconjunto de $\mathbb{R}^d$.

Capítulo 2

Título del segundo capítulo

2.1. Introduccion al capítulo

2.2. Lahares

2.2.1. Definición y mecanismos de formación

2.2.2. Clasificación de los lahares

2.2.3. Comportamiento dinámico y reológico

2.3. Volcán Villarrica

2.3.1. Contexto geográfico y geológico

2.3.2. Actividad histórica reciente

2.3.3. Justificación como caso de estudio

2.4. Riesgo y exposición

2.4.1. Zonas de amenaza

2.4.2. Antecedentes de gestión del riesgo

2.5. Modelamiento computacional de lahares (estado del

Utilice tablas para sintetizar datos. Estas deberían quedar referenciadas en un índice en las páginas iniciales, al igual que las figuras, al colocarles una etiqueta con \label. [8]

Cuadro 2.1: Resultados partículas exóticas

Parámetro del experimento	Valor obtenido
Energía de colisión	14 TeV
Partículas detectadas	Masa de 200 GeV/c ²
Sección transversal	0.01 pb

Entregue independencia a párrafos que contienen teoremas o fórmulas matemáticas, insertando las ecuaciones de este modo:

Teorema 1 (Convergencia Monótona). *Sea $\{f_n\}$ una sucesión de funciones medibles tales que: 1. $f_n(x) \geq 0$ para todo x y todo n . 2. $f_n(x)$ es monótona creciente, es decir, $f_n(x) \leq f_{n+1}(x)$. 3. Existe una función límite $f(x) = \lim_{n \rightarrow \infty} f_n(x)$.*

Entonces, se cumple que:

$$\lim_{n \rightarrow \infty} \int f_n(x) dx = \int \lim_{n \rightarrow \infty} f_n(x) dx. \quad (2.1)$$

Demostración. Dado que $\{f_n\}$ es creciente, tenemos:

$$f_1(x) \leq f_2(x) \leq \cdots \leq f(x). \quad (2.2)$$

Por la propiedad de la integral, la sucesión $I_n = \int f_n(x) dx$ es monótona creciente y acotada, por lo que tiene un límite finito:

$$\lim_{n \rightarrow \infty} I_n = I, \quad \text{donde } I = \int f(x) dx. \quad (2.3)$$

Aplicando la convergencia puntual de funciones medibles:

$$\lim_{n \rightarrow \infty} \int f_n(x) dx = \int \lim_{n \rightarrow \infty} f_n(x) dx. \quad (2.4)$$

Esto completa la demostración.

□

□

Agregue fragmentos de código con `\begin{lstlisting}`.

```
1 def main():  
2     print("Hello, World!")  
3  
4 if __name__ == "__main__":  
5     main()
```

Listing 2.1: Hello, World!

Otra cita bibliográfica interesante, a modo de ejemplo. [9]

Conclusiones

En las conclusiones de su tesis:

- Sintetice los hallazgos más importantes de la investigación.
- Responda a los objetivos planteados inicialmente.
- Destaque las contribuciones originales del trabajo.
- Mencione limitaciones y sugiera futuras líneas de investigación.

En esta parte terminan las páginas centrales. A continuación, se puede agregar optativamente, un glosario, anexos y apéndices; y, obligatoriamente, las referencias bibliográficas.

Referencias

- [1] E. J. Liu et al., «Dynamics of Outgassing and Plume Transport Revealed by Proximal Unmanned Aerial System (UAS) Measurements at Volcán Villarrica, Chile,» *Geochemistry, Geophysics, Geosystems*, vol. 20, n.º 2, págs. 730-750, 2019. doi: <https://doi.org/10.1029/2018GC007692> eprint: <https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2018GC007692>. dirección: <https://agupubs.onlinelibrary.wiley.com/doi/abs/10.1029/2018GC007692>
- [2] A. Krenker, J. Bešter y A. Kos, «Introduction to the artificial neural networks,» *Artificial Neural Networks: Methodological Advances and Biomedical Applications. InTech*, págs. 1-18, 2011.
- [3] S. Walczak, «Artificial neural networks,» en *Encyclopedia of Information Science and Technology, Fourth Edition*, IGI Global Scientific Publishing, 2018, págs. 120-131.
- [4] W. S. McCulloch y W. Pitts, «A logical calculus of the ideas immanent in nervous activity,» *The bulletin of mathematical biophysics*, vol. 5, n.º 4, págs. 115-133, 1943.
- [5] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. MIT Press, 2016. dirección: <http://www.deeplearningbook.org>
- [6] Y.-S. Park y S. Lek, «Artificial neural networks (multilayer perceptron) for ecological modeling,» en *Ecological model types*, Elsevier, 2025, págs. 297-322.
- [7] K. Hornik, M. Stinchcombe y H. White, «Multilayer feedforward networks are universal approximators,» *Neural Networks*, vol. 2, n.º 5, págs. 359-366, 1989, issn: 0893-6080. doi: [https://doi.org/10.1016/0893-6080\(89\)90020-8](https://doi.org/10.1016/0893-6080(89)90020-8) dirección: <https://www.sciencedirect.com/science/article/pii/0893608089900208>
- [8] R. Naulin y M. Pinto, «Admissible perturbations of exponential dichotomy roughness,» *Nonlinear Anal.*, vol. 31, n.º 5-6, págs. 559-571, 1998, issn: 0362-546X, 1873-5215.

DOI: 10.1016/S0362-546X(97)00423-9 dirección: [https://doi.org/10.1016/S0362-546X\(97\)00423-9](https://doi.org/10.1016/S0362-546X(97)00423-9)

- [9] I. Agricola y T. Friedrich, *Globale Analysis*. Friedr. Vieweg & Sohn, Braunschweig, 2001, págs. x+283, Differentialformen in Analysis, Geometrie und Physik. [Differential forms in analysis, geometry and physics], ISBN: 3-528-03154-9. DOI: 10.1007/978-3-322-92903-7 dirección: <https://doi.org/10.1007/978-3-322-92903-7>

Anexos

Anexo 1:. Primer anexo

Los anexos son material de apoyo externo: contienen información no producida por los autores de la tesis, pero útil como contexto o referencia.

Anexo 2:. Segundo anexo

Algunos ejemplos de anexos:

- documentos legales o normativos,
- manuales de equipos usados,
- artículos o estándares técnicos (ej.: ISO).

Los anexos no son críticos para entender el trabajo. Se incluyen como evidencia o para cumplir requisitos formales.

Apéndices

Apéndice 1:. Primer apéndice

Los apéndices son contenido esencial pero complementario: incluyen material elaborado por los autores de la tesis, que es relevante para entender la investigación, pero demasiado extenso o técnico para el cuerpo principal.

Apéndice 2:. Segundo apéndice

Algunos ejemplos de apéndices:

- códigos fuente completos,
- demostraciones matemáticas extensas,
- cuestionarios utilizados en la metodología.

Los apéndices guardan relación directa con el trabajo: son parte integral de la investigación y se citan en el texto principal.