

UNIVERSIDAD DE SANTIAGO DE CHILE
Facultad de Ciencia
Departamento de Matemática y Ciencia de la Computación



Modelamiento de Lahares mediante Redes Neuronales
Informadas por la Física (PINNs)
Aplicación al evento eruptivo de 2015 del volcán Villarica, Chile

Dylan Jara Carvajal

Profesor guía:
Dr. Felipe Herrera (USACH),
Dr. Johan Triana (UCN),
Dra. Yuvineza Gomez-Leyton (UCN)

Tesis para optar al título de
Analista en Computación Científica

Santiago, Chile
2026

Esta investigación se ha realizado
bajo el proyecto SUBVENCIÓN A LA INSTALACIÓN EN LA ACADEMIA -
CONVOCATORIA 2025 - 852501860

Resumen

Los lahares representan uno de los peligros volcánicos más devastadores debido a su alta movilidad y potencial de impacto en comunidades e infraestructura. En Chile, el volcán Villarrica constituye un escenario crítico para el estudio de estos flujos, particularmente aquellos originados por la interacción entre magma y criósfera, como se observó en el evento eruptivo de 2015. Este trabajo presenta el desarrollo de un modelo computacional para la simulación de lahares basado en Redes Neuronales Informadas por la Física (PINNs). La arquitectura propuesta integra ecuaciones diferenciales parciales (PDEs) acopladas bajo la aproximación de flujo somero (shallow water equations), incorporando variables de transporte de concentración sólida y dinámica de presión de poros para capturar la naturaleza multifásica del fenómeno. La metodología aborda la construcción de una PINN entrenada mediante restricciones físicas y condiciones iniciales derivadas de datos históricos del evento de 2015. Un componente central del estudio consiste en el análisis y mitigación de patologías propias del entrenamiento de PINNs en sistemas geofísicos complejos, tales como la convergencia a soluciones triviales, el desbalance de gradientes y la inestabilidad numérica. Los resultados buscan demostrar la viabilidad de las PINNs como una herramienta robusta para la modelación de peligros naturales, integrando las leyes de la física con los avances en inteligencia artificial para fortalecer las capacidades de predicción y gestión de riesgos volcánicos.

Palabras clave: Redes Neuronales Informadas por la Física (PINNs), Ecuaciones Diferenciales Parciales, Volcán Villarrica, Lahares, Peligros Volcánicos

Abstract

Lahars represent one of the most devastating volcanic hazards due to their high mobility and potential impact on communities and infrastructure. In Chile, the Villarrica volcano constitutes a critical scenario for studying these flows, particularly those triggered by the interaction between magma and the cryosphere, as observed during the 2015 eruptive event. This work presents the development of a computational model for lahar simulation based on Physics-Informed Neural Networks (PINNs). The proposed architecture integrates coupled partial differential equations (PDEs) under the shallow water approximation, incorporating solid concentration transport variables and pore pressure dynamics to capture the multiphase nature of the phenomenon.

The methodology addresses the construction of a PINN trained using physical constraints and initial conditions derived from historical data of the 2015 event. A core component of this study consists of analyzing and mitigating training pathologies inherent to PINNs when applied to complex geophysical systems, such as convergence to trivial solutions, gradient imbalance, and numerical instability. The results aim to demonstrate the viability of PINNs as a robust tool for natural hazard modeling, integrating the laws of physics with advancements in artificial intelligence to strengthen volcanic risk prediction and management capabilities.

Keywords: Physics-Informed Neural Networks (PINNs), Partial Differential Equations, Villarrica Volcano, Lahars, Volcanic Hazards mathematics, computer science

Una dedicatoria.

Agradecimientos

Reconocimiento a personas significativas durante el proceso de investigación.

Tabla de contenido

Introducción	1
1. Redes neuronales artificiales	2
1.1. Redes Neuronales Artificiales	2
1.1.1. Neurona Artificial	2
1.1.2. Perceptrón Multicapa	4
1.2. Funciones de activación	6
1.2.1. ReLU	7
1.2.2. Sigmoides	8
1.3. Optimizadores	9
1.4. Algoritmos de Optimización	9
1.4.1. Fundamentos y Descenso de Gradiente	9
1.4.2. RMSprop	9
1.4.3. Adam	10
1.5. PINNs	11
1.5.1. Loss function and optimization for PINN	12
2. Contexto geográfico y geológico de los peligros volcánicos	13
2.1. Introducción a los peligros volcánicos	13
2.2. Lahares	14
2.2.1. Zonas Volcánicas de Chile	15
2.3. Volcán Villarrica	15
2.3.1. Contexto geográfico y geológico	15
2.3.2. Evento eruptivo del Volcán Villarrica del 3 de marzo del 2015	15
2.3.3. Justificación como caso de estudio	17
Conclusiones	18
Glosario	19
Anexos	20

Índice de tablas

Índice de figuras

1.1. Esquema de trabajo de una neurona artificial.	3
1.2. Red neuronal <i>feedforward</i> de tres capas con una capa de entrada, una (o más) capa(s) oculta(s) y una capa de salida.	5
1.3. Función ReLU y su derivada.	7
1.4. Función sigmoide y su derivada.	8
2.1. Contexto Geodinámico de Chile	16

Introducción

El Machine Learning ha avanzado significativamente a través de los años. Áreas como la visión por computador, el procesamiento de lenguaje natural y la robótica han experimentado mejoras notables gracias a la aplicación de técnicas de aprendizaje profundo. Estas técnicas permiten a los modelos aprender representaciones complejas de datos, lo que ha llevado a avances en tareas como el reconocimiento de imágenes, la traducción automática y la conducción autónoma. Sin embargo, las redes neuronales no son la bala de plata para todos los problemas. En particular, el modelamiento de fenómenos físicos complejos como la mecánica de fluidos sigue siendo un desafío debido a su naturaleza no lineal y la alta dimensionalidad de los sistemas involucrados. En este contexto, las redes neuronales físicas (PINNs) han surgido como una herramienta prometedora para abordar estos desafíos, integrando principios físicos directamente en el proceso de aprendizaje. El Volcán Villarrica (2,847 m AMSL) es un estratovolcán parcialmente glaciado dentro de la Zona Volcánica del Sur (SVZ) de los Andes de Chile <https://doi.org/10.1029/2018GC007692>.

Capítulo 1

Redes neuronales artificiales

1.1. Redes Neuronales Artificiales

Una red neuronal artificial (RNA) o por sus siglas en inglés ANN (*Artificial Neural Network*) es un modelo matemático que intenta simular la estructura y las funcionalidades de las redes neuronales biológicas. El bloque base de una ANN es una neurona artificial, esto es, un simple modelo matemático (una función). Este modelo contiene tres reglas básicas: la suma ponderada de las entradas, la adición de un sesgo y la aplicación de una función de activación. Las entradas de la neurona multiplicadas por un peso, es decir, cada valor de entrada es ponderado por un peso individual. En el medio de la neurona se encuentra la función que suma todas las entradas ponderadas y los sesgos. Posterior a la suma, en la salida de la neurona se encuentra la función de activación, la cual es una función no lineal que determina si la neurona se activa o no. **krenker2011introduction walczak2018artificial**.

1.1.1. Neurona Artificial

La neurona artificial constituye la unidad computacional fundamental de una red neuronal artificial. Su formulación matemática se inspira, de manera simplificada, en el funcionamiento de la neurona biológica: las dendritas que reciben señales se representan mediante entradas ponderadas, el cuerpo celular que integra dichas señales se representa mediante una suma, y el axón que transmite el resultado se representa mediante una función de salida. El primer modelo matemático formal de esta idea fue propuesto por McCulloch y Pitts, quienes introdujeron una neurona binaria capaz de representar operaciones lógicas a partir de la combinación de señales de entrada **mcculloch1943logical**. Si bien dicho modelo original consideraba únicamente salidas binarias, sentó las bases conceptuales de las neuronas artificiales utilizadas en la actualidad.




Figura 1.1: Esquema de trabajo de una neurona artificial.
Fuente: krenker2011introduction

Formalmente, sea $\mathbf{x} = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$ el vector de entradas de la neurona. A cada entrada x_i se le asocia un peso sináptico $w_i \in \mathbb{R}$, que pondera su contribución relativa. La neurona calcula primero una combinación lineal de las entradas, conocida como *entrada neta* o *potencial de activación*, definida como

$$z = \sum_{i=1}^n w_i x_i + b, \quad (1.1)$$

donde $b \in \mathbb{R}$ es el sesgo (*bias*), un parámetro adicional que permite desplazar el umbral de activación de la neurona independientemente de los valores de entrada. Es posible escribir la Ecuación (1.1) de forma compacta como $z = \mathbf{w}^\top \mathbf{x} + b$, con $\mathbf{w} = (w_1, \dots, w_n)^\top$.

Posteriormente, la entrada neta z es transformada mediante una función de activación $\varphi : \mathbb{R} \rightarrow \mathbb{R}$, que introduce no linealidad en el modelo y determina el grado de activación de la neurona. La salida de la neurona artificial queda entonces definida por

$$y = \varphi(z) = \varphi \left(\sum_{i=1}^n w_i x_i + b \right). \quad (1.2)$$

La elección de φ es determinante para la capacidad expresiva del modelo: sin una función de activación no lineal, la composición de múltiples neuronas se reduciría a una simple

transformación lineal, independientemente del número de neuronas o capas involucradas. Entre las funciones de activación más utilizadas se encuentran la función sigmoide, la tangente hiperbólica y la unidad lineal rectificadora (ReLU), cada una con propiedades distintas en cuanto a suavidad, rango de salida y comportamiento del gradiente durante el entrenamiento; estas se discutirán con mayor detalle en las secciones siguientes, en el contexto de la arquitectura completa de la red **goodfellow2016deep**.

Es importante notar que, si bien la analogía biológica resulta útil como motivación conceptual, la neurona artificial descrita por las Ecuaciones (1.1) y (1.2) es, en esencia, un modelo matemático de aproximación de funciones. Una única neurona posee una capacidad de representación limitada, restringida a separaciones lineales o a transformaciones simples de sus entradas. La potencia de las redes neuronales artificiales surge, en cambio, de la interconexión de múltiples neuronas organizadas en capas, dando lugar al perceptrón multicapa que se describe a continuación.

1.1.2. Perceptrón Multicapa

El perceptrón multicapa (MLP, por sus siglas en inglés) es la arquitectura más común de redes neuronales artificiales. En la mayoría de los casos, las señales son transmitidas de manera unidireccional desde la capa de entrada hasta la capa de salida y el valor de salida de la neurona no afecta a la red. Este tipo de arquitectura se llama *feedforward* y se representa mediante un grafo acíclico dirigido.

Las capas que no se conectan directamente con la entrada o la salida se denominan capas ocultas. La presencia de estas capas permite a la red aprender representaciones intermedias de los datos, capturando patrones complejos y no lineales que serían inalcanzables para un modelo lineal simple. La introducción de múltiples capas es determinada por la complejidad de la función que se desea aproximar y la no-linealidad de esta. En general, a mayor complejidad de la función objetivo, mayor número de capas y neuronas se requerirá para lograr una aproximación satisfactoria. El número de neuronas en la capa de entrada depende de la cantidad de variables independientes que se deseen considerar, mientras que el número de neuronas en la capa de salida depende de la cantidad de variables dependientes que se deseen predecir. Finalmente, tanto el número de capas ocultas como el número de neuronas por capa son dependientes de la complejidad del modelo y son parámetros importantes en el desarrollo del MLP **park2025artificial**.




Figura 1.2: Red neuronal *feedforward* de tres capas con una capa de entrada, una (o más) capa(s) oculta(s) y una capa de salida.

Fuente: park2025artificial

Desde un punto de vista formal, es posible extender la formulación presentada para una única neurona (Ecuaciones (1.1) y (1.2)) a la red completa mediante la composición sucesiva de transformaciones afines y funciones de activación, aplicadas capa a capa. Sea L el número total de capas de la red (sin contar la capa de entrada), y sea $\mathbf{h}^{(l)} \in \mathbb{R}^{n_l}$ el vector de activaciones de la capa l , con $\mathbf{h}^{(0)} = \mathbf{x}$ el vector de entrada. La salida de cada capa $l = 1, \dots, L$ se calcula recursivamente como

$$\mathbf{h}^{(l)} = \varphi^{(l)}(W^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}), \quad (1.3)$$

donde $W^{(l)} \in \mathbb{R}^{n_l \times n_{l-1}}$ es la matriz de pesos que conecta la capa $l-1$ con la capa l , $\mathbf{b}^{(l)} \in \mathbb{R}^{n_l}$ es el vector de sesgos de la capa l , y $\varphi^{(l)}$ es la función de activación correspondiente, aplicada componente a componente. Nótese que la Ecuación (1.3) generaliza directamente las Ecuaciones (1.1) y (1.2) de la neurona individual, aplicándolas ahora de manera simultánea a todas las neuronas de una capa.

La salida final de la red, $\hat{\mathbf{y}} = \mathbf{h}^{(L)}$, queda expresada como la composición de L transformaciones sucesivas,

$$\hat{\mathbf{y}} = F_{\theta}(\mathbf{x}) = \varphi^{(L)}(W^{(L)}\varphi^{(L-1)}(\dots\varphi^{(1)}(W^{(1)}\mathbf{x} + \mathbf{b}^{(1)})\dots) + \mathbf{b}^{(L)}), \quad (1.4)$$

donde $\theta = \{W^{(l)}, \mathbf{b}^{(l)}\}_{l=1}^L$ agrupa el conjunto completo de parámetros entrenables de la red. Esta notación compacta, F_θ , será la que se utilice en lo sucesivo para referirse a la red neuronal como aproximador de una función objetivo, y resulta particularmente relevante en el contexto de las PINNs, donde una red de este tipo se emplea directamente para aproximar la solución latente $u(t, x)$ de la ecuación diferencial de interés **goodfellow2016deep**.

Cabe destacar que la capacidad de un MLP para aproximar funciones arbitrarias no es solo empírica, sino que está respaldada teóricamente por el teorema de aproximación universal, el cual establece que una red *feedforward* con al menos una capa oculta y un número suficiente de neuronas puede aproximar cualquier función continua sobre un subconjunto compacto de $\mathbb{R}^n$ con la precisión deseada, bajo condiciones razonables sobre la función de activación **HORNIK1989359**. Este resultado es, en última instancia, el que justifica el uso de redes neuronales profundas como aproximadores de soluciones de ecuaciones diferenciales en el marco de las PINNs

1.2. Funciones de activación

Las funciones de activación (FA) son usadas en las redes neuronales artificiales para transformar un valor de entrada en un valor de salida a través de un procesamiento de gradientes, el cual es usado como entrada para la siguiente capa de la red. Dentro de la literatura también se les conoce como funciones de transferencia **nwankpa2018activation**. Gran parte de la precisión a la hora de predecir un resultado depende de la función de activación que se use. Si bien existen muchas funciones de activación, no existe una que sea mejor para todos los casos **sharma2017activation**. Esta FA puede ser lineal o no lineal dependiendo de la función matemática que represente y debe cumplir con no agregar complejidad computacional de manera extensiva **dubey2022activation**.

Durante los años se han explorado y creado variedad de FA. Dentro de ellas, algunas de las más usadas son: la función sigmoide, la función tangente hiperbólica, la función ReLU y sus variantes, la función softmax y la función lineal. Cada una de estas funciones tiene propiedades matemáticas particulares que las hacen más o menos adecuadas para diferentes tipos de problemas **lederer2021activation**. En este capítulo se describen dos funciones de interés para este trabajo.



Figura 1.3: Función ReLU y su derivada.
Fuente: lederer2021activation

1.2.1. ReLU

ReLU viene del inglés *Rectified Linear Unit*, el cual significa "Unidad lineal rectificada". Esta función también es conocida como función parte-positiva, ya que, para los valores positivos de entrada, la salida es igual a la entrada (función identidad), mientras que para las entradas negativas o nulas, la salida es igual a 0 **lederer2021activation**. Esta definida como,

$$f(x) = \max(0, x) \quad (1.5)$$

La primera y segunda derivada de esta función es,

$$\dot{f}(x) = \begin{cases} 1, & \forall x \in (0, \infty) \\ 0, & \forall x \in (-\infty, 0) \end{cases} \quad \text{y} \quad \ddot{f}(x) = 0 \quad \forall x \in \mathbb{R} \setminus \{0\} \quad (1.6)$$

Si se analiza la ecuación 1.6, se puede observar que la segunda derivada es 0 para todo el dominio, lo que puede repercutir negativamente en ciertos problemas que requieran de ella, como es el caso de este trabajo.



Figura 1.4: Función sigmoide y su derivada.
Fuente: **nwankpa2018activation**

1.2.2. Sigmoide

Una función sigmoide es una función matemática suave que se caracteriza por su forma en "S". Esta es continua y diferenciable, y sus valores de salida se encuentran en el rango $(0, 1)$. Es función de activación muy usadas en el aprendizaje profundo para predecir probabilidades y salidas binarias. Se define como,

$$f(x) = \frac{1}{1 + e^{-x}} \quad (1.7)$$

La derivada de esta función es,

$$\dot{f}(x) = f(x)(1 - f(x)) \quad (1.8)$$

Si bien ReLU puede ser más usada en la actualidad en el ámbito del aprendizaje profundo, la función sigmoide tiene la ventaja de ser infinitamente diferenciable, lo que la hace muy útil en problemas donde las derivadas de orden superior son requeridas. Sin embargo, la FA Sigmoide tiene la desventaja de que puede saturar su gradiente y converger lentamente a una solución, provocando que el gradiente se propague en diferentes direcciones **nwankpa2018activation**.

1.3. Optimizadores

1.4. Algoritmos de Optimización

El entrenamiento de una red neuronal artificial se formula fundamentalmente como un problema de optimización no convexa, cuyo objetivo es encontrar el conjunto de parámetros $\theta \in \mathbb{R}^d$ (pesos y sesgos) que minimice una función de pérdida $\mathcal{L}(\theta)$ sobre el conjunto de datos de entrenamiento:

$$\theta^* = \arg \min_{\theta} \mathcal{L}(\theta) \quad (1.9)$$

Los algoritmos de optimización determinan la trayectoria y la velocidad con la que los parámetros convergen hacia un mínimo local a través de aproximaciones iterativas basadas en el gradiente de la función de pérdida, $\nabla_{\theta} \mathcal{L}(\theta)$, calculado mediante el algoritmo de retropropagación (*backpropagation*).

1.4.1. Fundamentos y Descenso de Gradiente

La base de la mayoría de los métodos modernos es el Descenso de Gradiente Estocástico (SGD, por sus siglas en inglés *Stochastic Gradient Descent*), cuya regla de actualización en la iteración t se define como:

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \mathcal{L}(\theta_t; \mathcal{B}_t) \quad (1.10)$$

donde $\eta > 0$ representa la tasa de aprendizaje (*learning rate*) y $\mathcal{B}_t$ denota un subconjunto aleatorio de datos (*mini-batch*). A pesar de su simplicidad computacional, SGD presenta limitaciones significativas en superficies de pérdida no isotrópicas, zonas con mesetas o valles pronunciados, y es altamente sensible a la elección estática de η . Para mitigar estos problemas, surgen los métodos de tasa de aprendizaje adaptativa.

1.4.2. RMSprop

Propuesto por Geoff Hinton, RMSprop (*Root Mean Square Propagation*) resuelve las oscilaciones excesivas en dimensiones con gradientes pronunciados dividiendo la tasa

de aprendizaje por un promedio móvil exponencial de los cuadrados de los gradientes históricos.

El algoritmo calcula en cada paso t :

$$\mathbf{v}_t = \beta \mathbf{v}_{t-1} + (1 - \beta) \mathbf{g}_t^{\odot 2} \quad (1.11)$$

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \frac{\eta}{\sqrt{\mathbf{v}_t} + \epsilon} \odot \mathbf{g}_t \quad (1.12)$$

donde $\mathbf{g}_t = \nabla_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta}_t)$, $\beta \in [0, 1)$ es el factor de decaimiento (comúnmente $\beta = 0,9$), $\epsilon > 0$ es una constante pequeña (típicamente 10^{-8}) para evitar la división por cero, y $\odot$ denota el producto elemento a elemento. De este modo, RMSprop atenúa los pasos en direcciones con variaciones abruptas y acelera en aquellas con pendientes suaves.

1.4.3. Adam

El optimizador Adam (*Adaptive Moment Estimation*) combina las ventajas del método de momento (aceleración en la dirección relevante) con RMSprop (escalamiento adaptativo por coordenada). Mantiene promedios móviles tanto del gradiente (primer momento) como de su cuadrado (segundo momento no centrado):

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \mathbf{g}_t \quad (1.13)$$

$$\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2) \mathbf{g}_t^{\odot 2} \quad (1.14)$$

Dado que los vectores $\mathbf{m}_t$ y $\mathbf{v}_t$ se inicializan en cero, presentan un sesgo hacia el origen en las primeras iteraciones. Adam incorpora una corrección de sesgo analítica:

$$\hat{\mathbf{m}}_t = \frac{\mathbf{m}_t}{1 - \beta_1^t}, \quad \hat{\mathbf{v}}_t = \frac{\mathbf{v}_t}{1 - \beta_2^t} \quad (1.15)$$

Finalmente, la regla de actualización de los parámetros está dada por:

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \frac{\eta}{\sqrt{\hat{\mathbf{v}}_t} + \epsilon} \odot \hat{\mathbf{m}}_t \quad (1.16)$$

donde típicamente se configuran $\beta_1 = 0,9$, $\beta_2 = 0,999$ y $\epsilon = 10^{-8}$. Gracias a su robustez y rápida convergencia, Adam se ha establecido como el optimizador por defecto en diversas tareas de aprendizaje profundo.

1.5. PINNs

Este trabajo adopta una aproximación diferente a lo que suele realizarse en la literatura, empleando redes neuronales profundas gracias a su gran y bien conocida capacidad como aproximadores universales **HORN1989359**. De esta manera se puede abordar sin problemas la no-linealidad de los sistemas acoplados que aborda este trabajo. En áreas tales como sistemas físicos, biológicos o de ingeniería puede ser difícil o directamente imposible conseguir datos para el entrenamiento de modelos de aprendizaje automático causando un sesgo de entrenamiento y conclusiones incompletas o equívocas.

Consideramos una ecuación diferencial no lineal y parametrizada en su forma general,

$$\mathbf{u}_t + \mathcal{N}[\mathbf{u}] = 0, \quad x \in \Omega, t \in [0, T] \quad (1.17)$$

donde $u(t, x)$ denota la solución latente, $\mathcal{N}[\cdot]$ es un operador diferencial lineal o no lineal y Ω es un subconjunto de $\mathbb{R}^d$. Sujeto a las condiciones iniciales y de frontera,

$$\mathbf{u}(0, x) = g(x), x \in \Omega, \quad (1.18)$$

$$\mathcal{B}[\mathbf{u}] = 0, \quad t \in [0, T], x \in \partial\Omega \quad (1.19)$$

donde $\mathcal{B}[\cdot]$ es un operador de frontera correspondiente a Dirichlet, Neumann o Robin, o condiciones de frontera periódicas.

Se representa la solución desconocida (latente) de una red neuronal profunda $u_\theta(t, x)$, donde θ denota el conjunto de parámetros entrenables o configurables de la red, por ejemplo, pesos y sesgos. Esto permite definir los residuos de la ecuación diferencial como,

$$\mathcal{R}_\theta(t, \mathbf{x}) = \frac{\partial \mathbf{u}_\theta}{\partial t}(t_r, \mathbf{x}_r) + \mathcal{N}[\mathbf{u}_\theta](t_r, \mathbf{x}_r) \quad (1.20)$$

Dadas las ecuaciones anteriores, es posible entrenar un modelo informado por la física, minimizando la función de pérdida,

$$\mathcal{L}(\theta) = \lambda_1 \mathcal{L}_{ic}(\theta) + \lambda_2 \mathcal{L}_{bc}(\theta) + \lambda_3 \mathcal{L}_r(\theta) \quad (1.21)$$

donde

$$\mathcal{L}_{ic}(\theta) = \frac{1}{N_{ic}} \sum_{i=1}^{N_{ic}} |\mathbf{u}_{\theta}(0, \mathbf{x}_{ic}^i) - g(\mathbf{x}_{ic}^i)|^2 \quad (1.22)$$

$$\mathcal{L}_{bc}(\theta) = \frac{1}{N_{bc}} \sum_{i=1}^{N_{bc}} |\mathcal{B}[\mathbf{u}_{\theta}](t_{bc}^i, \mathbf{x}_{bc}^i)|^2 \quad (1.23)$$

$$\mathcal{L}_r(\theta) = \frac{1}{N_r} \sum_{i=1}^{N_r} |\mathcal{R}_{\theta}(t_r^i, \mathbf{x}_r^i)|^2 \quad (1.24)$$

De esta forma, $\{x_{ic}^i\}_{i=1}^{N_{ic}}$ representan los puntos de datos iniciales, $\{x_{bc}^i\}_{i=1}^{N_{bc}}$ los puntos de datos de frontera y $\{x_r^i\}_{i=1}^{N_r}$ los puntos de datos residuales. Estos datos pueden ser vertices de mallas fijas o puntos aleatoriamente distribuidos en cada iteración del algoritmo del gradiente descendente. Obsérvese que cada gradiente con respecto a las variables de entrada o a los parámetros θ de la red pueden ser calculados de forma eficiente mediante la diferenciación automática. **wang2023expert, griewank2008evaluating, RAISSI2019686.**

1.5.1. Loss function and optimization for PINN

Capítulo 2

Contexto geográfico y geológico de los peligros volcánicos

2.1. Introducción a los peligros volcánicos

El concepto de peligro volcánico comprende al conjunto de eventos que se producen en un volcán y que pueden provocar daños a personas o bienes expuestos **ortiz1995danos**, para cuya mitigación se realizan evaluaciones y mapas para predecir las rutas que seguirán los eventos volcánicos. Es definido como la probabilidad de que un área determinada sea afectada por procesos o productos volcánicos potencialmente destructivos en un intervalo de tiempo dado.

Los peligros volcánicos abarcan una amplia variedad de fenómenos cuya naturaleza, alcance y grado de destructividad dependen tanto del estilo eruptivo del volcán como de las condiciones ambientales de su entorno **blong1984volcanic**. Es posible distinguir entre peligros primarios que corresponden a productos directos de la actividad eruptiva y peligros secundarios, que se originan como consecuencia de la interacción entre dichos productos y el entorno, incluso en ausencia de actividad eruptiva activa **sigurdsson2015encyclopedia**.

Entre los peligros primarios se encuentran los flujos de lava, coladas de roca fundida que, si bien rara vez representan una amenaza directa para la vida humana debido a sus velocidades de desplazamiento relativamente bajas, pueden sepultar, destruir o incendiar toda infraestructura a su paso **blong1984volcanic**. Asimismo, la caída de tefra, la cual consiste en diferentes componentes con una densidad variable, tanto de partículas juvenes (magma fresco) como líticas (roca envolvente), y pueden variar desde bloques y bombas de cerca de un metro de tamaño que son expulsados de la erupción de forma balística y caen unos pocos kilómetros desde la fuente de erupción, hasta partículas de tamaño del orden de los micrones que pueden ser transportadas por el viento a escala continental o global

BONADONNA2015587. Los flujos piroclásticos, por su parte, corresponden a corrientes de alta densidad compuestas por gases calientes y material volcánico fragmentado y son considerados el peligro volcánico individualmente más letal debido a su elevada temperatura y velocidad de desplazamiento **blong1984volcanic**.

Dentro de los peligros secundarios destacan los lahares, flujos de detritos saturados en agua que se originan a partir de la remoción de material volcánico no consolidado presente en las laderas del edificio volcánico **vallance2015lahars**. A diferencia de otros peligros volcánicos, los lahares pueden generarse tanto durante episodios eruptivos activos, por ejemplo, mediante la fusión rápida de nieve o hielo por flujos piroclásticos tanto como en ausencia de actividad eruptiva, disparados por precipitaciones intensas sobre depósitos piroclásticos inestables **gudmundsson2015hazards**. Esta capacidad de generarse independientemente de la actividad eruptiva, sumada a un alcance a lo largo de valles fluviales que puede extenderse decenas de kilómetros desde el volcán, los convierte en uno de los peligros volcánicos con mayor potencial de afectar a poblaciones alejadas del cono volcánico **mothes2015lahars**.

La magnitud y frecuencia relativa de estos fenómenos suele caracterizarse a nivel de erupción mediante escalas semicuantitativas como el Índice de Explosividad Volcánica (VEI), que permite comparar eventos eruptivos históricos en función del volumen de material expulsado, la altura de la columna eruptiva, entre otros **newhallself1982vei**. Sin embargo, dicha escala describe la magnitud de la erupción en su conjunto y no captura por sí sola el riesgo diferenciado que cada tipo de peligro representa para las comunidades expuestas. Análisis recientes de bases de datos de víctimas fatales por erupciones volcánicas muestran que peligros como los flujos piroclásticos y los lahares concentran una proporción desproporcionadamente alta de las víctimas fatales en comparación con la caída de tefra, pese a que esta última suele tener un mayor alcance geográfico **brown2017volcanic**.

2.2. Lahares

Lahar es uno de los pocos términos de origen indonesio (javanés) que han ingresado al idioma inglés y se traduce como un flujo de lodo destructivo que desciende por las laderas de un volcán. Fue utilizado, probablemente, por primera vez en 1922 por Escher, el cual propuso que los flujos de lodo volcánico se originan en la erupción de: un lago

cratérico, el derretimiento de una capa de hielo o intensas lluvias sobre materiales sueltos **neall1976lahars**.

2.2.1. Zonas Volcánicas de Chile

Chile se ubica en las zonas de subducción entre la placa de Nazca y la placa Sudamericana, y entre las placas Antártica y Sudamericana, ambas zonas separadas por la subducción de la Dorsal de Chile a los $\sim 47^{\circ}S$, dando origen al arco volcánico de la Cordillera de los Andes. Existen tres zonas volcánicas de este arco ubicadas en Chile: la Zona Volcánica Central, en la zona norte del país ($17-27^{\circ}S$) y compartida con Bolivia y Perú; la Zona Volcánica Sur en la zona centro-sur de Chile ($33-46^{\circ}S$); y la Zona Volcánica Austral en el sur del país ($49-55^{\circ}S$) (Figura 1). A lo largo de estas zonas volcánicas se reconocen numerosos centros eruptivos, de los cuales 92 se consideran geológicamente activos **stern2007chilean**.

2.3. Volcán Villarrica

2.3.1. Contexto geográfico y geológico

El volcán Villarrica corresponde a uno de los más de 200 volcanes pleistocenos a holocenos ubicados en el arco Andino **article**.

2.3.2. Evento eruptivo del Volcán Villarrica del 3 de marzo del 2015

La erupción paroxística de 2015 del Volcán Villarrica (Chile) produjo un lahar de 2,5 h de duración, que descendió más de 20 km dentro de la cuenca del Río Correntoso/Turbio y destruyó dos pequeños puentes **johnson2015lahar**. Los lahares son uno de los principales peligros en los volcanes. El lahar histórico más mortal ocurrió en 1985 en el Nevado del Ruiz (Colombia) cuando el derretimiento glacial inducido por la erupción produjo flujos que viajaron más de 100 km y mataron a más de 25,000 personas **lowe1986lahars**. Lahares tales como los de Nevado del Ruiz pueden ser generados coincidentemente con erupciones volcánicas, pero también pueden ser generados como un flujo secundario de episodios




Figura 2.1: Contexto Geodinámico de Chile
Fuente: geoffroy2023peligros

de lluvia en laderas cubiertas de ceniza, roturas de los embalses de los lagos de cráter o erosión o derrumbe espontáneos de las laderas volcánicas **vallance2000lahars**.

2.3.3. Justificación como caso de estudio

Conclusiones

En las conclusiones de su tesis:

- Sintetice los hallazgos más importantes de la investigación.
- Responda a los objetivos planteados inicialmente.
- Destaque las contribuciones originales del trabajo.
- Mencione limitaciones y sugiera futuras líneas de investigación.

En esta parte terminan las páginas centrales. A continuación, se puede agregar optativamente, un glosario, anexos y apéndices; y, obligatoriamente, las referencias bibliográficas.

Anexos

Anexo 1:. Primer anexo

Los anexos son material de apoyo externo: contienen información no producida por los autores de la tesis, pero útil como contexto o referencia.

Anexo 2:. Segundo anexo

Algunos ejemplos de anexos:

- documentos legales o normativos,
- manuales de equipos usados,
- artículos o estándares técnicos (ej.: ISO).

Los anexos no son críticos para entender el trabajo. Se incluyen como evidencia o para cumplir requisitos formales.

Apéndices

Apéndice 1:. Primer apéndice

Los apéndices son contenido esencial pero complementario: incluyen material elaborado por los autores de la tesis, que es relevante para entender la investigación, pero demasiado extenso o técnico para el cuerpo principal.

Apéndice 2:. Segundo apéndice

Algunos ejemplos de apéndices:

- códigos fuente completos,
- demostraciones matemáticas extensas,
- cuestionarios utilizados en la metodología.

Los apéndices guardan relación directa con el trabajo: son parte integral de la investigación y se citan en el texto principal.