UNIVERSIDAD DE SANTIAGO DE CHILE
Facultad de Ciencia
Departamento de Matemática y Ciencia de la Computación

Modelamiento de Lahares mediante Redes Neuronales Informadas por la Física (PINNs)

Aplicación al evento eruptivo de 2015 del volcán Villarica, Chile

Dylan Jara Carvajal

Profesor guía:
Dr. Felipe Herrera (USACH),
Dr. Johan Triana (UCN),
Dra. Yuvineza Gomez-Leyton (UCN)

Tesis para optar al título de
Analista en Computación Científica

Santiago, Chile
2026

Esta investigación se ha realizado
bajo el proyecto SUBVENCIÓN A LA INSTALACIÓN EN LA ACADEMIA -
CONVOCATORIA 2025 – 852501860

Resumen

Los lahares constituyen uno de los principales peligros asociados a volcanes cubiertos por nieve y hielo, debido a su capacidad para movilizar rápidamente mezclas de agua, sedimentos y material volcánico a través de los sistemas de drenaje. El volcán Villarrica, uno de los sistemas volcánicos más activos de Chile, constituye un caso de estudio relevante debido a la generación de lahares durante su evento eruptivo de 2015, asociados a la interacción del proceso eruptivo con la cubierta de nieve y hielo.

Esta investigación propone desarrollar un modelo computacional de lahares mediante Redes Neuronales Informadas por la Física (PINNs), utilizando el evento eruptivo de 2015 del volcán Villarrica como caso de estudio. El modelo físico se formulará mediante un sistema acoplado de ecuaciones diferenciales parciales basado en la aproximación de flujo somero, incorporando la conservación de masa y momento, el transporte de concentración sólida y la evolución de la presión de poros. La PINN aproximará los campos espacio-temporales de espesor, velocidad, concentración sólida y presión de poros, incorporando las ecuaciones gobernantes directamente en su función de pérdida.

La metodología considerará condiciones iniciales y de frontera físicamente consistentes, representación de la topografía y estrategias específicas para mejorar la estabilidad del entrenamiento, incluyendo la imposición fuerte de condiciones iniciales, normalización de variables y control de la convergencia hacia soluciones triviales. Posteriormente, el modelo será aplicado al caso del Villarrica 2015 utilizando parámetros y observaciones disponibles para el evento. Se espera evaluar la capacidad de las PINNs para reproducir la dinámica espacio-temporal de lahares y establecer su potencial como herramienta complementaria para la modelación física de este tipo de peligro volcánico.

Palabras clave: Redes Neuronales Informadas por la Física (PINNs), Ecuaciones Diferenciales Parciales, Volcán Villarica, Lahares, Peligros Volcánicos

Abstract

Lahars represent one of the primary hazards associated with snow- and ice-capped volcanoes due to their ability to rapidly mobilize mixtures of water, sediment, and volcanic material through drainage networks. Villarrica volcano, one of Chile's most active volcanic systems, serves as a relevant case study due to the generation of lahars during its 2015 eruptive event, which were triggered by the interaction between the eruptive process and the snow and ice cover.

This research proposes the development of a computational lahar model using Physics-Informed Neural Networks (PINNs), using the 2015 Villarrica volcano eruption as a case study. The physical model will be formulated as a coupled system of partial differential equations based on the shallow water (shallow flow) approximation, incorporating mass and momentum conservation, solid concentration transport, and pore pressure evolution. The PINN will approximate the spatio-temporal fields of flow depth, velocity, solid concentration, and pore pressure by embedding the governing equations directly into its loss function.

The methodology will account for physically consistent initial and boundary conditions, topographic representation, and specific training stability strategies—including hard enforcement of initial conditions, variable normalization, and convergence control to prevent trivial solutions. Subsequently, the model will be applied to the 2015 Villarrica event using available parameters and observational data. The study aims to evaluate the capability of PINNs to reproduce the spatio-temporal dynamics of lahars and establish their potential as a complementary tool for the physical modeling of this volcanic hazard.

Keywords:Physics-Informed Neural Networks (PINNs), Partial Differential Equations, Villarrica Volcano, Lahars, Volcanic Hazards

Tabla de contenido

Introducción **1**

1. Redes neuronales artificiales **5**
1.1. Redes Neuronales Artificiales 5
1.1.1. Neurona Artificial 5
1.1.2. Perceptrón Multicapa 7
1.2. Funciones de activación 10
1.2.1. ReLU 11
1.2.2. Sigmoide 11
1.2.3. Otras funciones de activación 12
1.3. Funciones de pérdida 13
1.4. Gradiente Descendente y algoritmos de optimización 14
1.4.1. Gradiente Descendiente (*Batch Gradient Descent*) 15
1.5. Redes Neuronales Informadas por la Física (PINNs) 15

2. Contexto geológico **18**
2.1. Introducción a los peligros volcánicos 18
2.2. Lahares 20
2.2.1. Zonas Volcánicas de Chile 21
2.3. Volcán Villarrica 22
2.3.1. Contexto geográfico y geológico 22
2.3.2. Evento eruptivo del Volcán Villarrica del 3 de marzo del 2015 23

3. Marco metodológico **25**
3.1. Enfoque general de la investigación 25
3.2. Modelo físico del flujo lahárico 25
3.2.1. Supuestos del modelo 25
3.2.2. Variables de estado 26
3.2.3. Sistema de ecuaciones gobernantes 27
3.2.4. Transporte de concentración sólida con difusión y relajación 28

3.2.5. Relaciones constitutivas . . . 29
3.2.6. Parámetros del modelo . . . 30
3.2.7. Formulación compacta y relación con la PINN . . . 30
3.2.8. Consideraciones para su resolución mediante PINNs . . . 31
3.2.9. Condiciones iniciales y de frontera . . . 32
3.2.10. Adimensionalización . . . 33
3.2.11. Supuestos del modelo . . . 33
3.2.12. Sistema de ecuaciones . . . 33
3.2.13. Términos de fricción y reología . . . 33
3.2.14. Condiciones iniciales y de frontera . . . 33
3.2.15. Adimensionalización . . . 33
3.3. Área de estudio y datos . . . 33
3.3.1. Dominio computacional . . . 33
3.3.2. Topografía . . . 33
3.3.3. Datos observacionales del evento de 2015 . . . 33
3.3.4. Muestreo de puntos de entrenamiento . . . 33
3.4. Diseño de la red neuronal informada por la física . . . 33
3.4.1. Arquitectura . . . 33
3.4.2. Función de pérdida . . . 33
3.4.3. Entrenamiento . . . 33
3.5. Estrategia de validación . . . 33
3.5.1. Métricas de evaluación . . . 33
3.5.2. Modelo de referencia . . . 33
3.6. Entorno de implementación . . . 33
3.7. Resultados preliminares . . . 33
3.7.1. Caso de verificación . . . 33
3.7.2. Discusión preliminar . . . 33
3.8. Trabajo futuro y plan de actividades . . . 33

Conclusiones **34**

Glosario **35**

Referencias **36**

Índice de tablas

1. Comparación entre redes neuronales artificiales convencionales y redes neuronales informadas por la física (PINN). 4

1.1. Resumen de funciones de activación comúnmente usadas en redes neuronales. 13

3.1. Parámetros del modelo físico de flujo lahárico. 31

Índice de figuras

1.1. Esquema de trabajo de una neurona artificial. 6
1.2. Esquema de una neurona artificial con n entradas ponderadas, un sesgo y una función de activación. 8
1.3. Red neuronal feedforward de tres capas con una capa de entrada, una (o más) capa(s) oculta(s) y una capa de salida. 9
1.4. Función ReLU. 12
1.5. Función sigmoide. 13
1.6. Esquema de una red neuronal informada por la física (PINN) con su sistema compuesto de funciones de pérdida y EDPs. 17

2.1. Esquema de un volcán y sus principales peligros. 19
2.2. Lahar y sus zonas de peligro 21
2.3. a) Contexto geográfico b) Recorrido del lahar por los esteros c) Vista azimutal del volcán Villarrica d) Columna eruptiva e) Esquema de un lahar 22

Introducción

El aprendizaje automático ha avanzado significativamente a través de los años. Áreas como la visión computacional [1], el procesamiento de lenguaje natural [2] y la robótica [3] han experimentado mejoras notables gracias a la aplicación de técnicas de aprendizaje profundo. Estas técnicas permiten a los modelos aprender representaciones complejas de datos, lo que ha llevado a avances en tareas como el reconocimiento de imágenes [4], la traducción automática [5] y la conducción autónoma [6]. Todos estos avances presentan un elemento común, que son las redes neuronales artificiales (RNA). Estas son modelos computacionales compuestos por capas de neuronas artificiales, las cuales simulan a la neurona biológica y son capaces de procesar y aproximar relaciones no lineales entre variables. Gracias al teorema de aproximación universal, una red simple de al menos una capa y un número mínimo de neuronas puede aproximar cualquier función continua en un dominio [7].

Sin embargo, las redes neuronales no son una solución universal para todos los problemas. La correcta convergencia de una red neuronal artificial es fuertemente dependiente del volumen de datos utilizados, de la calidad de estos y su nivel de representación del fenómeno a modelar, por ejemplo, si el conjunto de datos presenta datos ruidosos es posible que la red pueda no representar correctamente el fenómeno. La recopilación de datos de alta calidad puede ser costosa y de dificil acceso, especialmente en áreas como la volcanología, donde los eventos son de baja frecuencia y la instrumentación es limitada [8], la oceanografía, donde la recopilación se limita en gran parte a teledetección satelital , la astrofísica, la medicina, entre otros [9]-[11]. En particular, el modelamiento de fenómenos físicos complejos, como es el caso de la mecánica de fluidos sigue siendo un desafío debido a su naturaleza no lineal y la alta dimensionalidad de los sistemas involucrados [12], [13]. Un modelo basado puramente en datos observados puede converger a una solución, y a la vez violar principios fundamentales de la física, como pueden ser las leyes de conservación de masa, momento, entre otros.

En este contexto, las redes neuronales informadas por la física (PINNs) han surgido como una herramienta prometedora para abordar estos desafíos, integrando principios físicos directamente en el proceso de aprendizaje [14]. Mientras que los métodos de aprendizaje

automático tradicionales requieren una gran cantidad de datos para poder entrenar modelos con una alta precisión, en muchos escenarios del mundo cotidiano la recopilación de información puede ser costosa y difícil de realizar. Por otra parte, las PINNs incorporan el conocimiento de las leyes físicas que gobiernan el fenómeno a modelar, lo que permite una mejor generalización del modelo aún con una escasez de información. Este enfoque consiste en utilizar una red neuronal artificial como un aproximador de la solución de una ecuación diferencial parcial (EDP), incorporando su residuo como un término adicional a la función de pérdida de dicha RNA. Es de esta manera que al entrenar la red, esta no sólo penaliza el error de los datos, sino también el grado de lejanía de la solución respecto a las ecuaciones que gobiernan el fenómeno, evaluado en puntos de colocación. La Tabla 1 resume las principales diferencias entre ambos enfoques mencionados.

Estas propiedades de las PINNs resultan particularmente valiosas al modelar fenómenos de baja frecuencia de ocurrencia y difícil instrumentación, donde los registros son de difícil acceso y costosos tanto en tiempo como monetario, pero sí incluyen un modelo físico que describa su comportamiento. Los lahares, flujos de agua y sedimentos que se desplazan por el edificio cónico de un volcán, son uno de los fenómenos más destructivos asociados a los peligros volcánicos, y constituyen un ejemplo representativo de esta situación.

El modelamiento matemático de la morfodinámica de un lahar implica resolver un sistema de ecuaciones diferenciales parciales no lineales que describen la evolución de un flujo que mezcla agua y sedimento sobre una topografía. Tradicionalmente, esta tarea se resuelve utilizando simuladores basados en métodos numéricos. Dentro de los modelos computacionales más conocidos se encuentran: a) LAHARZ, que es un modelo computacional que utiliza descripciones estadísticas de áreas inundadas por eventos pasados de flujo masivo para pronosticar áreas que probablemente serán inundadas por eventos hipotéticos futuros [15]; b) D-Claw, siendo una biblioteca de software para la simulación de flujos granulares densos sobre topografía espacialmente variable [16]; c) LaharFlow, que es un software de dinámica de lahares, diseñado en la Universidad de Bristol, que modela el flujo de lahar como una mezcla de agua y granos sólidos, basado en tres principios de conservación. Estos son conservación de la masa, momentum y transporte de material sólido [17]. Si bien han sido de utilidad en la creación de mapas de peligro, presentan limitaciones como costos computacionales elevados junto con altos tiempos de respuesta en escenarios donde una respuesta rápida es mandatoria. Considerando las limitancias de métodos tradicionales y las ventajas de los métodos vanguardistas, es precisamente en donde las PINNs surgen como estudio de interés para problemas de volcanología.

Si bien, en la literatura existen trabajos que han aplicado PINNs al modelamiento de flujos de aguas someras y flujos de masa, no se han encontrado una aplicación de este tipo de enfoque a modelamiento de fenómenos laháricos y volcanológicos. Este trabajo considera el uso de un sistema de ecuaciones diferenciales parciales que describen la dinámica de flujos mixtos de agua y sedimento, conservaciones de masa y momentum, advección-difusión y presión de poros.

El volcán Villarrica también conocido como Rukapillan ($\sim 39{,}5°S$, ubicado a $2847\ m$ sobre el nivel del mar) es un estratovolcán parcialmente glaciado dentro de la Zona Volcánica del Sur (SVZ) de los Andes de Chile [18]. Siendo el volcán de mayor riesgo de Chile[1] y uno de los más activos de América del Sur, este estratovolcán ha presentado gran frecuencia eruptiva durante los años, afectando a poblados cercanos, como lo es la ciudad de Pucón [19], [20]. Dada una gran cobertura glaciar con un alcance de aproximadamente $40\ km^2$ y un volumen de hielo de $\sim 8\ km^3$, equivalente a $\sim 6{,}5\ km^3$ de agua, lo convierte en una fuente recurrente de lahares en episodios eruptivos. Flujos laháricos tanto antiguos como recientes han invadido los sistemas de drenajes del Volcán Villarrica, provocando daños significativos a la infraestructura de las poblaciones aledañas a este. Eventos históricos como los lahares de $1908, 1964$ y 1971 suman más de 100 fatalidades y un número desconocido de personas desaparecidas [21]. El evento eruptivo del 3 de marzo de 2015 generó un lahar que descendió más de $20\ km$ por el drenaje del Estero Correntoso-Turbio, Estero Zanjón-Seco y Río Pedregoso, entre otros, evacuando a miles de personas y generando daños en puentes cercanos. Estos eventos convierten al Volcán Villarrica en un caso de estudio para analizar la morfodinámica de lahares mediante un enfoque basado en PINNs.

El objetivo general de este trabajo es desarrollar un modelo de lahares basado en Redes Neuronales Informadas por la Física (PINNs), aplicado al evento eruptivo de 2015 del volcán Villarica, Chile, incorporando ecuaciones acopladas de flujo somero, concentración sólida y presión de poros. Los objetivos específicos consisten en $1)$ Formular un sistema acoplado de Ecuaciones Diferenciales Parciales (PDEs) que modelen la morfodinámica de un lahar, incorporando conservación de masa, momento, concentración sólida y presión de poros. $2)$ Construir una Red Neuronal Informada por la Física, basada en un sistema de ecuaciones diferenciales y parámetros geológicos, con la finalidad de predecir el comportamiento real de un flujo de sedimento. $3)$ Diagnosticar patologías de desvanecimiento y decaimiento de los gradientes e incorporar técnicas de estabilización y optimización avanzadas para mejorar la convergencia del modelo. $4)$ Predecir la morfodinámica de manera realista y acorde a la física para exportar un mapa de peligro volcánico que entregue datos de

[1] El riesgo volcánico se compone del peligro volcánico más la exposición de la población circundante

evacuación según el riesgo calculado por la red neuronal.

La hipótesis para este estudio es que las Redes Neuronales Informadas por la Física (PINNs) pueden modelar de manera efectiva la morfodinámica de los lahares, entregando predicciones precisas y consistentes con las leyes físicas. Este trabajo propone un enfoque novedoso para el estudio de la morfodinámica de lahares al aplicar redes neuronales informadas por la física a un fenómeno donde, hasta donde se ha revisado, este tipo de metodología no ha sido explorada. Se espera que este enfoque permita superar los resultados de los métodos tradicionales, ofreciendo predicciones más precisas gracias a los sistemas acoplados de EDPs y la incorporación de la física. Asimismo, se espera permita una mejor comprensión del comportamiento de los lahares y contribuya a la mitigación de riesgos en áreas propensas a estos fenómenos.

El cuerpo de esta tesis se organiza de la siguiente manera. El Capítulo 1 presenta los fundamentos teóricos computacionales que sustentan este trabajo, abarcando desde la neurona artificial y el perceptrón multicapa hasta las funciones de activación, los algoritmos de optimización y la formulación de las redes neuronales informadas por la física. El Capítulo 2 describe el contexto geográfico y geológico de los peligros volcánicos, con énfasis en los lahares y en la caracterización del volcán Villarrica como caso de estudio.

Cuadro 1: Comparación entre redes neuronales artificiales convencionales y redes neuronales informadas por la física (PINN).

Características	**RNA convencional**	**PINN**
Fuente de aprendizaje	Únicamente datos etiquetados	Datos etiquetados y EDPs
Volumen de datos	Alto	Reducido
Consistencia física	No garantizada	Garantizada por la EDP
Función de pérdida	Error sobre los datos	Datos, condiciones iniciales/borde y residuo físico
Extrapolación y generalización	Limitada a la distribución de los datos	Mayor robustez al estar restringida por el modelo físico
Interpretabilidad	Opera como caja negra	La solución satisface leyes físicas conocidas

Capítulo 1

Redes neuronales artificiales

1.1. Redes Neuronales Artificiales

Una red neuronal artificial (RNA) o por sus siglas en inglés ANN (*Artificial Neural Network*) es un modelo matemático que intenta simular la estructura y las funcionalidades de las redes neuronales biológicas. El bloque base de una RNA es un una neurona artificial, esto es, un simple modelo matemático o función. Este modelo contiene tres reglas básicas: la suma ponderada de las entradas, la adición de un sesgo y la aplicación de una función de activación. Las entradas de la neurona multiplicadas por un peso, es decir, cada valor de entrada es ponderado por un peso individual. En el medio de la neurona se encuentra la función que suma todas las entradas ponderadas y los sesgos. Posterior a la suma, en la salida de la neurona se encuentra la función de activación, la cual es una función no lineal que determina si la neurona se activa o no [22], [23].

1.1.1. Neurona Artificial

Su formulación matemática se inspira en el funcionamiento de la neurona biológica desde un punto de vista más simple: las dendritas que reciben señales son representadas por las entradas ponderadas, el cuerpo celular que integra dichas señales se representa mediante una suma, y el axón que transmite el resultado equivale a una función de salida. El primer modelo matemático formal de esta idea fue propuesto por McCulloch y Pitts [24], quienes introdujeron una neurona binaria capaz de representar operaciones lógicas a partir de la combinación de señales de entrada. Si bien, este modelo original consideraba únicamente salidas binarias, sentó las bases teóricas de las neuronas artificiales que se utilizan actualmente.

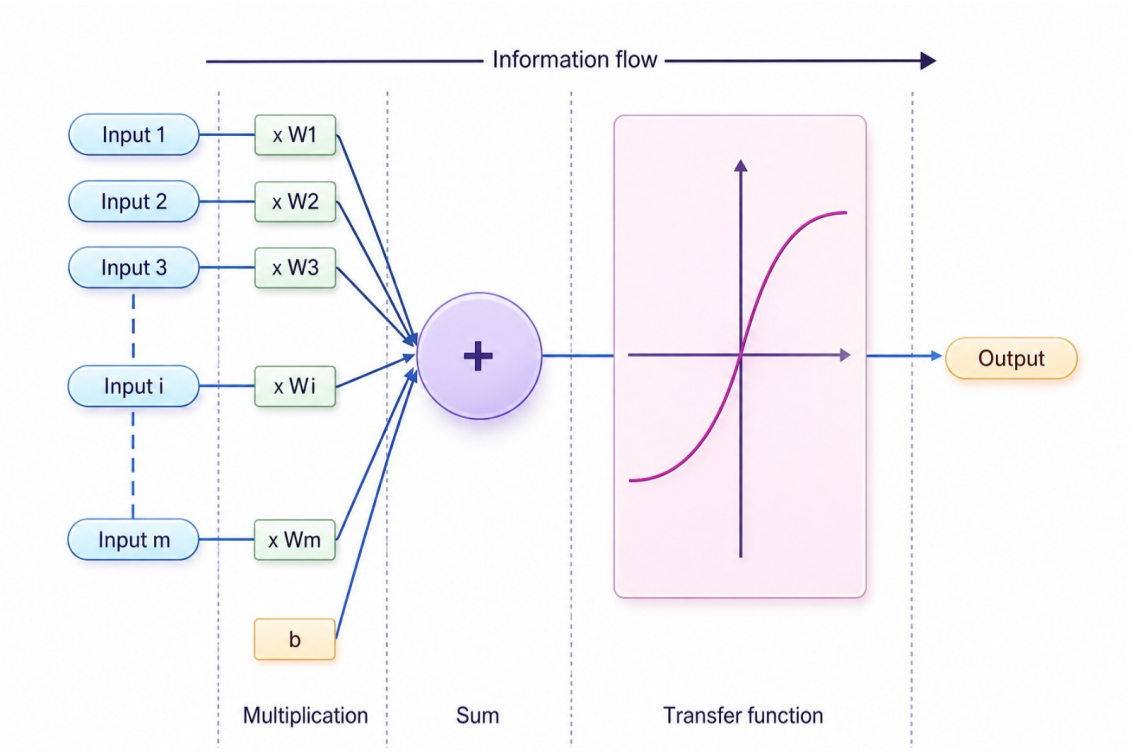

Figura 1.1: Esquema de trabajo de una neurona artificial.
Fuente: Construcción propia basada en [22].

Formalmente, sea $\mathbf{x} = (x_1, x_2, \ldots, x_n) \in \mathbb{R}^n$ el vector de entradas de la neurona. A cada entrada x_i se le asocia un peso sináptico $w_i \in \mathbb{R}$, que pondera su contribución relativa, es decir, qué tanto impacto causará en el valor de salida. La neurona calcula primero una combinación lineal de las entradas, conocida como *entrada neta* o *potencial de activación*, se define como,

$$z = \sum_{i=1}^{n} w_i x_i + b, \tag{1.1}$$

donde $b \in \mathbb{R}$ es el sesgo (*bias*), un parámetro adicional que permite desplazar el umbral de activación de la neurona independientemente de los valores de entrada. Es posible escribir la Ecuación (1.1) de forma compacta como $z = \mathbf{w}^\top \mathbf{x} + b$, con,

$$\mathbf{w} = (w_1, \ldots, w_n)^\top. \tag{1.2}$$

Posteriormente, la entrada neta z es transformada mediante una función de activación $\varphi : \mathbb{R} \to \mathbb{R}$. Esta función introduce no linealidad en la arquitectura de la red neuronal,

permitiéndole aproximar relaciones complejas que no pueden representarse mediante una sucesión de transformaciones exclusivamente lineales. La salida de una neurona artificial puede expresarse como,

$$y = \varphi(z) = \varphi\left(\sum_{i=1}^{n} w_i x_i + b\right). \tag{1.3}$$

En el contexto de una PINN, esta no linealidad propia de la arquitectura debe distinguirse de la no linealidad asociada al sistema físico gobernante. En el presente problema, las ecuaciones diferenciales parciales que describen la dinámica del lahar contienen términos no lineales, particularmente aquellos asociados al transporte advectivo y al acoplamiento entre espesor, velocidad, concentración sólida y presión de poros. Las ecuaciones gobernantes no introducen la no linealidad de la red neuronal, sino que actúan como restricciones físicas durante su entrenamiento.

Es importante notar que si bien la analogía biológica resulta útil como aproximación conceptual, la neurona artificial descrita por las ecuaciones (1.1) y (1.3) es sólo un modelo matemático de aproximación de funciones. La limitancia computacional de usar una sola neurona corresponde a su restringida capacidad de transformaciones lineales simples de sus entradas. Las redes neuronales consiguen su potencia a partir de la interconexión de múltiples neuronas organizadas en una arquitecturas basadas en capas, creando así al perceptrón multicapa.

1.1.2. Perceptrón Multicapa

El perceptrón multicapa (MLP, por sus siglas en inglés) es la arquitectura más común de redes neuronales artificiales. En la mayoría de los casos, las señales son transmitidas de manera unidireccional desde la capa de entrada hasta la capa de salida y el valor de salida de la neurona no afecta a la red. Este tipo de arquitectura se llama *feedforward* y se representa mediante un grafo acíclico dirigido.

Las capas que no se conectan directamente con la entrada o la salida se denominan capas ocultas. La presencia de estas capas permite a la red aprender representaciones intermedias de los datos, capturando patrones complejos y no lineales que serían inalcanzables para un modelo lineal simple. La introducción de múltiples capas es determinada por la complejidad de la función que se desea aproximar y la no-linealidad de esta. En general, a

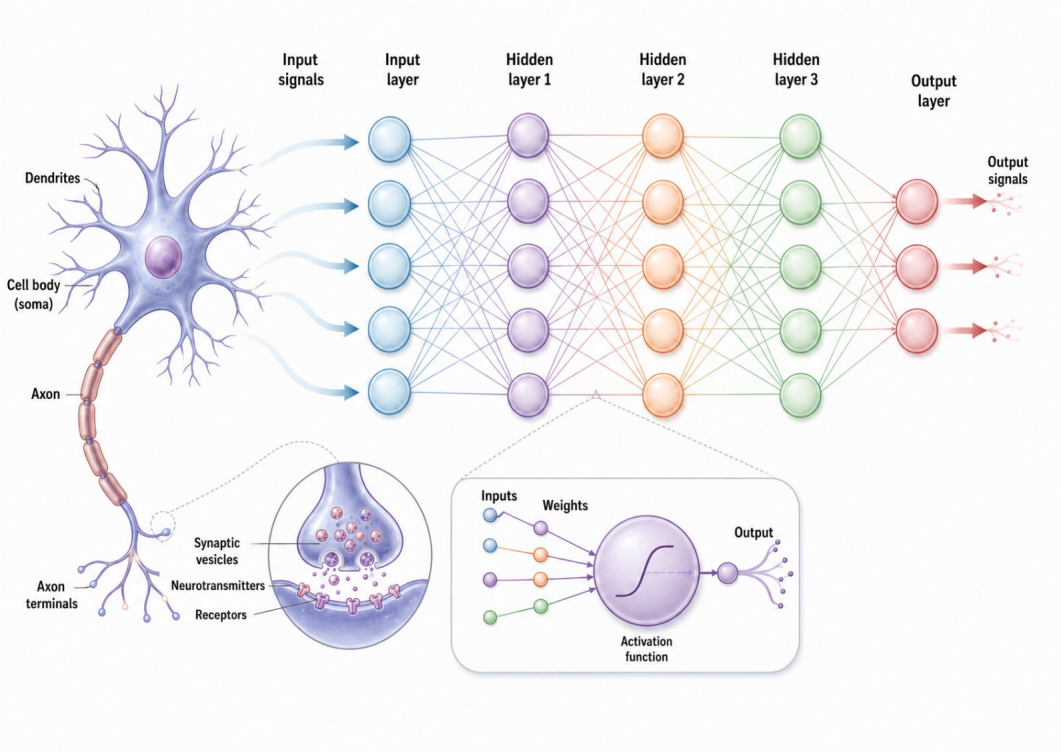

Figura 1.2: Esquema de una neurona artificial con n entradas ponderadas, un sesgo y una función de activación.

Fuente: Construcción propia basada en [25].

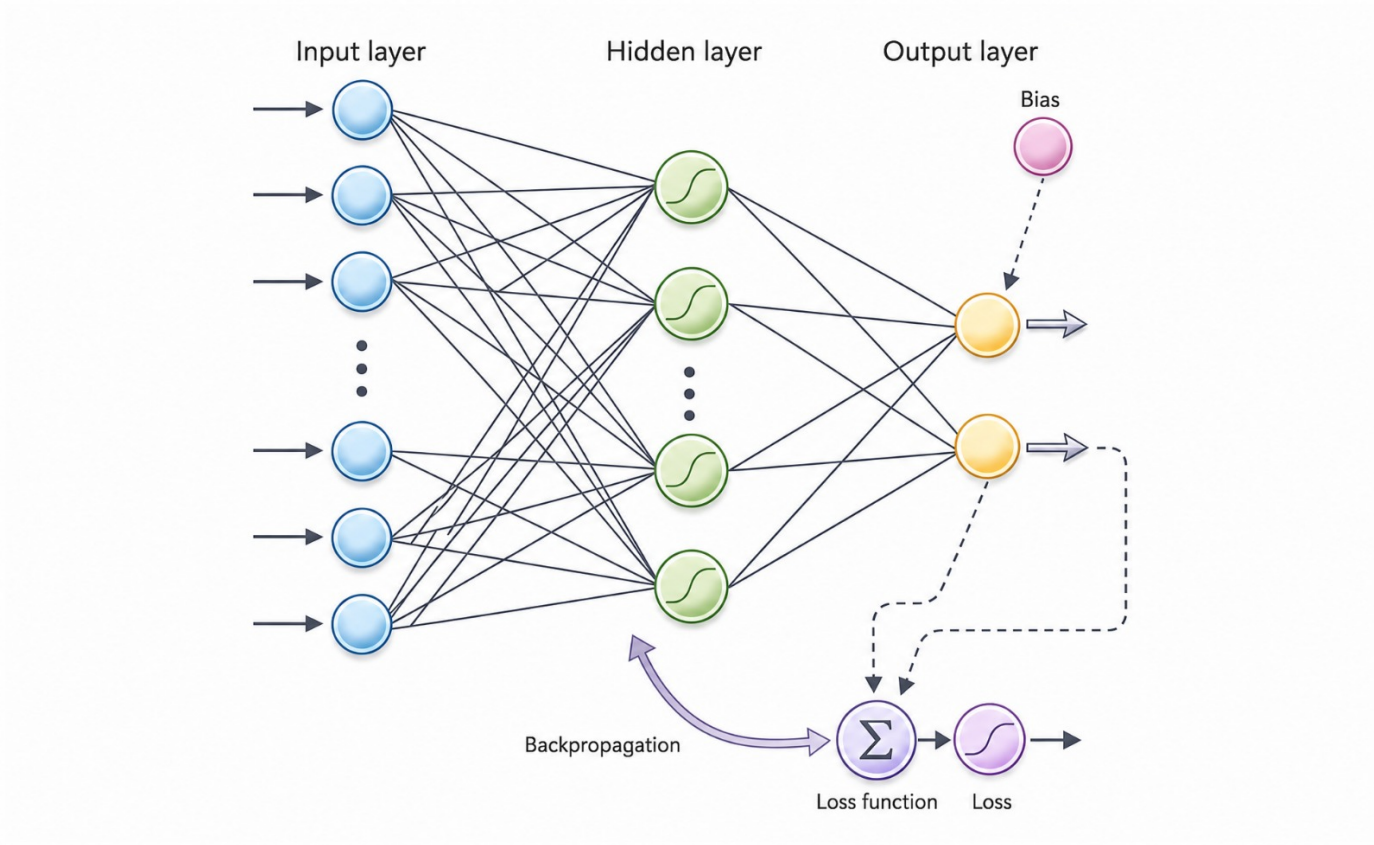

Figura 1.3: Red neuronal feedforward de tres capas con una capa de entrada, una (o más) capa(s) oculta(s) y una capa de salida.
Fuente: Construcción propia basada en [25].

mayor complejidad de la función objetivo, mayor número de capas y neuronas se requerirá para lograr predicciones con mayor precisión. El número de neuronas en la capa de entrada depende de la cantidad de variables independientes o de entrada que se deseen considerar, mientras que el número de neuronas en la capa de salida depende de la cantidad de variables dependientes que se deseen predecir. Finalmente, tanto el número de capas ocultas como el número de neuronas por capa son dependientes de la complejidad del modelo y son parámetros importantes en el desarrollo del MLP [25].

Desde un punto de vista formal, es posible extender la formulación presentada para una única neurona basada en las ecuaciones (1.1) y (1.3) a la red completa mediante la composición sucesiva de transformaciones afines y funciones de activación, aplicadas capa a capa. Sea L el número total de capas de la red (sin contar la capa de entrada), y sea $\mathbf{h}^{(l)} \in \mathbb{R}^{n_l}$ el vector de activaciones de la capa l, con $\mathbf{h}^{(0)} = \mathbf{x}$ el vector de entrada. La

salida de cada capa $l = 1, \ldots, L$ se calcula recursivamente como,

$$\mathbf{h}^{(l)} = \varphi^{(l)}\left(W^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}\right), \tag{1.4}$$

donde $W^{(l)} \in \mathbb{R}^{n_l \times n_{l-1}}$ es la matriz de pesos que conecta la capa $l-1$ con la capa l, $\mathbf{b}^{(l)} \in \mathbb{R}^{n_l}$ es el vector de sesgos de la capa l, y $\varphi^{(l)}$ es la función de activación correspondiente, aplicada componente a componente. Nótese que la ecuación (1.4) generaliza directamente las Ecuaciones (1.1) y (1.3) de la neurona individual, aplicándolas ahora de manera simultánea a todas las neuronas de una capa.

La salida final de la red, $\hat{\mathbf{y}} = \mathbf{h}^{(L)}$, queda expresada como la composición de L transformaciones sucesivas,

$$\hat{\mathbf{y}} = F_{\boldsymbol{\theta}}(\mathbf{x}) = \varphi^{(L)}\left(W^{(L)}\varphi^{(L-1)}\left(\cdots \varphi^{(1)}\left(W^{(1)}\mathbf{x} + \mathbf{b}^{(1)}\right)\cdots\right) + \mathbf{b}^{(L)}\right), \tag{1.5}$$

donde $\boldsymbol{\theta} = \{W^{(l)}, \mathbf{b}^{(l)}\}_{l=1}^{L}$ agrupa el conjunto completo de parámetros entrenables de la red. Esta notación compacta, $F_{\boldsymbol{\theta}}$, será la que se utilice en lo sucesivo para referirse a la red neuronal como aproximador de una función objetivo, y resulta particularmente relevante en el contexto de las PINNs, donde una red de este tipo se emplea directamente para aproximar la solución latente $u(t, x)$ de la ecuación diferencial de interés [26].

Cabe destacar que la capacidad de un MLP para aproximar funciones arbitrarias no es solo empírica, sino que está respaldada teóricamente por el teorema de aproximación universal [7], el cual establece que una red *feedforward* con al menos una capa oculta y un número suficiente de neuronas puede aproximar cualquier función continua sobre un subconjunto compacto de $\mathbb{R}^n$ con la precisión deseada, bajo condiciones razonables sobre la función de activación.

1.2. Funciones de activación

Las funciones de activación (FA) son usadas en las redes neuronales artificiales para transformar un valor de entrada en un valor de salida a traves de un procesamiento de gradientes, el cual es usado como entrada para la siguiente capa de la red. Dentro de la literatura también se les conoce como funciones de transferencia [27]. Gran parte de la precisión a la hora de predecir un resultado depende de la función de activación que se use.

Si bien existen muchas funciones de activación, no existe una que sea mejor para todos los casos [28]. Esta FA puede ser lineal o no lineal dependiendo de la función matemática que represente y debe cumplir con no agregar complejidad computacional de manera extensiva [29].

Durante los años se han explorado y creado variedad de FA. Dentro de ellas, algunas de las más usadas son: la función sigmoide, la función tangente hiperbólica, la función ReLU y sus variantes, la función softmax y la función lineal. Cada una de estas funciones tiene propiedades matemáticas particulares que las hacen más o menos adecuadas para diferentes tipos de problemas [30]. En este capítulo se describen dos funciones de interés para este trabajo.

1.2.1. ReLU

ReLU viene del inglés *Rectified Linear Unit*, el cual significa ¨Unidad lineal rectificada¨. Esta función también es conocida como función parte-positiva, ya que, como se puede observar en la figura 1.4, para los valores positivos de entrada, la salida es igual a la entrada (función identidad), mientras que para las entradas negativas o nulas, la salida es igual a 0 [30]. Esta definida como,

$$f(x) = \max(0, x) \tag{1.6}$$

La primera y segunda derivada de esta función es,

$$\dot{f}(x) = \begin{cases} 1, & \forall x \in (0, \infty) \\ 0, & \forall x \in (-\infty, 0) \end{cases} \qquad \text{y} \qquad \ddot{f}(x) = 0 \quad \forall x \in \mathbb{R} \setminus \{0\} \tag{1.7}$$

Si se analiza la ecuación 1.7, se puede observar que la segunda derivada es 0 para todo el dominio, lo que puede repercutir negativamente en ciertos problemas que requieran de ella, como es el caso de este trabajo.

1.2.2. Sigmoide

Una función sigmoide es una función matemática suave que se caracteriza por su forma en "S". La figura 1.5 muestra que esta función es continua y diferenciable, y sus valores de salida se encuentran en el rango $(0, 1)$. Es función de activación muy usadas en el

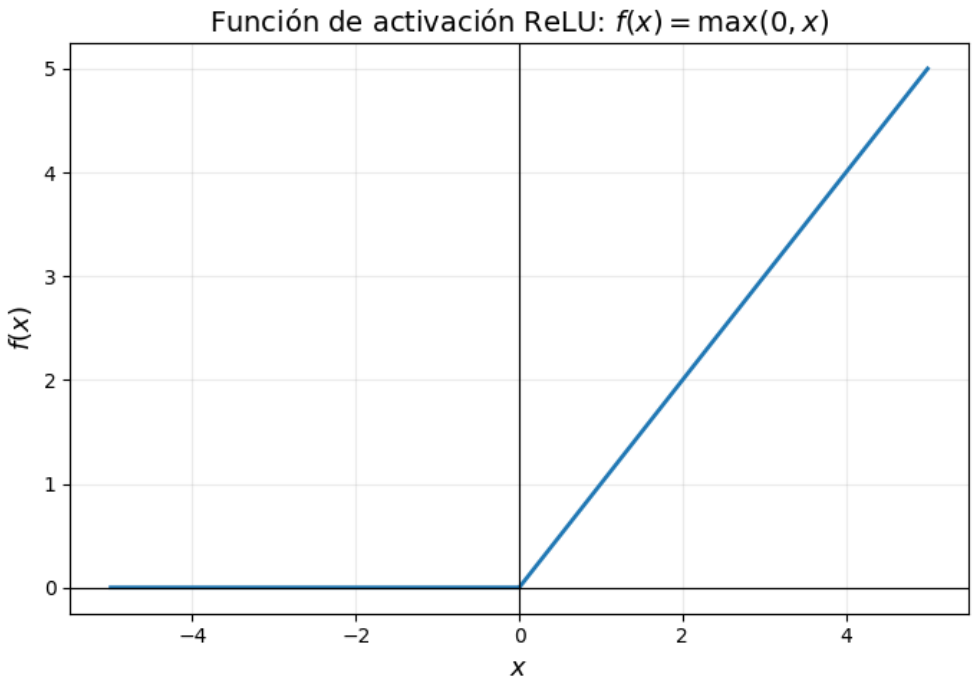

Figura 1.4: Función ReLU.

aprendizaje profundo para predecir probabilidades y salidas binarias. Se define como,

$$f(x) = \frac{1}{1 + e^{-x}} \tag{1.8}$$

La derivada de esta función es,

$$\dot{f}(x) = f(x)(1 - f(x)) \tag{1.9}$$

Si bien ReLU puede ser más usada en la actualidad en el ámbito del aprendizaje profundo, la función sigmoide tiene la ventaja de ser infinitamente diferenciable, lo que la hace muy útil en problemas donde las derivadas de orden superior son requeridas. Sin embargo, la FA Sigmoide tiene la desventaja de que puede saturar su gradiente y converger lentamente a una solución, provocando que el gradiente se propague en diferentes direcciones [27].

1.2.3. Otras funciones de activación

Dada la masividad de funciones de activación que existen, en este documento sólo se mencionan las relevantes para esta investigación. Sin embargo, la tabla 1.1 muestra un

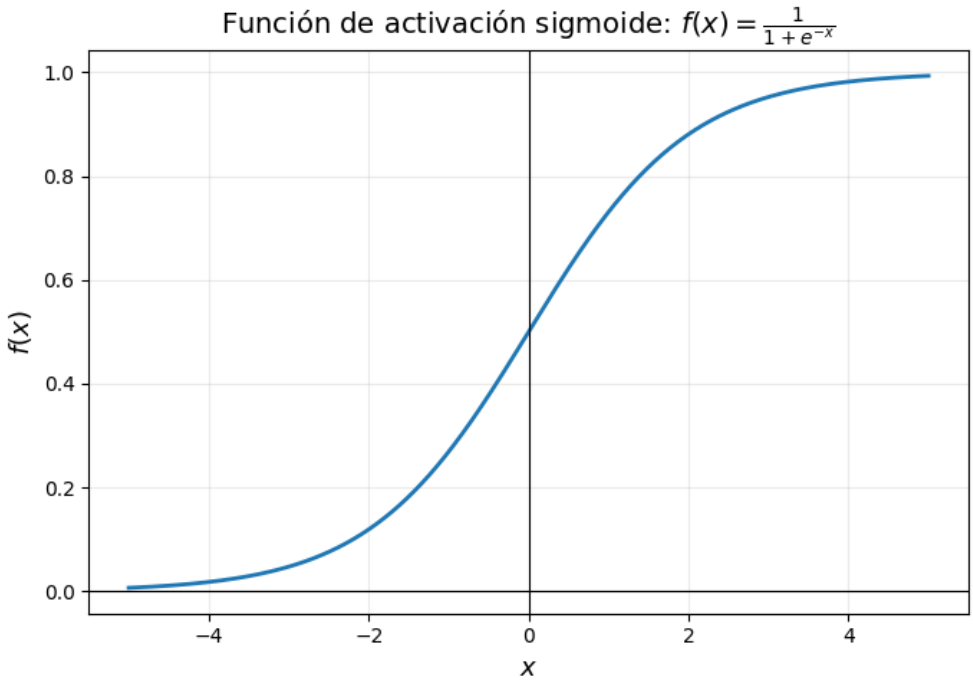

Figura 1.5: Función sigmoide.

listado de funciones de activación ampliamente usadas en la literatura y que pueden ser de interés el lector y servir como punto de comparación.

Cuadro 1.1: Resumen de funciones de activación comúnmente usadas en redes neuronales.

Fuente: Modificado de [31].

símbolo	nombre	ecuación
$\mathcal{L}_1$	pérdida L_1	$\|\mathbf{y} - \mathbf{o}\|_1$
$\mathcal{L}_2$	pérdidaL_2	$\|\mathbf{y} - \mathbf{o}\|_2^2$
log	pérdida logarítmica (entropía cruzada)	$-\sum_j \mathbf{y}^{(j)} \log \sigma(\mathbf{o})^{(j)}$
$\log^2$	pérdida logarítmica cuadrada	$-\sum_j [\mathbf{y}^{(j)} \log \sigma(\mathbf{o})^{(j)}]^2$
D_{CS}	Divergencia de Cauchy-Schwarz [3]	$-\log \frac{\sum_j \sigma(\mathbf{o})^{(j)} \mathbf{y}^{(j)}}{\|\sigma(\mathbf{o})\|_2 \|\mathbf{y}\|_2}$

1.3. Funciones de pérdida

En el aprendizaje profundo, uno de los componentes más importantes es la elección de la función de pérdida y la métrica de rendimiento adecuada para entrenar y evaluar el modelo. Las funciones de pérdida o de costo son funciones matemáticas que cuantifican

la diferencia entre una predicción del modelo y el valor real. Mientras que las métricas de rendimiento son funciones que evalúan la calidad de las predicciones del modelo sobre datos que el modelo no ha visto durante el entrenamiento [32].

La elección de ambas funciones depende principalmente de la naturaleza de la tarea. Para problemas de clasificación, donde la salida representa una distribución o .[el]ección"sobre categorías discretas, las pérdidas de tipo entropía cruzada son mandatorias. Para problemas de regresión, donde la salida corresponde a uno o más valores numéricos, se aplican funciones basadas en la diferencia del residuo entre la predicción y el valor esperado [32], [33].

Dentro de las pérdidas de regresión, las dos formulaciones más utilizadas son el error absoluto medio (MAE o pérdida L_1) y el error cuadrático medio (MSE o pérdida L_2). Se definen respectivamente como

$$\mathcal{L}_1(\boldsymbol{\theta}) = \frac{1}{N}\sum_{i=1}^{N} \left\|\mathbf{y}^i - F_{\boldsymbol{\theta}}(\mathbf{x}^i)\right\|_1 \tag{1.10}$$

$$\mathcal{L}_2(\boldsymbol{\theta}) = \frac{1}{N}\sum_{i=1}^{N} \left\|\mathbf{y}^i - F_{\boldsymbol{\theta}}(\mathbf{x}^i)\right\|_2^2 \tag{1.11}$$

Ambas funciones presentan propiedades distintas. El error cuadrático medio penaliza proporcionalmente al tamaño del cuadrado del residuo, esto otorga un peso considerablemente mayor a las desviaciones grandes y produce una función suave y diferenciable en todo su dominio [31]. Por otra parte, esta misma sensibilidad puede causar la aparición de valores atípicos. El error absoluto medio, por su parte, resulta más robusto frente a dichos valores, pero no es diferenciable en el origen [32].

1.4. Gradiente Descendente y algoritmos de optimización

El algoritmo del Gradiente Descendente (GD) es uno de los métodos más populares al momento de entrenar modelos de aprendizaje automático y por lejos la forma más común de optimizar redes neuronales, esto gracias a su eficiencia en la minimización de funciones de pérdida [34]. El GD computa el gradiente de la función de pérdida con respecto a los parámetros del modelo [35]. Sea $\mathcal{L}(\theta)$ una función de pérdida, tal que $\theta \in \mathbb{R}^d$ es el conjunto

de parámetros del modelo. El gradiente de la función de pérdida parametrizada se denota como $\nabla_\theta \mathcal{L}(\theta)$.

La optimización se refiere a proceso de minimizar o maximizar una función $f(x)$ mediante la alteración de su parámetro x. El entrenamiento de una red neuronal artificial puede ser considerado como una problema de optimización no convexa[1], cuyo objetivo es encontrar el conjunto de parámetros θ que minimice la función de pérdida $\mathcal{L}(\theta)$ sobre el conjunto de datos de entrenamiento [26], [37]. Se expresa como,

$$\theta^* = \arg\min_\theta \mathcal{L}(\theta) \tag{1.12}$$

1.4.1. Gradiente Descendiente (*Batch Gradient Descent*)

Manteniendo la notación de la ecuación 1.12. Sea $\eta > 0$ la tasa de aprendizaje (*learning rate*) que determina el tamaño de los pasos para alcanzar el mínimo local y $\mathcal{L} : \mathbb{R} \to \mathbb{R}$ una función diferenciable. El gradiente descendente se define como,

$$\theta = \theta - \eta \cdot \nabla_\theta \mathcal{L}(\theta) \tag{1.13}$$

Dado que se deben calcular los gradientes respecto a todos los parámetros de todo el conjunto, este método puede ser computacionalmente costoso, lento e incluso no computable para conjuntos de datos que no caben en memoria [34], [38].

1.5. Redes Neuronales Informadas por la Física (PINNs)

Este trabajo adopta una aproximación diferente a lo que suele realizarse en la literatura, empleando redes neuronales profundas gracias a su gran y bien conocida capacidad como aproximadores universales [7]. De esta manera se puede abordar sin problemas la no-linealidad de los sistemas acoplados que aborda este trabajo. En áreas tales como sistemas físicos, biológicos o de ingeniería puede ser difícil o directamente imposible conseguir datos para el entrenamiento de modelos de aprendizaje automático causando un sesgo de entrenamiento y conclusiones incompletas o equívocas.

[1] A diferencia de la optimización convexa, en la no convexa puede haber múltiples mínimos locales. [36]

Consideramos una ecuación diferencial no lineal y parametrizada en su forma general,

$$\mathbf{u}_t + \mathcal{N}[\mathbf{u}] = 0, \quad x \in \Omega, t \in [0, T] \tag{1.14}$$

donde $u(t, x)$ denota la solución latente[2], $\mathcal{N}[\cdot]$ es un operador diferencial lineal o no lineal y Ω es un subconjunto de $\mathbb{R}^d$. Sujeto a las condiciones iniciales y de frontera,

$$\mathbf{u}(0, x) = g(x), x \in \Omega, \tag{1.15}$$

$$\mathcal{B}[\mathbf{u}] = 0, \quad t \in [0, T], x \in \partial\Omega \tag{1.16}$$

donde $\mathcal{B}[\cdot]$ es un operador de frontera correspondiente a Dirichlet, Neumann o Robin, o condiciones de frontera periodicas.

Se representa la solución desconocida (latente) de una red neuronal profunda $u_\theta(t, x)$, donde θ denota el conjunto de parámetros entrenables o configurables de la red, por ejemplo, pesos y sesgos. Esto permite definir los residuos de la ecuación diferencial como,

$$\mathcal{R}_\theta(t, \mathbf{x}) = \frac{\partial \mathbf{u}_\theta}{\partial t}(t_r, \mathbf{x}_r) + \mathcal{N}[\mathbf{u}_\theta](t_r, \mathbf{x}_r) \tag{1.17}$$

Dadas las ecuaciones anteriores, es posible entrenar un modelo informado por la física, minimizando la función de pérdida,

$$\mathcal{L}(\theta) = \lambda_1 \mathcal{L}_{ic}(\theta) + \lambda_2 \mathcal{L}_{bc}(\theta) + \lambda_3 \mathcal{L}_r(\theta) \tag{1.18}$$

donde,

$$\mathcal{L}_{ic}(\theta) = \frac{1}{N_{ic}} \sum_{i=1}^{N_{ic}} \left| \mathbf{u}_\theta(0, \mathbf{x}_{ic}^i) - g(\mathbf{x}_{ic}^i) \right|^2, \tag{1.19}$$

$$\mathcal{L}_{bc}(\theta) = \frac{1}{N_{bc}} \sum_{i=1}^{N_{bc}} \left| \mathcal{B}[\mathbf{u}_\theta](t_{bc}^i, \mathbf{x}_{bc}^i) \right|^2, \tag{1.20}$$

$$\mathcal{L}_r(\theta) = \frac{1}{N_r} \sum_{i=1}^{N_r} \left| \mathcal{R}_\theta(t_r^i, \mathbf{x}_r^i) \right|^2 \tag{1.21}$$

[2]Referente a la solución o trayectoria computada representada dentro de una dimensión espacial comprimida oculta (espacio latente) más que en el espacio físico real [39].

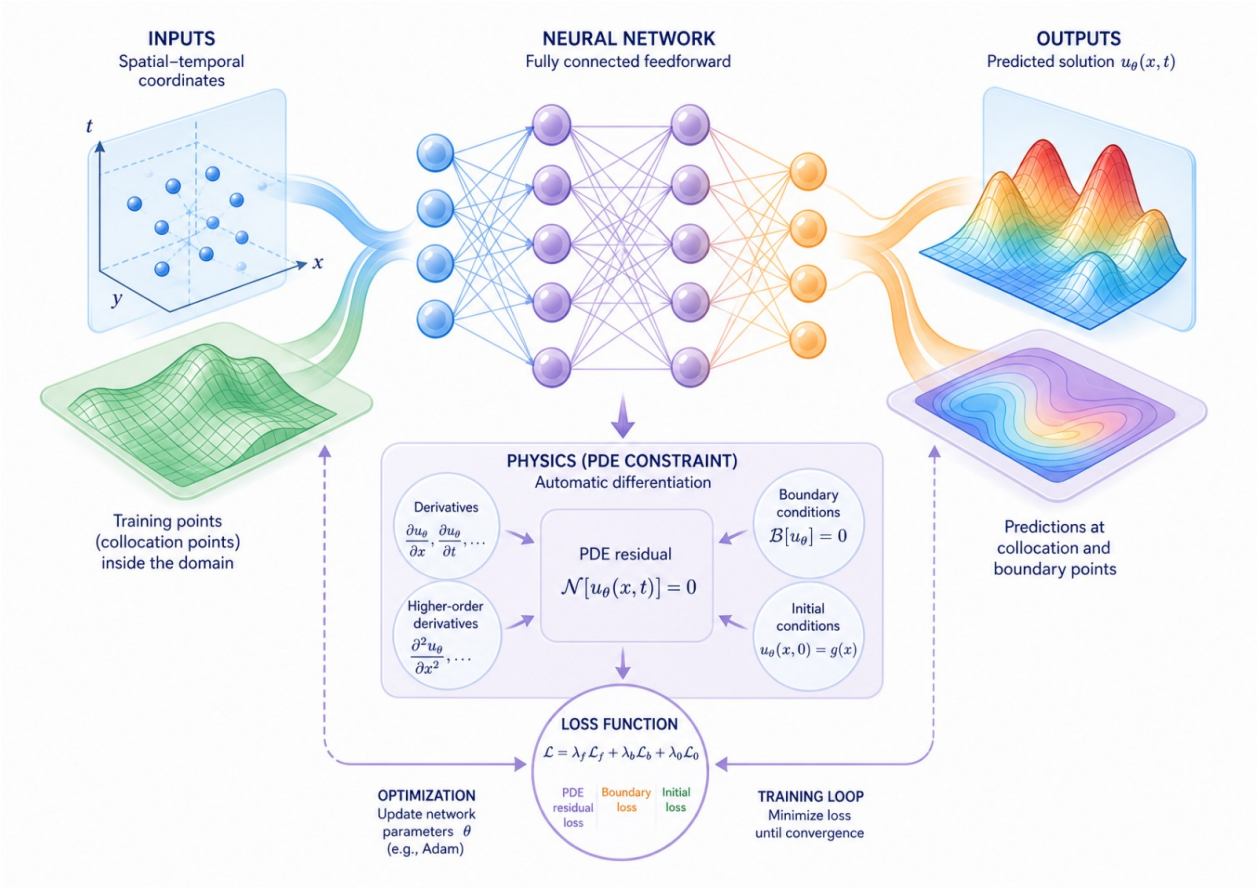

Figura 1.6: Esquema de una red neuronal informada por la física (PINN) con su sistema compuesto de funciones de pérdida y EDPs.
Fuente: Creación propia basada en [14].

De esta forma, $\{x_{ic}^i\}_{i=1}^{N_{ic}}$ representan los puntos de datos iniciales, $\{x_{bc}^i\}_{i=1}^{N_{bc}}$ los puntos de datos de frontera y $\{x_r^i\}_{i=1}^{N_r}$ los puntos de datos residuales. Estos datos pueden ser vertices de mallas fijas o puntos aleatoriamente distribuidos en cada iteración del algoritmo del gradiente descendente. Obsérvese que cada gradiente con respecto a las variables de entrada o a los parámetros θ de la red pueden ser calculados de forma eficiente mediante la diferenciación automática. [14], [40], [41]. La figura 1.6 muestra un esquema de una red neuronal informada por la física (PINN) con su función de pérdida compuesta de la ecuación 1.18.

Capítulo 2

Contexto geológico

2.1. Introducción a los peligros volcánicos

El peligro volcánico corresponde a la posibilidad de ocurrencia de fenómenos o procesos volcánicos potencialmente dañinos en un área determinada, caracterizados por su extensión espacial, intensidad o magnitud y, cuando es posible, por su probabilidad de ocurrencia dentro de un intervalo temporal específico [42], es decir, son el fenómeno físico. Entre estos fenómenos se incluyen, entre otros, la caída de tefra, los flujos piroclásticos, las coladas de lava, los proyectiles balísticos y los lahares. La evaluación del peligro busca determinar las áreas potencialmente afectadas y las características físicas del fenómeno, tales como su extensión, profundidad, velocidad o intensidad. Esta información puede representarse mediante mapas de peligro, los cuales constituyen una herramienta fundamental para la planificación territorial y la gestión del riesgo volcánico.

Los peligros volcánicos abarcan una amplia variedad de fenómenos cuya naturaleza, alcance y grado de destructividad dependen tanto del estilo eruptivo del volcán como de las condiciones ambientales de su entorno [43]. Es posible distinguir entre peligros primarios que corresponden a productos directos de la actividad eruptiva y peligros secundarios, que se originan como consecuencia de la interacción entre dichos productos y el entorno, incluso en ausencia de actividad eruptiva activa [44].

Entre los peligros primarios se encuentran los flujos de lava, coladas de roca fundida que, si bien rara vez representan una amenaza directa para la vida humana debido a sus velocidades de desplazamiento relativamente bajas, pueden sepultar, destruir o incendiar toda infraestructura a su paso [43]. Asimismo, la caída de tefra, la cual consiste en diferentes componentes con una densidad variable, tanto de partículas jóvenes (magma fresco) como líticas (roca envolvente), y pueden variar desde bloques y bombas de cerca de un metro de tamaño que son expulsados de la erupción de forma balística y caen unos

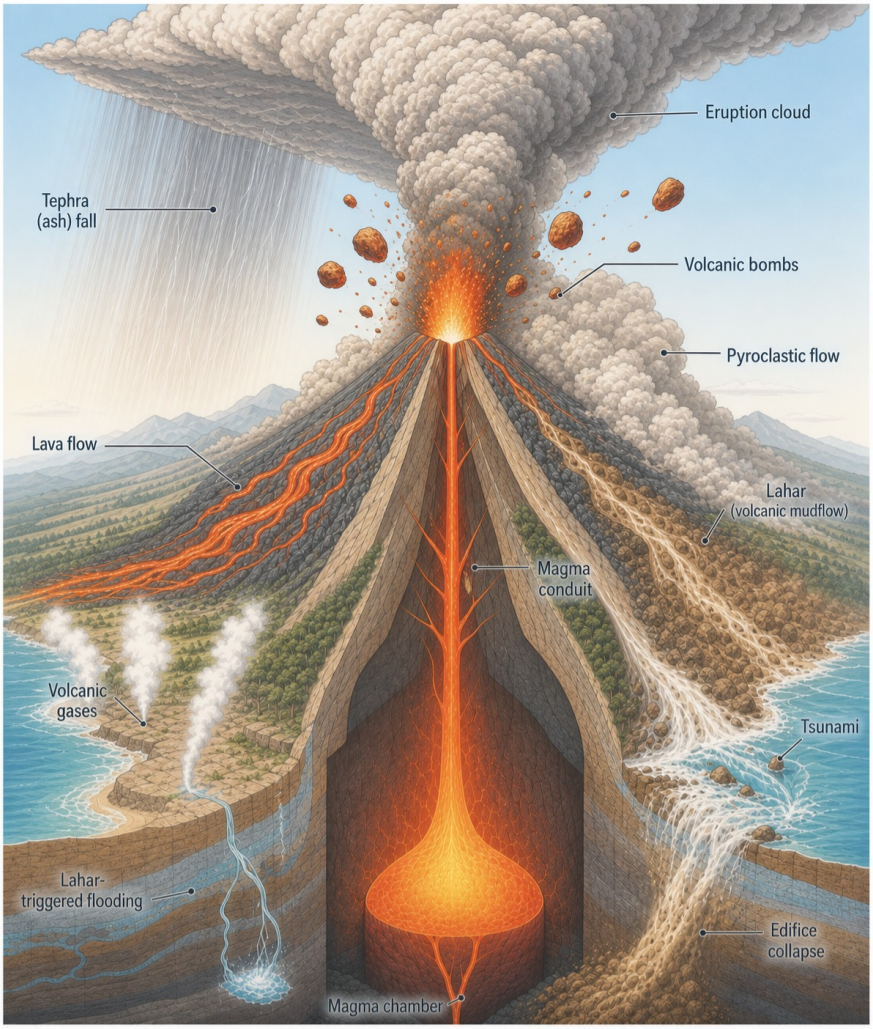

Figura 2.1: Esquema de un volcán y sus principales peligros.
Fuente: Creación propia.

pocos kilómetros desde la fuente de erupción, hasta partículas de tamaño del orden de los micrones que pueden ser transportadas por el viento a escala continental o global [45]. Los flujos piroclásticos, por su parte, corresponden a corrientes de alta densidad compuestas por gases calientes y material volcánico fragmentado y son considerados el peligro volcánico individualmente más letal debido a su elevada temperatura y velocidad de desplazamiento [43].

Dentro de los peligros secundarios destacan los lahares, flujos de detritos saturados en agua que se originan a partir de la remoción de material volcánico no consolidado presente en las laderas del edificio volcánico [46]. A diferencia de otros peligros volcánicos, los lahares pueden generarse tanto durante episodios eruptivos activos, por ejemplo, mediante la fusión rápida de nieve o hielo por flujos piroclásticos tanto como en ausencia de actividad

eruptiva, disparados por precipitaciones intensas sobre depósitos piroclásticos inestables [47]. Esta capacidad de generarse independientemente de la actividad eruptiva, sumada a un alcance a lo largo de valles fluviales que puede extenderse decenas de kilómetros desde el volcán, los convierte en uno de los peligros volcánicos con mayor potencial de afectar a poblaciones alejadas del cono volcánico [48].

La magnitud y frecuencia relativa de estos fenómenos suele caracterizarse a nivel de erupción mediante escalas semicuantitativas como el Índice de Explosividad Volcánica (VEI), que permite comparar eventos eruptivos históricos en función del volumen de material expulsado, la altura de la columna eruptiva, entre otros [49]. Sin embargo, dicha escala describe la magnitud de la erupción en su conjunto y no captura por sí sola el riesgo diferenciado que cada tipo de peligro representa para las comunidades expuestas. Análisis recientes de bases de datos de víctimas fatales por erupciones volcánicas muestran que peligros como los flujos piroclásticos y los lahares concentran una proporción desproporcionadamente alta de las víctimas fatales en comparación con la caída de tefra, pese a que esta última suele tener un mayor alcance geográfico [50].

2.2. Lahares

Lahar es un término de origen indonesio (javanés) que actualmente se considera en el idioma inglés y se traduce como un flujo de lodo destructivo que desciende por las laderas de un volcán, tal como se observa en la figura 2.2. Su primer uso documentado data de 1922 por Escher, el cual propuso que los flujos de lodo volcánico se originan en la erupción de: un lago cratérico, el derretimiento de una capa de hielo o intensas lluvias sobre materiales sueltos [51]. El lahar histórico más mortal ocurrió en 1985 en el Nevado del Ruiz (Colombia) cuando el derretimiento glacial inducido por la erupción produjo flujos que viajaron más de $100\ km$ y mataron a más de 25.000 personas [52]. Lahares tales como los de Nevado del Ruiz pueden ser generados coincidentemente con erupciones volcánicas, pero también pueden ser generados como un flujo secundario de episodios de lluvia en laderas cubiertas de ceniza, roturas de los embalses de los lagos de cráter o erosión o derrumbe espontáneos de las laderas volcánicas [53].

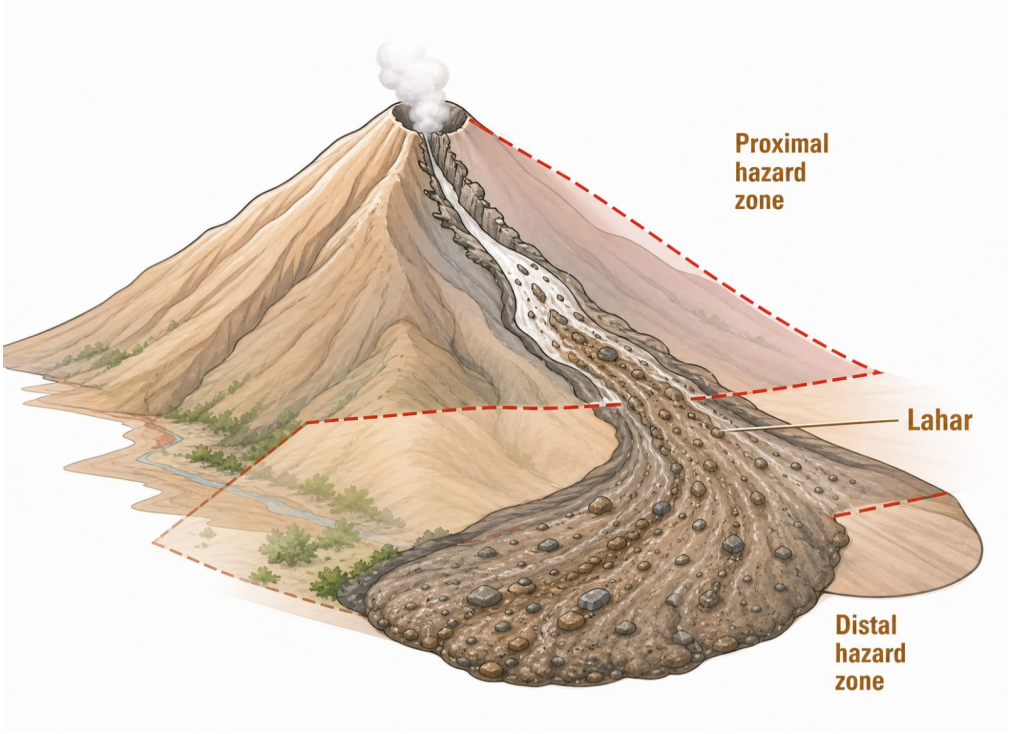

Figura 2.2: Lahar y sus zonas de peligro
Fuente: [55]

2.2.1. Zonas Volcánicas de Chile

Chile se ubica en las zonas de subducción entre la placa de Nazca y la placa Sudamericana, y entre las placas Antártica y Sudamericana, ambas zonas separadas por la subducción de la Dorsal de Chile a los $\sim 47°S$, dando origen al arco volcánico de la Cordillera de los Andes. Existen tres zonas volcánicas de este arco ubicadas en Chile: la Zona Volcánica Central, en la zona norte del país $(17 - 27°S)$ y compartida con Bolivia y Perú; la Zona Volcánica Sur en la zona centro-sur de Chile $(33 - 46°S)$; y la Zona Volcánica Austral en el sur del país $(49 - 55°S)$. A lo largo de estas zonas volcánicas se reconocen numerosos centros eruptivos, de los cuales 92 se consideran geológicamente activos [54].

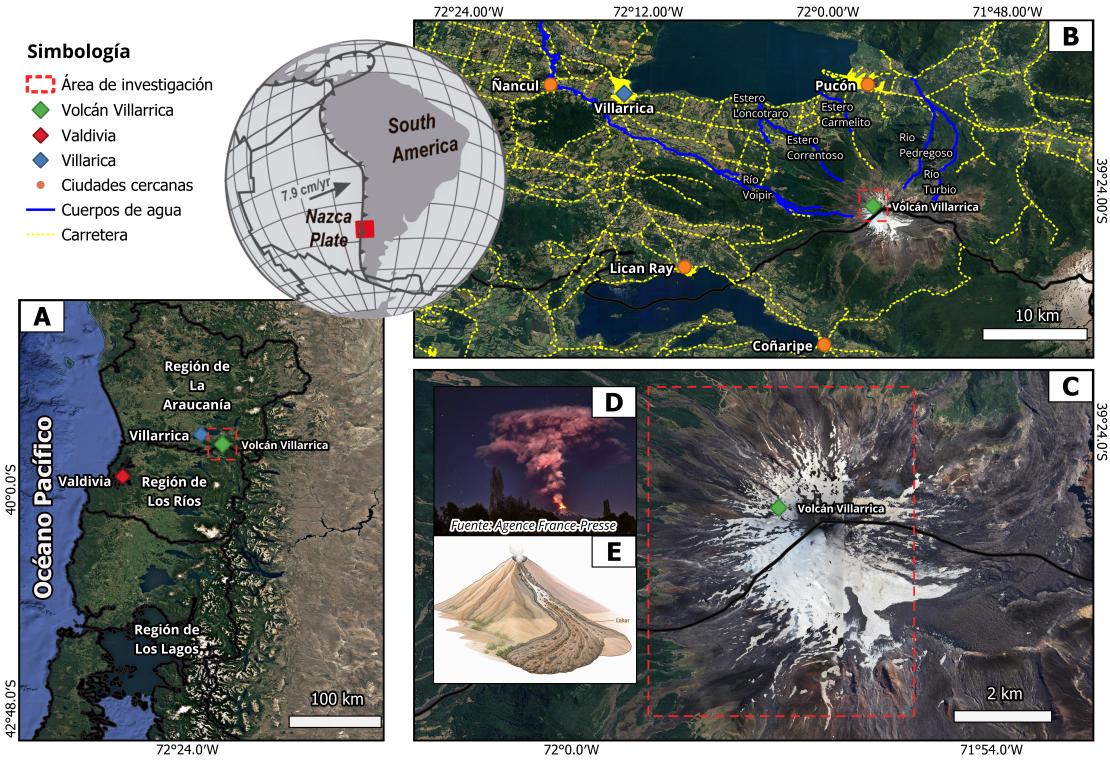

Figura 2.3: a) Contexto geográfico b) Recorrido del lahar por los esteros c) Vista azimutal del volcán Villarrica d) Columna eruptiva e) Esquema de un lahar
Fuente: Creación propia.

2.3. Volcán Villarrica

2.3.1. Contexto geográfico y geológico

El volcán Villarrica corresponde a uno de los más de 200 volcanes pleistocenos a holocenos ubicados en el arco Andino [56]. Se localiza en el sur de Chile, aproximadamente en las coordenadas $39{,}42S$ y $71{,}93O$, en el límite regional entre La Araucanía y Los Ríos. Su edificio volcánico alcanza aproximadamente $2847\ m.s.n.m.$ y se encuentra cercanos a cuidades y pueblos como Pucón, Villarrica, Licán Ray y Coñaripe. SERNAGEOMIN reporta un diámetro basal aproximado de $12{,}5\ km$, un área basal de $490\ km^2$ y un volumen estimado de $321\ km^3$.

Desde el punto de vista morfológico, Villarrica corresponde a un estratovolcán o volcán compuesto, caracterizado por un edificio cónico construido mediante la superposición de productos generados durante sucesivos episodios eruptivos. Forma parte de una cadena

volcánica de orientación aproximada NO-SE que incluye los volcanes Villarrica, Quetrupillán y Lanín. Además, el edificio presenta numerosos conos de escoria y centros eruptivos secundarios en sus flancos

2.3.2. Evento eruptivo del Volcán Villarrica del 3 de marzo del 2015

Las erupciones paroxísticas[1] junto con erupciones que producen lahares han estado ausentes en el registro del Volcán Villarrica desde los últimos 40 años. Desde inicios de febrero de 2015, el volcán presentó un aumento repentino en la actividad infrasónica, coincidente con el incremento de actividad estromboliana[2] en dos pequeños ductos asociados a un lago de lava emergente [59]. La erupción paroxística de 2015 del Volcán Villarrica (Chile) tuvo una corta duración de ~ 18 minutos y de alta energía (VEI = 2-3) [60], y produjo un lahar de $2,5\ h$ de duración, que descendió más de $20\ km$ dentro de la cuenca del Río Correntoso/Turbio y destruyó dos pequeños puentes [61]. El 3 de marzo de 2015 a las $2:37$ (UTC+3) hora local de Chile y con una duración de 55 minutos se inició un pulso estromboliano eruptivo, con proyectiles balísticos que alcanzaron más de 100 metros de altura. El movimiento sísmico fue continuado por una fuente de lava de cerca de $1{,}500$ metros sobre el cráter. Se generó además una columna eruptiva de gases y piroclástos con una altura máxima de entre 8 y 10 kilómetros que mantuvo una duración de 16 minutos. [62], [63]

El primer movimiento lahárico detectado gracias a ondas infrasónicas ocurrió a las $\sim 03:25{,}5$. Desde las $03:26{,}5$ hasta las $03:31{,}0$ la fuente se movió rápidamente con de 2 kilómetros hasta 12 kilómetros de distancia con una velocidad promedio de $38 \pm 1\ m/s$ equivalente a $137 \pm 3\ km/h$ con un $95\,\%$ de confianza. La fuente ya en moviemiento mantiene una velocidad aparentemente constante a pesar de un decrecimiento de la pendiente de $20°$ a $4°$. Parte del génesis de los lahares se atribuye a las avalanchas mixtas de nieve/hielo y escoria, que erodaron y fundieron el glaciar del cráter, creando canales longitudinales y por ende, generando flujos laháricos. Dada una DEM de alta resolución obtenido con un *drone*, se evaluó el volumen mínimo de hielo y nieve erodados en el cono principal del volcán. Considerando una proporción de los lahares de $60\,\%$ de carga sólida y $40\,\%$ de

[1] El término "paroxística"se refiere a estallidos repentinos y violentos que, en ocasiones, interrumpen la actividad explosiva moderada de los volcanes [57]

[2] La actividad estromboliana corresponde a un estilo eruptivo caracterizado por explosiones intermitentes y de corta duración, asociadas a la ruptura de grandes bolsas de gas en la parte superficial del conducto, que producen la expulsión de fragmentos de magma incandescente y otros piroclastos [58].

agua, se estimó un volumen para: Pedregoso de $4 \times 10^5\ m^3$, Correntoso de $3 \times 10^5\ m^3$ y Zanjón Seco de $1 \times 10^5\ m^3$ [64].

La erupción generó una evacuación preventiva de $3{,}000$ personas, destrucción de dos puentes y daños en el centro de ski ¨Cavernas Volcánicas¨. El suministro de agua potable se mantuvo interrumpido a más de $2{,}000$ personas incluso una semana posterior a la erupción. No se registraron daños por tefra en poblados.

Capítulo 3

Marco metodológico

3.1. Enfoque general de la investigación

3.2. Modelo físico del flujo lahárico

Para que una PINN sea capaz de aprender la morfodinámica de un lahar bajando por un estatrovolcán, es necesaria la definición explícita del operador diferencial $\mathcal{N}[\cdot]$ mencionado en la ecuación Ecuación (1.14), es decir, el sistema de ecuaciones parciales diferenciales que gobierna el fenómeno. Este modelo se construye a partir del modelo de flujo de detritos promediado en la profundidad [65], [66], mismo modelo en el cual se basa D-Claw [16]. La elección de este modelo se debe a que describe el flujo como una mezcla de partículas sólidas y fluido e incorpora de manera explícita la evolución de la presión de poros. De esta forma el modelo tiene el potencial de controlar la resistencia friccional de los sólidos en el flujo y de esta forma, su movilidad durante el evento. En este trabajo se incluyen además los factores de cálculo numérico de LaharFlow [17], que permiten modelar el flujo basado en tres principios de conservación: conservación de masa, conservación de momentum y transporte de la fracción de sólidos.

3.2.1. Supuestos del modelo

El modelo se construye a partir de los siguientes supuestos [65]:

1. **Aproximación de aguas someras:** el espesor del flujo es pequeño en comparación con su extensión horizontal, de modo que las variables pueden promediarse en la vertical y el problema tridimensional se reduce a uno bidimensional en el plano (x, y).

2. **Mezcla de dos fases:** el flujo se compone de granos sólidos de densidad ρ_s y de un fluido intersticial de densidad ρ_f. Ambas fases se desplazan con la misma velocidad promediada en la vertical.

3. **Presión de poros basal:** la presión del fluido intersticial se representa mediante su valor en la base del flujo, p_b, que puede diferir de la presión hidrostática y evoluciona en el tiempo.

4. **Dilatancia:** la mezcla puede expandirse o contraerse según el estado de empaquetamiento de los granos, lo que modifica la fracción de sólidos m y, en consecuencia, la presión de poros.

5. **Fricción basal de tipo Coulomb:** la resistencia en la base del flujo depende del esfuerzo normal efectivo, es decir, del peso del material menos la presión de poros.

3.2.2. Variables de estado

El estado del flujo en cada punto (x, y) y en cada instante t queda descrito por cinco variables:

1. Espesor del flujo $h(x, y, t)(m)$
2. Componentes de las velocidades promediadas en profundidad $u(x, y, t)$ y $v(x, y, t)\,(m/s)$
3. Concentración volumétrica de sólidos $C(x, y, t)\,(adimensional, 0 \leq C \leq 1???)$
4. Presión de poros basal $p(x, y, t)\,(Pa)$

Siguiendo la formulación de D-Claw, estas variables se agrupan en el vector de estado

$$\mathbf{q}(x, y, t) = (h,\ hu,\ hv,\ hC,\ p)^\top . \tag{3.1}$$

La densidad de la mezcla no es constante, sino que depende de la fracción de sólidos según

$$\rho = \rho_s C + (1 - C)\rho_f. \tag{3.2}$$

3.2.3. Sistema de ecuaciones gobernantes

El sistema está compuesto por cinco ecuaciones diferenciales parciales acopladas, que expresan la conservación de masa, la conservación de momentum en ambas direcciones horizontales, el transporte de la fracción de sólidos y la evolución de la presión de poros [16], [65].

Conservación de masa.

$$\frac{\partial h}{\partial t} + \nabla \cdot (h\mathbf{u}) = S_h(x, y, t), \qquad \mathbf{u} = (u, v). \tag{3.3}$$

donde $S_m(x, y, t)$ representa un término fuente de masa (aporte por lluvia intensa, aporte desde el cráter, entradas laterales por quebradas, etc.). Para un prototipo sin aporte adicional consideramos,

$$S_m(x, y, t) = 0 \tag{3.4}$$

Conservación de momentum.

$$\frac{\partial u}{\partial t} + u\frac{\partial u}{\partial x} + v\frac{\partial u}{\partial y} + g\frac{\partial H}{\partial x} + \frac{\tau_{bx}}{\rho_m h} = 0, \tag{3.5}$$

$$\frac{\partial v}{\partial t} + u\frac{\partial v}{\partial x} + v\frac{\partial v}{\partial y} + g\frac{\partial H}{\partial y} + \frac{\tau_{by}}{\rho_m h} = 0. \tag{3.6}$$

Donde la tensión basal se parametriza como:

$$\boldsymbol{\tau}_b = \tau_b \frac{\mathbf{u}}{\|\mathbf{u}\| + \varepsilon}, \qquad \tau_b = \mu_{\text{eff}}(C, p)\, \rho_m g h \cos\theta, \tag{3.7}$$

y ε evita singularidad numérica cuando $\|\mathbf{u}\| \to 0$.

La pendiente local se aproxima por:

$$\cos\theta \approx \frac{1}{\sqrt{1 + \|\nabla z_b\|^2}}. \tag{3.8}$$

Un modelo reducido pero físicamente interpretable para fricción efectiva:

$$\mu_{\text{eff}}(C, p) = \mu_0 \left(1 + \alpha_C \left(C - C_0\right)\right) \exp\left(-\alpha_p \frac{p}{\rho_m g h + p_{\text{ref}}}\right), \tag{3.9}$$

donde C_0 es una concentración de referencia y p_{ref} estabiliza la razón. Este término representa: (i) mayor fricción con mayor carga sólida, y (ii) menor fricción efectiva cuando el exceso de presión de poros es alto (disminuye el esfuerzo efectivo).

3.2.4. Transporte de concentración sólida con difusión y relajación

Una ecuación advección–difusión con término de relajación hacia un equilibrio (opcional):

$$\frac{\partial C}{\partial t} + \mathbf{u} \cdot \nabla C = \nabla \cdot (\kappa_C \nabla C) + \frac{C_{\mathrm{eq}}(x, y) - C}{\tau_C}. \tag{3.10}$$

En prototipo sintético se puede fijar $\tau_C \to \infty$ (sin relajación) o definir C_{eq} como mayor en cauces y menor en planicies.

Evolución de presión de poros (variable interna) Se usa una ecuación de advección con relajación:

$$\frac{\partial p}{\partial t} + \mathbf{u} \cdot \nabla p = \frac{p_{\mathrm{eq}}(h, C, \|\mathbf{u}\|) - p}{\tau_p}. \tag{3.11}$$

Un ejemplo simple para equilibrio de presión:

$$p_{\mathrm{eq}} = \chi_p \, \rho_m g h \, \phi(C) \, \frac{\|\mathbf{u}\|}{\|\mathbf{u}\| + u_*}, \qquad \phi(C) = \frac{C}{C + C_*}, \tag{3.12}$$

que aumenta con espesor y con concentración, y satura con velocidad. Esto captura cualitativamente el aumento de presión por mezcla densa y cizalle.

Morfodinámica del lecho: ecuación de Exner

$$\frac{\partial z_b}{\partial t} + \frac{1}{1 - \lambda_p} \nabla \cdot \mathbf{q}_s = E - D, \tag{3.13}$$

donde $\mathbf{q}_s$ es el flujo sólido superficial (m^2/s) y E, D (m/s) son erosión y deposición. Para un modelo reducido, se puede usar:

$$\mathbf{q}_s = \gamma_s \, h \, C \, \mathbf{u}. \tag{3.14}$$

y un cierre simple para erosión/deposición (prototipo):

$$E - D = \beta_e \, \|\mathbf{u}\| - \beta_d \, C, \tag{3.15}$$

con β_e, β_d ajustables. En escenarios iniciales, muchas veces se fija $E - D = 0$ para congelar el lecho y validar primero la dinámica; luego se activa Exner.

3.2.5. Relaciones constitutivas

El sistema anterior se cierra mediante un conjunto de relaciones constitutivas que vinculan la presión de poros, la dilatancia y la resistencia basal [16], [65].

Tasa de dilatación. La tasa de dilatación integrada en la profundidad, D, es proporcional al exceso de presión de poros respecto de la presión hidrostática:

$$D = -\frac{2k}{h\mu} \left(p_b - \rho_f g_z h \right), \tag{3.16}$$

donde μ es la viscosidad efectiva del fluido intersticial y k la permeabilidad hidráulica de la mezcla, que depende de la fracción de sólidos:

$$k = k_r \exp\left(\frac{m - m_r}{0{,}04} \right), \tag{3.17}$$

con k_r y m_r valores de referencia.

Esfuerzo normal efectivo. Corresponde a la fracción del peso del flujo que es soportada por el contacto entre granos, y no por el fluido:

$$\sigma_e = \rho g_z h - p_b. \tag{3.18}$$

Esta relación explica la alta movilidad de los lahares: cuando la presión de poros se aproxima al peso total del material, σ_e tiende a cero y la fricción entre granos prácticamente desaparece.

Resistencia basal. La resistencia en la base se compone de un término asociado a los sólidos, de tipo Coulomb, y otro asociado al fluido, de tipo viscoso:

$$\tau_s = \sigma_e \tan(\phi + \psi) \frac{(u,v)^\top}{\|(u,v)^\top\|}, \qquad \tau_f = \frac{2\mu(1-m)}{h} (u,v)^\top, \tag{3.19}$$

donde ϕ es el ángulo de fricción granular y ψ el ángulo de dilatancia.

Ángulo de dilatancia. El ángulo ψ mide qué tan lejos se encuentra la mezcla de su estado crítico de empaquetamiento:

$$c_1 \tan\psi = m - \frac{m_{\text{crit}}}{1+\sqrt{N}}, \qquad N = \frac{\mu\dot{\gamma}}{\rho_s \dot{\gamma}^2 \delta^2 + \sigma_e}, \tag{3.20}$$

donde m_{crit} es la fracción de sólidos en el estado crítico, $\dot{\gamma}$ la tasa de corte, δ una escala de longitud característica de las colisiones entre granos y c_1 una constante adimensional, usualmente igual a 1.

Compresibilidad. Finalmente, la compresibilidad elástica de la mezcla se define como

$$\alpha = \frac{a}{m\left(\rho g_z h - p_b + \sigma_0\right)}, \tag{3.21}$$

con a y σ_0 constantes del modelo.

3.2.6. Parámetros del modelo

La Tabla 3.1 resume los parámetros físicos que intervienen en el sistema.

3.2.7. Formulación compacta y relación con la PINN

El sistema de Ecuaciones (3.3)–(**??**) puede escribirse en la forma compacta

$$\frac{\partial \mathbf{q}}{\partial t} + \frac{\partial \mathbf{F}(\mathbf{q})}{\partial x} + \frac{\partial \mathbf{G}(\mathbf{q})}{\partial y} + \mathbf{B}(\mathbf{q})\,\nabla \mathbf{q} = \mathbf{S}(\mathbf{q}), \tag{3.22}$$

Cuadro 3.1: Parámetros del modelo físico de flujo lahárico.

Símbolo	Descripción	Unidad	Valor
ρ_s	Densidad de los sólidos	$\mathrm{kg\,m^{-3}}$	Por definir
ρ_f	Densidad del fluido intersticial	$\mathrm{kg\,m^{-3}}$	Por definir
μ	Viscosidad efectiva del fluido	Pa s	Por definir
ϕ	Ángulo de fricción granular	$^\circ$	Por definir
k_r	Permeabilidad de referencia	$\mathrm{m^2}$	Por definir
m_r	Fracción de sólidos de referencia	–	Por definir
m_{crit}	Fracción de sólidos en estado crítico	–	Por definir
δ	Escala de colisión entre granos	m	Por definir
a	Constante de compresibilidad	–	$0{,}01$–$0{,}3$ [16]
σ_0	Constante de compresibilidad	Pa	1000 [16]
κ	Coeficiente de presión lateral	–	1 [16]
c_1	Constante de dilatancia	–	1 [16]

donde $\mathbf{F}$ y $\mathbf{G}$ agrupan los flujos en las direcciones x e y, $\mathbf{B}(\mathbf{q})\,\nabla\mathbf{q}$ reúne los términos no conservativos (como los productos $u\,\partial p_b/\partial x$ de la Ecuación (**??**)) y $\mathbf{S}$ contiene los términos fuente asociados a la gravedad, la dilatancia y la resistencia basal.

Comparando con la Ecuación (1.14), se identifica la solución latente con el vector de estado, $\mathbf{u} \equiv \mathbf{q}$, y el operador diferencial como

$$\mathcal{N}[\mathbf{q}] = \frac{\partial \mathbf{F}(\mathbf{q})}{\partial x} + \frac{\partial \mathbf{G}(\mathbf{q})}{\partial y} + \mathbf{B}(\mathbf{q})\,\nabla\mathbf{q} - \mathbf{S}(\mathbf{q}). \tag{3.23}$$

De este modo, la PINN aproxima las cinco componentes de $\mathbf{q}$ a partir de las coordenadas (t, x, y), y el residuo $\mathcal{R}_{\boldsymbol{\theta}}$ definido en el Capítulo 1 queda compuesto por cinco términos, uno por cada ecuación del sistema. Cada uno de ellos contribuye a la pérdida residual $\mathcal{L}_r$ de la Ecuación (1.21).

3.2.8. Consideraciones para su resolución mediante PINNs

La estructura de este sistema introduce dificultades específicas para su resolución con una PINN, que condicionan las decisiones de diseño descritas en la Sección 3.4:

- **Singularidades en zonas secas:** varios términos dividen por el espesor h, como la tasa de dilatación (Ecuación (3.16)), la resistencia viscosa (Ecuación (3.19)) y el

coeficiente ζ (Ecuación (**??**)). En las regiones donde el lahar aún no ha llegado, $h \to 0$ y estos términos divergen, por lo que requieren un tratamiento especial.

- **Restricciones físicas sobre las salidas:** el espesor debe ser no negativo ($h \geq 0$) y la fracción de sólidos debe permanecer acotada ($0 \leq m \leq 1$). Una red sin restricciones no garantiza estas condiciones.
- **Escalas dispares:** la presión de poros (del orden de miles de pascales), el espesor (metros) y la fracción de sólidos (adimensional y menor que uno) difieren en varios órdenes de magnitud. Esto desbalancea los términos de la función de pérdida [33] y motiva la adimensionalización del sistema descrita en la Sección 3.2.10.
- **Frentes abruptos:** el frente de un lahar presenta gradientes muy pronunciados, que las redes neuronales con funciones de activación suaves tienden a representar de forma difusa.

3.2.9. Condiciones iniciales y de frontera

Para el evento del 3 de marzo de 2015, el dominio se define sobre los cauces de los ríos Correntoso, Pedregoso y Turbio. Como condición inicial se considera el cauce seco, es decir, $h(0, x, y) = 0$ fuera de la zona de origen del flujo. El lahar ingresa al dominio a través de la frontera aguas arriba, donde se impone un hidrograma de entrada que especifica el espesor, la velocidad y la fracción de sólidos en función del tiempo. En los bordes laterales del cauce se impone flujo nulo a través de la frontera, y en la frontera aguas abajo una condición de salida libre. Estas condiciones definen la función g de la Ecuación (1.15) y el operador $\mathcal{B}$ de la Ecuación (1.16).

3.2.10. Adimensionalización

3.2.11. Supuestos del modelo

3.2.12. Sistema de ecuaciones

3.2.13. Términos de fricción y reología

3.2.14. Condiciones iniciales y de frontera

3.2.15. Adimensionalización

3.3. Área de estudio y datos

3.3.1. Dominio computacional

3.3.2. Topografía

3.3.3. Datos observacionales del evento de 2015

3.3.4. Muestreo de puntos de entrenamiento

3.4. Diseño de la red neuronal informada por la física

3.4.1. Arquitectura

3.4.2. Función de pérdida

3.4.3. Entrenamiento

3.5. Estrategia de validación

3.5.1. Métricas de evaluación

Conclusiones

En las conclusiones de su tesis:

- Sintetice los hallazgos más importantes de la investigación.
- Responda a los objetivos planteados inicialmente.
- Destaque las contribuciones originales del trabajo.
- Mencione limitaciones y sugiera futuras líneas de investigación.

En esta parte terminan las páginas centrales. A continuación, se puede agregar optativamente, un glosario, anexos y apéndices; y, obligatoriamente, las referencias bibliográficas.

Referencias

[1] R. Szeliski et al., *Computer vision: algorithms and applications*. Springer London, 2011, vol. 1.

[2] J. Hirschberg y C. D. Manning, «Advances in natural language processing,» *Science*, vol. 349, n.º 6245, págs. 261-266, 2015.

[3] A. Billard et al., «A roadmap for AI in robotics,» *Nature Machine Intelligence*, vol. 7, n.º 6, págs. 818-824, 2025.

[4] Y. Li, «Research and application of deep learning in image recognition,» en *2022 IEEE 2nd international conference on power, electronics and computer applications (ICPECA)*, IEEE, 2022, págs. 994-999.

[5] D. Bahdanau, K. Cho e Y. Bengio, «Neural machine translation by jointly learning to align and translate,» *arXiv preprint arXiv:1409.0473*, 2014.

[6] S. Grigorescu, B. Trasnea, T. Cocias y G. Macesanu, «A survey of deep learning techniques for autonomous driving,» *Journal of field robotics*, vol. 37, n.º 3, págs. 362-386, 2020.

[7] K. Hornik, M. Stinchcombe y H. White, «Multilayer feedforward networks are universal approximators,» *Neural Networks*, vol. 2, n.º 5, págs. 359-366, 1989, ISSN: 0893-6080. DOI: https://doi.org/10.1016/0893-6080(89)90020-8 dirección: https://www.sciencedirect.com/science/article/pii/0893608089900208

[8] S. K. Brown et al., «Global Volcanic Hazard and Risk,» en *Global Volcanic Hazards and Risk*, S. C. Loughlin, R. S. J. Sparks, S. K. Brown, S. F. Jenkins y C. Vye-Brown, eds., Verificar rango de páginas en la edición impresa, Cambridge: Cambridge University Press, 2015, cap. 2.

[9] M. Sonnewald, R. Lguensat, D. C. Jones, P. D. Dueben, J. Brajard y V. Balaji, «Bridging Observations, Theory and Numerical Simulation of the Ocean Using Machine Learning,» *Environmental Research Letters*, vol. 16, n.º 7, pág. 073 008, 2021, Verificar el listado completo de autores. DOI: 10.1088/1748-9326/ac0eb0

[10] S. Kumari y P. Singh, «Data Efficient Deep Learning for Medical Image Analysis: A Survey,» *arXiv preprint arXiv:2310.06557*, 2024.

[11] N. M. Ball y R. J. Brunner, «Data Mining and Machine Learning in Astronomy,» *International Journal of Modern Physics D*, vol. 19, n.º 7, págs. 1049-1106, 2010. DOI: 10.1142/S0218271810017160

[12] S. L. Brunton, B. R. Noack y P. Koumoutsakos, «Machine learning for fluid mechanics,» *Annual review of fluid mechanics*, vol. 52, n.º 1, págs. 477-508, 2020.

[13] K. Duraisamy, G. Iaccarino y H. Xiao, «Turbulence modeling in the age of data,» *Annual review of fluid mechanics*, vol. 51, n.º 1, págs. 357-377, 2019.

[14] M. Raissi, P. Perdikaris y G. Karniadakis, «Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations,» *Journal of Computational Physics*, vol. 378, págs. 686-707, 2019, ISSN: 0021-9991. DOI: https://doi.org/10.1016/j.jcp.2018.10.045 dirección: https://www.sciencedirect.com/science/article/pii/S0021999118307125

[15] S. Schilling, J. Griswold y R. Iverson, «Using LAHARZ to Forecast Inundation from lahars, debris flows, and rock avalanches: Confidence limits on prediction,» en *AGU Fall Meeting Abstracts*, vol. 2008, 2008, H51F-0891.

[16] D. L. George, K. R. Barnhart y R. M. Iverson, «D-Claw-A library for the simulation of granular-fluid flows, v1. 0.0,» *US Geological Survey (USGS) Software*, pág. 34, 2025.

[17] M. Woodhouse, A. Hogg y J. Phillips, «A shallow-layer model for lahars: formulation and phenomenology,» *JGR-Earth Surface*,

[18] E. J. Liu et al., «Dynamics of Outgassing and Plume Transport Revealed by Proximal Unmanned Aerial System (UAS) Measurements at Volcán Villarrica, Chile,» *Geochemistry,*

Geophysics, Geosystems, vol. 20, n.º 2, págs. 730-750, 2019. DOI: https://doi.org/10.1029/2018GC007692 eprint: https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2018GC007692. dirección: https://agupubs.onlinelibrary.wiley.com/doi/abs/10.1029/2018GC007692

[19] J. E. Romero et al., «Pre-eruptive conditions of the 3 march 2015 lava fountain of Villarrica volcano (southern Andes),» *Bulletin of Volcanology*, vol. 85, n.º 1, pág. 2, 2022.

[20] A. Rivera et al., «Recent changes in total ice volume on Volcán Villarrica, Southern Chile,» *Natural Hazards*, vol. 75, n.º 1, págs. 33-55, 2015.

[21] L. E. Lara, J. Clavero et al., *Villarrica Volcano (39.5 S), Southern Andes, Chile*. Servicio Nacional de Geología y Minería, 2004.

[22] A. Krenker, J. Bešter y A. Kos, «Introduction to the artificial neural networks,» *Artificial Neural Networks: Methodological Advances and Biomedical Applications. InTech*, págs. 1-18, 2011.

[23] S. Walczak, «Artificial neural networks,» en *Encyclopedia of Information Science and Technology, Fourth Edition*, IGI Global Scientific Publishing, 2018, págs. 120-131.

[24] W. S. McCulloch y W. Pitts, «A logical calculus of the ideas immanent in nervous activity,» *The bulletin of mathematical biophysics*, vol. 5, n.º 4, págs. 115-133, 1943.

[25] Y.-S. Park y S. Lek, «Artificial neural networks (multilayer perceptron) for ecological modeling,» en *Ecological model types*, Elsevier, 2025, págs. 297-322.

[26] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. MIT Press, 2016. dirección: http://www.deeplearningbook.org

[27] C. Nwankpa, W. Ijomah, A. Gachagan y S. Marshall, «Activation functions: Comparison of trends in practice and research for deep learning,» *arXiv preprint arXiv:1811.03378*, 2018.

[28] S. Sharma, S. Sharma y A. Athaiya, «Activation functions in neural networks,» *Towards Data Sci*, vol. 6, n.º 12, págs. 310-316, 2017.

[29] S. R. Dubey, S. K. Singh y B. B. Chaudhuri, «Activation functions in deep learning: A comprehensive survey and benchmark,» *Neurocomputing*, vol. 503, págs. 92-108, 2022.

[30] J. Lederer, «Activation functions in artificial neural networks: A systematic overview,» *arXiv preprint arXiv:2101.09957*, 2021.

[31] K. Janocha y W. M. Czarnecki, «On Loss Functions for Deep Neural Networks in Classification,» *Schedae Informaticae*, vol. 25, págs. 49-59, 2017. DOI: 10.4467/20838476SI.16.004.6185

[32] J. Terven, D.-M. Cordova-Esparza, J.-A. Romero-González, A. Ramírez-Pedraza y E. A. Chavez-Urbiola, «A comprehensive survey of loss functions and metrics in deep learning,» *Artificial Intelligence Review*, vol. 58, n.º 7, pág. 195, 2025.

[33] S. Wang, Y. Teng y P. Perdikaris, «Understanding and Mitigating Gradient Flow Pathologies in Physics-Informed Neural Networks,» *SIAM Journal on Scientific Computing*, vol. 43, n.º 5, A3055-A3081, 2021. DOI: 10.1137/20M1318043

[34] S. Ruder, «An overview of gradient descent optimization algorithms,» *arXiv preprint arXiv:1609.04747*, 2016.

[35] D. E. Rumelhart, G. E. Hinton y R. J. Williams, «Learning representations by back-propagating errors,» *nature*, vol. 323, n.º 6088, págs. 533-536, 1986.

[36] G. B. Fotopoulos, P. Popovich y N. H. Papadopoulos, *Review Non-convex Optimization Method for Machine Learning*, 2024. arXiv: 2410.02017 [cs.LG]. dirección: https://arxiv.org/abs/2410.02017

[37] M. Andrychowicz et al., «Learning to learn by gradient descent by gradient descent,» *Advances in neural information processing systems*, vol. 29, 2016.

[38] J. Zhang, «Gradient descent based optimization algorithms for deep learning models training,» *arXiv preprint arXiv:1903.03614*, 2019.

[39] W. C. Nockolds, C. G. Krishnanunni, T. Bui-Thanh y X. Tang, *LiLaN: A Linear Latent Network as the Solution Operator for Real-Time Solutions to Stiff Nonlinear Ordinary Differential Equations*, 2025. arXiv: 2501.08423 [stat.ML]. dirección: https://arxiv.org/abs/2501.08423

[40] S. Wang, S. Sankaran, H. Wang y P. Perdikaris, «An expert's guide to training physics-informed neural networks,» *arXiv preprint arXiv:2308.08468*, 2023.

[41] A. Griewank y A. Walther, *Evaluating derivatives: principles and techniques of algorithmic differentiation*. SIAM, 2008.

[42] R. Ortiz y V. Araña, «Daños que pueden producir las erupciones,» *Riesgo Volcánico: Cabildo de Lanzarote, Serie Casa de los Volcanes*, vol. 5, págs. 37-67, 1995.

[43] R. J. Blong, *Volcanic Hazards: A Sourcebook on the Effects of Eruptions*. Sydney: Academic Press, 1984.

[44] H. Sigurdsson, B. Houghton, S. McNutt, H. Rymer y J. Stix, eds., *The Encyclopedia of Volcanoes*, 2nd. Academic Press, 2015.

[45] C. Bonadonna, A. Costa, A. Folch y T. Koyaguchi, «Chapter 33 - Tephra Dispersal and Sedimentation,» en *The Encyclopedia of Volcanoes (Second Edition)*, H. Sigurdsson, ed., Second Edition, Amsterdam: Academic Press, 2015, págs. 587-597, ISBN: 978-0-12-385938-9. DOI: https://doi.org/10.1016/B978-0-12-385938-9.00033-X dirección: https://www.sciencedirect.com/science/article/pii/B978012385938900033X

[46] J. W. Vallance y R. M. Iverson, «Lahars and Their Deposits,» en *The Encyclopedia of Volcanoes*, H. Sigurdsson, B. Houghton, S. McNutt, H. Rymer y J. Stix, eds., 2nd, Academic Press, 2015, págs. 649-664.

[47] M. T. Gudmundsson, «Hazards from Lahars and Jökulhlaups,» en *The Encyclopedia of Volcanoes*, H. Sigurdsson, B. Houghton, S. McNutt, H. Rymer y J. Stix, eds., 2nd, Academic Press, 2015, págs. 971-984.

[48] P. A. Mothes y J. W. Vallance, «Lahars at Cotopaxi and Tungurahua Volcanoes, Ecuador: highlights from stratigraphy and observational records and related downstream hazards,» en *Volcanic hazards, risks and disasters*, Elsevier, 2015, págs. 141-168.

[49] C. G. Newhall y S. Self, «The Volcanic Explosivity Index (VEI): An Estimate of Explosive Magnitude for Historical Volcanism,» *Journal of Geophysical Research*, vol. 87, n.º C2, págs. 1231-1238, 1982. DOI: 10.1029/JC087iC02p01231

[50] S. K. Brown, S. F. Jenkins, R. S. J. Sparks, H. Odbert y M. R. Auker, «Volcanic Fatalities Database: Analysis of Volcanic Threat with Distance and Victim Classification,» *Journal of Applied Volcanology*, vol. 6, pág. 15, 2017. DOI: 10.1186/s13617-017-0067-4

[51] V. Neall, «Lahars as major geological hazards,» *Bulletin of the International Association of Engineering Geology-Bulletin de l'Association Internationale de Géologie de l'Ingénieur*, vol. 13, n.º 1, págs. 233-240, 1976.

[52] D. R. Lowe, S. N. Williams, H. Leigh, C. B. Connort, J. B. Gemmell y R. E. Stoiber, «Lahars initiated by the 13 November 1985 eruption of Nevado del Ruiz, Colombia,» *Nature*, vol. 324, n.º 6092, págs. 51-53, 1986.

[53] J. W. Vallance, «Lahars,» *Encyclopedia of volcanoes*, págs. 601-616, 2000.

[54] C. R. Stern et al., «Chilean volcanoes,» *The geology of Chile*, págs. 147-178, 2007.

[55] C. Geoffroy e I. Ciocca, «Los peligros volcánicos en la planificación urbana en Chile,» *Revista de Estudios Latinoamericanos sobre Reducción del Riesgo de Desastres REDER*, vol. 7, n.º 2, págs. 36-56, 2023.

[56] C. Stern, «Active Andean volcanism: its geologic and tectonic setting,» *Revista geológica de Chile*, vol. 31, dic. de 2004. DOI: 10.4067/S0716-02082004000200001

[57] L. Caricchi, C. P. Montagna, A. Aiuppa, J. Lages, G. Tamburello y P. Papale, «CO2 flushing triggers paroxysmal eruptions at open conduit basaltic volcanoes,» *Journal of Geophysical Research: Solid Earth*, vol. 129, n.º 4, e2023JB028486, 2024.

[58] D. Gaudin et al., «Integrating puffing and explosions in a general scheme for Strombolian-style activity,» *Journal of Geophysical Research: Solid Earth*, vol. 122, n.º 3, págs. 1860-1875, 2017. DOI: 10.1002/2016JB013707

[59] J. Romero, W. Keller, J. Díaz Alvarado, M. Polacci y M. Inostroza, *The 3 March 2015 eruption of Villarrica volcano, Southern Andes of Chile: Overview of deposits and impacts*, mayo de 2016. DOI: 10.13140/RG.2.1.3575.1286

[60] M. Inostroza, F. Aguilera, C. González, S. Layana y J. Chocobar, «Variaciones en la anomalía termal del volcán Villarrica asociadas al pulso eruptivo de Marzo 2015: Interpretaciones mediante imágenes Landsat ETM+ y OLI,» oct. de 2015.

[61] J. B. Johnson y J. L. Palma, «Lahar infrasound associated with Volcán Villarrica's 3 March 2015 eruption,» *Geophysical Research Letters*, vol. 42, n.º 15, págs. 6324-6325, 2015.

[62] Sernageomin, «Informe de Resumen Crisis Volcán Villarrica, Febrero-Marzo 2015,» *Red Nacional de Vigilancia Volcánica, OVDAS, Servicio Nacional de Geología y Minería*, 2015.

[63] J. Naranjo, «Nuevo estilo eruptivo del volcán Villarrica: 3 de marzo 2015,» oct. de 2019.

[64] F. Vera, J. Palma, J. Johnson y N. Flores, *Lahares generados por avalanchas mixtas durante la erupción del 03 de Marzo de 2015 en el Volcán Villarrica*, mar. de 2017. DOI: 10.13140/RG.2.2.18802.40643

[65] R. M. Iverson y D. L. George, «A Depth-Averaged Debris-Flow Model that Includes the Effects of Evolving Dilatancy. I. Physical Basis,» *Proceedings of the Royal Society A: Mathematical, Physical and Engineering Sciences*, vol. 470, n.º 2170, pág. 20 130 819, 2014. DOI: 10.1098/rspa.2013.0819

[66] D. L. George y R. M. Iverson, «A Depth-Averaged Debris-Flow Model that Includes the Effects of Evolving Dilatancy. II. Numerical Predictions and Experimental Tests,» *Proceedings of the Royal Society A: Mathematical, Physical and Engineering Sciences*, vol. 470, n.º 2170, pág. 20 130 820, 2014. DOI: 10.1098/rspa.2013.0820