

GAX-Kepler: Clasificador de morfología galáctica mediante el uso de redes neuronales convolucionales

Brian Gonzalez, Dylan Jara

Universidad de Santiago de Chile

15 de enero de 2026



- 1 Introducción
- 2 Estado del Arte
- 3 Fundamentos Teóricos: SVR
- 4 Implementación
- 5 Entrenamiento del modelo de estudio
- 6 validación
- 7 Conclusiones

1 Introducción

Estado del arte

2 Estado del Arte

3 Fundamentos Teóricos: SVR

4 Implementación

5 Entrenamiento del modelo de estudio

6 validación

7 Conclusiones

1 Introducción

Estado del arte

2 Estado del Arte

3 Fundamentos Teóricos: SVR

4 Implementación

5 Entrenamiento del modelo de estudio

6 validación

7 Conclusiones

Estado del arte

- Las Máquinas de Soporte Vectorial fueron introducidas por Cortes y Vapnik (Cortes y Vapnik, 1995)

Estado del arte

- Las Máquinas de Soporte Vectorial fueron introducidas por Cortes y Vapnik (Cortes y Vapnik, 1995)
- Se volvieron populares en los tardíos 90, particularmente en la comunidad de machine learning (Vapnik, 2013).

Estado del arte

- Las Máquinas de Soporte Vectorial fueron introducidas por Cortes y Vapnik (Cortes y Vapnik, 1995)
- Se volvieron populares en los tardios 90, particularmente en la comunidad de machine learning (Vapnik, 2013).
- Usaremos un ensamble CNN-SVR para clasificar la morfología de las galaxias.

Modelo inicial: CNN clásica

- Se utilizó una red neuronal convolucional para clasificar imágenes de galaxias.

Modelo inicial: CNN clásica

- Se utilizó una red neuronal convolucional para clasificar imágenes de galaxias.
- El modelo aprende filtros convolucionales fijos a partir de los datos.

Modelo inicial: CNN clásica

- Se utilizó una red neuronal convolucional para clasificar imágenes de galaxias.
- El modelo aprende filtros convolucionales fijos a partir de los datos.
- Cada imagen produce una única predicción determinista.

Modelo inicial: CNN clásica

- Se utilizó una red neuronal convolucional para clasificar imágenes de galaxias.
- El modelo aprende filtros convolucionales fijos a partir de los datos.
- Cada imagen produce una única predicción determinista.
- **Limitación:**
El modelo no entrega información sobre la incertidumbre de sus predicciones.

Limitaciones del enfoque clásico

- Las imágenes astronómicas presentan ruido y estructuras difusas.

Limitaciones del enfoque clásico

- Las imágenes astronómicas presentan ruido y estructuras difusas.
- Existen casos ambiguos incluso para observadores humanos.

Limitaciones del enfoque clásico

- Las imágenes astronómicas presentan ruido y estructuras difusas.
- Existen casos ambiguos incluso para observadores humanos.
- Una predicción puntual puede ser engañosa en estos casos.

Limitaciones del enfoque clásico

- Las imágenes astronómicas presentan ruido y estructuras difusas.
- Existen casos ambiguos incluso para observadores humanos.
- Una predicción puntual puede ser engañosa en estos casos.
- **Pregunta clave:** ¿Cómo saber cuándo el modelo está realmente seguro de su predicción?

¿Qué es un modelo bayesiano?

- En un modelo bayesiano, los parámetros no son valores fijos.
- Cada peso se modela como una distribución de probabilidad.
- El modelo aprende tanto el valor esperado como la incertidumbre de los pesos.

Idea central:

El modelo no aprende una única solución, sino un conjunto de soluciones plausibles.

- 1 Introducción
- 2 Estado del Arte
- 3 Fundamentos Teóricos: SVR
- 4 Implementación
- 5 Entrenamiento del modelo de estudio
- 6 validación
- 7 Conclusiones

Estado del Arte: Evolución de la Clasificación

La clasificación morfológica ha evolucionado desde la inspección visual hasta el Deep Learning.

- **Dieleman et al. (2015):** El cambio de paradigma. Ganadores del desafío Kaggle Galaxy Zoo, demostraron que las CNNs pueden predecir probabilidades de morfología mejor que los humanos, utilizando rotaciones para invarianza (Dieleman, Willett, y Dambre, 2015).
- **Arquitecturas Híbridas (Actualidad):** Modelos recientes combinan la extracción de características profundas con clasificadores robustos como SVM/SVR o Random Forest para mejorar la generalización en datasets ruidosos (Huertas-Company y cols., 2015).

- 1 Introducción
- 2 Estado del Arte
- 3 Fundamentos Teóricos: SVR
- 4 Implementación
- 5 Entrenamiento del modelo de estudio
- 6 validación
- 7 Conclusiones

Support Vector Regression (SVR)

A diferencia de la clasificación tradicional, la SVR busca predecir valores continuos (probabilidades).

- **Objetivo:** Encontrar una función $f(x)$ que tenga, a lo sumo, una desviación ϵ de los objetivos reales y_i .
- **Margen de Tolerancia:** Ignora errores menores a ϵ (zona insensible), lo que la hace muy robusta ante el ruido (Drucker, Burges, Kaufman, Smola, y Vapnik, 1996).
- **Kernel Trick:** Permite mapear datos a dimensiones superiores para resolver problemas no lineales (Vapnik, 1995).

- 1 Introducción
- 2 Estado del Arte
- 3 Fundamentos Teóricos: SVR
- 4 Implementación**
Arquitectura de la red
- 5 Entrenamiento del modelo de estudio
- 6 validación
- 7 Conclusiones

- 1 Introducción
- 2 Estado del Arte
- 3 Fundamentos Teóricos: SVR
- 4 Implementación**
Arquitectura de la red
- 5 Entrenamiento del modelo de estudio
- 6 validación
- 7 Conclusiones

Arquitectura del Modelo CNN

Capa (tipo)	Forma de salida	Parámetros
Input (Sequential)	(64, 64, 3)	0
Conv2D (64 filtros)	(62, 62, 64)	1,792
Batch Normalization	(62, 62, 64)	256
MaxPooling2D	(31, 31, 64)	0
Conv2D (128 filtros)	(29, 29, 128)	73,856
Batch Normalization	(29, 29, 128)	512
MaxPooling2D	(14, 14, 128)	0
Conv2D (256 filtros)	(12, 12, 256)	295,168
Batch Normalization	(12, 12, 256)	1,024
MaxPooling2D	(6, 6, 256)	0

Arquitectura del Modelo CNN II

Capa (tipo)	Forma de salida	Parámetros
GlobalAveragePooling2D	(None, 256)	0
Dense	(None, 256)	65,792
Dropout	(None, 256)	0
Dense (Output)	(None, 37)	9,509
Total params		447,909
Trainable params		447,013
Non-trainable params		896

Arquitectura de la CNN Bayesiana

Layer (Type)	Output Shape	Param #
Input	(None, 64, 64, 3)	0
Convolution2DFlipout	(None, 64, 64, 64)	~3,584
BatchNormalization	(None, 64, 64, 64)	256
MaxPooling2D	(None, 32, 32, 64)	0
Convolution2DFlipout	(None, 32, 32, 128)	~147,712
BatchNormalization	(None, 32, 32, 128)	512
MaxPooling2D	(None, 16, 16, 128)	0
Convolution2DFlipout	(None, 16, 16, 256)	~590,336
BatchNormalization	(None, 16, 16, 256)	1,024
MaxPooling2D	(None, 8, 8, 256)	0
GlobalAveragePooling2D	(None, 256)	0
DenseFlipout	(None, 256)	~131,584
DenseFlipout (Output)	(None, 37)	~18,962
Total parameters		~893k

Arquitectura del Modelo CNN-SVR

Layer (Type)	Output Shape	Param #
Input (Functional)	(64, 64, 3)	0
Sequential(Sequential)	(64, 64, 3)	0
Conv2D (64 filtros)	(64, 64, 64)	1,792
Batch Normalization	(64, 64, 64)	256
MaxPooling2D	(32, 32, 64)	0
Conv2D (128 filtros)	(32, 32, 128)	73,856
Batch Normalization	(32, 32, 128)	512
MaxPooling2D	(16, 16, 128)	0
Conv2D (256 filtros)	(16, 16, 256)	295,168
Batch Normalization	(16, 16, 256)	1,024
MaxPooling2D	(8, 8, 256)	0
features = GlobalAveragePooling2D	(None, 256)	0
Dense (Output)	(None, 37)	9,509
extractor = Model(in,out(f))		
Total parameters		~382k

- 1 Introducción
- 2 Estado del Arte
- 3 Fundamentos Teóricos: SVR
- 4 Implementación
- 5 Entrenamiento del modelo de estudio
- 6 validación
- 7 Conclusiones

- 1 Introducción
- 2 Estado del Arte
- 3 Fundamentos Teóricos: SVR
- 4 Implementación
- 5 Entrenamiento del modelo de estudio
- 6 validación**
- 7 Conclusiones

- 1 Introducción
- 2 Estado del Arte
- 3 Fundamentos Teóricos: SVR
- 4 Implementación
- 5 Entrenamiento del modelo de estudio
- 6 validación
- 7 Conclusiones

Conclusiones

- 1 Las CNN son una herramienta poderosa para la clasificación de imágenes
- 2 Con ayuda de un buen entendimiento en la teoría del problema, se pueden lograr muy buenos resultados.
- 3 La clasificación automática de galaxias puede acelerar significativamente el análisis de grandes conjuntos de datos astronómicos.

Referencias I

- Cortes, C., y Vapnik, V. (1995). Support-vector networks. *Machine learning*, 20(3), 273–297.
- Dieleman, S., Willett, K. W., y Dambre, J. (2015). Rotation-invariant convolutional neural networks for galaxy morphology prediction. *Monthly Notices of the Royal Astronomical Society*.
- Drucker, H., Burges, C. J., Kaufman, L., Smola, A., y Vapnik, V. (1996). Support vector regression machines. En *Advances in neural information processing systems*.
- Huertas-Company, M., y cols. (2015). A catalog of visual morphology for low-redshift galaxies from the sloan digital sky survey. *The Astrophysical Journal Supplement Series*.
- Vapnik, V. (1995). The nature of statistical learning theory. Springer.

Referencias II

Vapnik, V. (2013). The nature of statistical learning theory.
Springer science & business media.