

Modelamiento de Lahares Mediante Redes Neuronales Informadas por la Física (PINNs): Aplicacion al Evento Eruptivo de 2015 del Volcán Villarica, Chile

Dylan Jara

Universidad de Santiago de Chile

8 de mayo de 2026



- 1 Introducción
- 2 Objetivos
- 3 Estado del Arte
- 4 Modelos, ANN y PINNs
- 5 Variables y parámetros
- 6 Sistema acoplado de PDEs
- 7 Conclusiones

1 Introducción

Lahares

2 Objetivos

3 Estado del Arte

4 Modelos, ANN y PINNs

5 Variables y parámetros

6 Sistema acoplado de PDEs

7 Conclusiones

1 Introducción

Lahares

2 Objetivos

3 Estado del Arte

4 Modelos, ANN y PINNs

5 Variables y parámetros

6 Sistema acoplado de PDEs

7 Conclusiones

Qué son los lahares?

- Volcanic debris flows that originate at potentially active volcanoes are called lahars (Vallance, 2024).

Qué son los lahares?

- Volcanic debris flows that originate at potentially active volcanoes are called lahars (Vallance, 2024).
- Lahars are mixtures of water, volcanic ash, tephra, rock fragments, and chunks of ice that can flow like wet concrete.

Qué son los lahares?

- Volcanic debris flows that originate at potentially active volcanoes are called lahars (Vallance, 2024).
- Lahars are mixtures of water, volcanic ash, tephra, rock fragments, and chunks of ice that can flow like wet concrete.
- The term comes from the Indonesian word for these destructive mudflows that cause both property damage and loss of life.



Figura 1: Lahar (dark deposit on snow) on Mount Saint Helens after the March 19, 1982, eruption.

- 1 Introducción
- 2 Objetivos**
- 3 Estado del Arte
- 4 Modelos, ANN y PINNs
- 5 Variables y parámetros
- 6 Sistema acoplado de PDEs
- 7 Conclusiones

Objetivo General

Desarrollar un modelo de lahares basado en redes neuronales informadas por la física (PINNs), aplicado al evento eruptivo de 2015 del volcán Villarica, Chile, incorporando ecuaciones acopladas de flujo somero, concentración sólida y presión de poros.

Objetivos Específicos

- 1 Formar un sistema de ecuaciones compuesto con, al menos, seis ecuaciones diferenciales parciales que modelen la morfodinámica de un lahar en el evento eruptivo del año 2015 del volcán Villarica, Chile.
- 2 Construir una red neuronal informada por la física usando el sistema de PDEs y otros parámetros geológicos que prediga el comportamiento real de un flujo de sedimento.

Objetivos Específicos

- 1 Diagnosticar patologías de desvanecimiento y decaimiento de los gradientes e incorporar técnicas de estabilización y optimización avanzadas para mejorar la convergencia del modelo.
- 2 Predecir la morfodinámica de manera realista y acorde a la física para exportar un mapa de peligro volcánico que entregue datos de evacuación según el riesgo calculado por la red neuronal.

- 1 Introducción
- 2 Objetivos
- 3 Estado del Arte
- 4 Modelos, ANN y PINNs
- 5 Variables y parámetros
- 6 Sistema acoplado de PDEs
- 7 Conclusiones

Metodos numericos actuales para prediccion

- LAHARZ es un modelo computacional que utiliza descripciones estadísticas de áreas inundadas por eventos pasados de flujo masivo para pronosticar áreas que probablemente serán inundadas por eventos hipotéticos futuros. (Schilling, Griswold, y Iverson, 2008)
- D-Claw es una biblioteca de software para la simulación de flujos granulares densos sobre topografía espacialmente variable. (George, Barnhart, y Iverson, 2025)
- LaharFlow es un software de dinámica de lahares, diseñado en la Universidad de Bristol, que modela el flujo de lahar como una mezcla de agua y granos sólidos, basado en tres principios de conservación. Estos son conservación de la masa, momentum y transporte de material sólido (Woodhouse, Hogg, y Phillips, s.f.)

- 1 Introducción
- 2 Objetivos
- 3 Estado del Arte
- 4 Modelos, ANN y PINNs
- 5 Variables y parámetros
- 6 Sistema acoplado de PDEs
- 7 Conclusiones

Que son las PINNs?

- Physics-informed neural networks are neural networks that are trained to solve supervised learning tasks while respecting any given laws of physics described by general nonlinear partial differential equations. (Raissi, Perdikaris, y Karniadakis, 2019)
- Such neural networks are constrained to respect any symmetries, invariances, or conservation principles originating from the physical laws that govern the observed data, as modeled by general time-dependent and nonlinear partial differential equations.

PDEs y Residuos en la PINN

- $\mathcal{L} = \mathcal{L}_{data} + \lambda \mathcal{L}_{physics}$, donde $\mathcal{L}_{data}$ mide el error en los datos y $\mathcal{L}_{physics}$ mide el incumplimiento de las PDEs.

- 1 Introducción
- 2 Objetivos
- 3 Estado del Arte
- 4 Modelos, ANN y PINNs
- 5 Variables y parámetros
- 6 Sistema acoplado de PDEs
- 7 Conclusiones

Variables y parámetros

- $h(x, y, t)$: espesor de la mezcla (m),
- $u(x, y, t), v(x, y, t)$: velocidades promediadas en profundidad (m/s),
- $C(x, y, t)$: concentración volumétrica de sólidos (adimensional, $0 \leq C \leq 1$),
- $z_b(x, y, t)$: elevación del lecho (m).

- 1 Introducción
- 2 Objetivos
- 3 Estado del Arte
- 4 Modelos, ANN y PINNs
- 5 Variables y parámetros
- 6 Sistema acoplado de PDEs**
- 7 Conclusiones

Conservacion de Masa y Momentum

Conservacion de masa con fuente de masa:

$$\frac{\partial h}{\partial t} + \nabla \cdot (h\vec{u}) = S_h(x, y, t), \quad u = (u, v) \quad (1)$$

Conservacion de momentum 2D con friccion basal modulada:

$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} + v \frac{\partial u}{\partial y} + g \frac{\partial H}{\partial x} + \frac{\tau_{bx}}{\rho_m h} = 0 \quad (2)$$

$$\frac{\partial v}{\partial t} + u \frac{\partial v}{\partial x} + v \frac{\partial v}{\partial y} + g \frac{\partial H}{\partial y} + \frac{\tau_{by}}{\rho_m h} = 0 \quad (3)$$

Donde la tension basal es parametrizada como

$$\tau_b = \tau_b \frac{u}{\|u\| + \epsilon}, \quad \tau_b = \mu_{eff}(C, p) \rho_m g h \cos \theta \quad (4)$$

Conservacion de Momentum

La pendiente se aproxima por:

$$\cos \theta \approx \frac{1}{\sqrt{1 + \|\nabla z_b\|^2}} \quad (5)$$

Un modelo reducido pero físicamente interpretable para fricción efectiva:

$$\mu_{eff}(C, p) = \mu_0(1 + \alpha_C(C - C_0)) \exp\left(-\alpha \frac{p}{\rho_m g h + p_{ref}}\right) \quad (6)$$

donde C_0 es una concentración de referencia y p_{ref} estabiliza la razón. Este término representa: (i) mayor fricción con mayor carga sólida, y (ii) menor fricción efectiva cuando el exceso de presión de poros es alto (disminuye el esfuerzo efectivo).

Ecuación de transporte de sólidos (Advección-difusión)

Ecuación advección–difusión con término de relajación hacia un equilibrio

$$\frac{\partial C}{\partial t} + u \cdot \nabla C = \nabla \cdot (k_C \nabla C) + \frac{C_{eq}(x, y) - C}{\tau_C} \quad (7)$$

En prototipo sintético se puede fijar $\tau_C \rightarrow \infty$ (sin relajación) o definir C_{eq} como mayor en cauces y menor en planicies.

Evolucion de presion de poros




Figura 2: Diagram illustrating the effective stress principle in a saturated cohesionless soil (Green, 2019)

Evolucion de presion de poros

Se usa una ecuación de advección con relajación:

$$\frac{\partial p}{\partial t} + u \cdot \nabla p = \frac{p_{eq}(h, C, \|u\|) - p}{\tau_p} \quad (8)$$

Un ejemplo simple para equilibrio de presión:

$$p_{eq} = \chi_p \rho_m g h \phi(C) \frac{\|u\|}{\|u\| + u_*}, \quad \phi(C) = \frac{C}{C + C_*} \quad (9)$$

que aumenta con espesor y con concentración, y satura con velocidad. Esto captura cualitativamente el aumento de presión por mezcla densa y cizalle.

Ecuación de Exner




Figura 3: Ecuación de Exner: evolución del lecho.

Ecuacion de Exner

$$\frac{\partial z_b}{\partial t} + \frac{1}{1 - \lambda_p} \nabla \cdot \mathbf{q}_s = E - D, \quad (10)$$

donde q_s es el flujo sólido superficial (m^2/s) y $E, D(m/s)$ son erosión y deposición. Para un modelo reducido, se puede usar:

$$\mathbf{q}_s = \gamma_s h C \mathbf{u} \quad (11)$$

y un cierre simple para erosión/deposición (prototipo):

$$E - D = \beta_e \|\mathbf{u}\| - \beta_d C, \quad (12)$$

con β_e, β_d ajustables. En escenarios iniciales, muchas veces se fija $E - D = 0$ para congelar el lecho y validar primero la dinámica; luego se activa Exner.

- 1 Introducción
- 2 Objetivos
- 3 Estado del Arte
- 4 Modelos, ANN y PINNs
- 5 Variables y parámetros
- 6 Sistema acoplado de PDEs
- 7 Conclusiones**

Conclusiones

- 1 Un modelo de PDE acopladas da mucha mas fiabilidad a las predicciones, ya que sigue mejor la fisica
- 2 Se pueden seguir agregando parametros y ecuaciones, aumentando la precision pero a la vez incrementando el costo computacional

Referencias I

- George, D. L., Barnhart, K. R., y Iverson, R. M. (2025). D-claw-a library for the simulation of granular-fluid flows, v1. 0.0. *US Geological Survey (USGS) Software*, 34.
- Green, R. (2019). Finite Element Modeling of a Suction Caisson Subject to Monotonic Tensile Loading (Tesis Doctoral no publicada).
- Raissi, M., Perdikaris, P., y Karniadakis, G. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686-707. Descargado de <https://www.sciencedirect.com/science/article/pii/S0021999118307125> doi: <https://doi.org/10.1016/j.jcp.2018.10.045>

Referencias II

- Schilling, S., Griswold, J., y Iverson, R. (2008). Using lahars to forecast inundation from lahars, debris flows, and rock avalanches: Confidence limits on prediction. En AGU Fall Meeting Abstracts (Vol. 2008, pp. H51F-0891).
- Vallance, J. W. (2024). Lahars: Origins, behavior and hazards. En M. Jakob, S. McDougall, y P. Santi (Eds.), *Advances in Debris-flow Science and Practice* (pp. 347-382). Cham: Springer International Publishing. Descargado de https://doi.org/10.1007/978-3-031-48691-3_12 doi: 10.1007/978-3-031-48691-3_12
- Woodhouse, M., Hogg, A., y Phillips, J. (s.f.). A shallow-layer model for lahars: formulation and phenomenology. *JGR-Earth Surface*.