Modelamiento de Lahares mediante Redes Neuronales Informadas por la Física (PINNs): Aplicación al evento eruptivo de 2015 del volcán Villarica, Chile

Dylan Jara Carvajal

Profesor Guía	Profesor Co-Guía	Profesor Informante
Felipe Herrera	**Johan Triana**	**Yuvineza Gomez-Leyton**

Departamento de Matemática y Ciencia de la Computación
Universidad de Santiago de Chile

3 de noviembre de 2026



1. Introducción
2. Topografía
3. Modelo físico
4. Red neuronal como aproximador
5. Red neuronal como aproximador

1 Introducción
Lahares
Physics-Informed Neural Networks (PINNs)

2 Topografía

3 Modelo físico

4 Red neuronal como aproximador

5 Red neuronal como aproximador

1 Introducción
Lahares
Physics-Informed Neural Networks (PINNs)
2 Topografía
3 Modelo físico
4 Red neuronal como aproximador
5 Red neuronal como aproximador

Qué son los lahares?

- Flujos de sedimentos volcánicos que se originan en volcanes potencialmente activos se llaman lahares [1].



1 Introducción
Lahares
Physics-Informed Neural Networks (PINNs)
2 Topografía
3 Modelo físico
4 Red neuronal como aproximador
5 Red neuronal como aproximador

Qué son las PINNs?

- Las redes neuronales basadas en la física son redes neuronales entrenadas para resolver tareas de aprendizaje supervisado respetando cualquier ley física dada descrita por ecuaciones diferenciales parciales no lineales generales [3].
- $\mathcal{L} = \mathcal{L}_{data} + \lambda \mathcal{L}_{physics}$, donde $\mathcal{L}_{data}$ mide el error en los datos y $\mathcal{L}_{physics}$ mide el incumplimiento de las PDEs.

1 Introducción

2 Topografía

3 Modelo físico

4 Red neuronal como aproximador

5 Red neuronal como aproximador

DEM ALOS PALSAR 12.5M

Cauces del evento eruptivo del 2015

Datos de campo de la literatura

1 Introducción

2 Topografía

3 Modelo físico
- Variables y parámetros
- Sistema acoplado de PDEs

4 Red neuronal como aproximador

5 Red neuronal como aproximador

1 Introducción

2 Topografía

3 Modelo físico
- Variables y parámetros
- Sistema acoplado de PDEs

4 Red neuronal como aproximador

5 Red neuronal como aproximador

Variables y parámetros

- $h(x, y, z, t)$: espesor de la mezcla (m),
- $u(x, y, z, t), v(x, y, z, t)$: velocidades promediadas en profundidad (m/s),
- $C(x, y, z, t)$: concentración volumétrica de sólidos (adimensional, $0 \leq C \leq 1$),
- $z_b(x, y, z, t)$: elevación del lecho (m).

1 Introducción

2 Topografía

3 Modelo físico
- Variables y parámetros
- Sistema acoplado de PDEs

4 Red neuronal como aproximador

5 Red neuronal como aproximador

Conservacion de Masa y Momentum

Conservacion de masa con fuente de masa:

$$\frac{\partial h}{\partial t} + \nabla \cdot (h\vec{u}) = S_h(x, y, t), \qquad u = (u, v) \tag{1}$$

Conservacion de momentum 2D con friccion basal modulada:

$$\frac{\partial u}{\partial t} + u\frac{\partial u}{\partial x} + v\frac{\partial u}{\partial y} + g\frac{\partial H}{\partial x} + \frac{\tau_{bx}}{\rho_m h} = 0 \tag{2}$$

$$\frac{\partial v}{\partial t} + u\frac{\partial v}{\partial x} + v\frac{\partial v}{\partial y} + g\frac{\partial H}{\partial y} + \frac{\tau_{by}}{\rho_m h} = 0 \tag{3}$$

Donde la tension basal es parametrizada como

$$\tau_b = \tau_b \frac{u}{\|u\| + \epsilon}, \qquad \tau_b = \mu_{eff}(C, p)\rho_m g h \cos\theta \tag{4}$$

Conservación de Momentum

La pendiente se aproxima por:

$$\cos\theta \approx \frac{1}{\sqrt{1 + \|\nabla z_b\|^2}} \tag{5}$$

Un modelo reducido pero físicamente interpretable para fricción efectiva:

$$\mu_{eff}(C, p) = \mu_0(1 + \alpha_C(C - C_0)) \exp(-\alpha \frac{p}{\rho_m g h + p_{ref}}) \tag{6}$$

donde C0 es una concentración de referencia y pref estabiliza la razón. Este término representa: (i) mayor fricción con mayor carga sólida, y (ii) menor fricción efectiva cuando el exceso de presión de poros es alto (disminuye el esfuerzo efectivo).

Ecuación de transporte de solidos (Advección-difusión)

Ecuación advección–difusión con término de relajación hacia un equilibrio

$$\frac{\partial C}{\partial t} + u \cdot \nabla C = \nabla \cdot (k_C \nabla C) + \frac{C_{eq}(x, y) - C}{\tau_C} \tag{7}$$

En prototipo sintético se puede fijar $\tau C \to \infty$ (sin relajación) o definir C_{eq} como mayor en cauces y menor en planicies.

Evolución de presión de poros

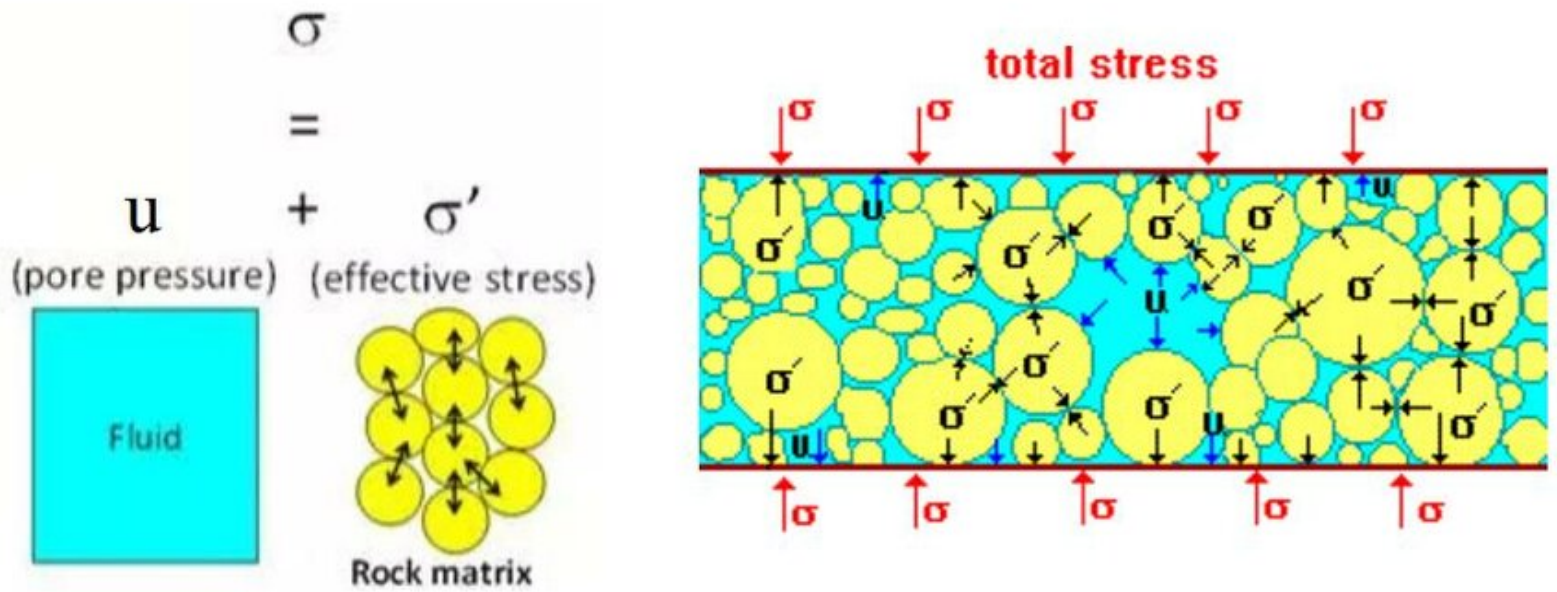


Figura 2: Diagram illustrating the effective stress principle in a saturated cohesionless soil [4]

Evolución de presión de poros

Se usa una ecuación de advección con relajación:

$$\frac{\partial p}{\partial t} + u \cdot \nabla p = \frac{p_{eq}(h, C, \|u\|) - p}{\tau_p} \tag{8}$$

Un ejemplo simple para equilibrio de presión:

$$p_{eq} = \chi_p \rho_m g h \phi(C) \frac{\|u\|}{\|u\| + u_*}, \qquad \phi(C) = \frac{C}{C + C_*} \tag{9}$$

que aumenta con espesor y con concentración, y satura con velocidad. Esto captura cualitativamente el aumento de presión por mezcla densa y cizalle.

1 Introducción

2 Topografía

3 Modelo físico

4 Red neuronal como aproximador

5 Red neuronal como aproximador

Arquitectura

Condiciones iniciales y fronteras

Variantes

1 Introducción

2 Topografía

3 Modelo físico

4 Red neuronal como aproximador

5 Red neuronal como aproximador

Referencias I

[1] J. W. Vallance, *Lahars: Origins, Behavior and Hazards*, pp. 347–382. Cham: Springer International Publishing, 2024.

[2] L. Jing, F. Kwok, A. Leung, Z. Zhang, and L. Dai, "Runout scaling and deposit morphology of rapid mudflows," *Journal of Geophysical Research: Earth Surface*, vol. 123, 07 2018.

[3] M. Raissi, P. Perdikaris, and G. Karniadakis, "Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations," *Journal of Computational Physics*, vol. 378, pp. 686–707, 2019.

[4] R. Green, *Finite Element Modeling of a Suction Caisson Subject to Monotonic Tensile Loading*. PhD thesis, 03 2019.

[5] S. Porfido, G. Alessio, G. Gaudiosi, and R. Nappi, "New perspectives in the definition/evaluation of seismic hazard through analysis of the environmental effects induced by earthquakes," 2020.

[6] R. Ortiz, *Riesgo volcánico*, vol. 5. Servicio de Publicaciones, Excmo. Cabildo de Lanzarote, 1996.

[7] S. Cai, Z. Mao, Z. Wang, M. Yin, and G. E. Karniadakis, "Physics-informed neural networks (pinns) for fluid mechanics: A review," *Acta Mechanica Sinica*, vol. 37, no. 12, pp. 1727–1738, 2021.

[8] M. Woodhouse, A. Hogg, and J. Phillips, "A shallow-layer model for lahars: formulation and phenomenology," *JGR-Earth Surface*.

[9] S. Schilling, J. Griswold, and R. Iverson, "Using laharz to forecast inundation from lahars, debris flows, and rock avalanches: Confidence limits on prediction," in *AGU Fall Meeting Abstracts*, vol. 2008, pp. H51F–0891, 2008.

Referencias II

[10] D. L. George, K. R. Barnhart, and R. M. Iverson, "D-claw-a library for the simulation of granular-fluid flows, v1. 0.0," *US Geological Survey (USGS) Software*, p. 34, 2025.

[11] A. Krishnapriyan, A. Gholami, S. Zhe, R. Kirby, and M. W. Mahoney, "Characterizing possible failure modes in physics-informed neural networks," *Advances in neural information processing systems*, vol. 34, pp. 26548–26560, 2021.

[12] M. Raissi, P. Perdikaris, N. Ahmadi, and G. E. Karniadakis, "Physics-informed neural networks and extensions," *arXiv preprint arXiv:2408.16806*, 2024.