Modelamiento de Lahares mediante Redes Neuronales Informadas por la Física (PINNs): Aplicación al evento eruptivo de 2015 del volcán Villarica, Chile

Dylan Jara Carvajal

Profesor Guía	Profesor Co-Guía	Profesor Informante
Felipe Herrera	**Johan Triana**	**Yuvineza Gomez-Leyton**

Departamento de Matemática y Ciencia de la Computación
Universidad de Santiago de Chile

4 de noviembre de 2026

1. Introducción
2. Objetivo general y motivación
3. Modelo físico
4. Topografía

1 Introducción
Lahares
Physics-Informed Neural Networks (PINNs)
2 Objetivo general y motivación
3 Modelo físico
4 Topografía

1 Introducción
Lahares
Physics-Informed Neural Networks (PINNs)
2 Objetivo general y motivación
3 Modelo físico
4 Topografía

Qué son los lahares?

- Flujos de sedimentos volcánicos que se originan en volcanes potencialmente activos se llaman lahares [1].

Figura 1: Lahar (dark deposit on snow) on Mount Saint Helens after the

1 Introducción
Lahares
Physics-Informed Neural Networks (PINNs)
2 Objetivo general y motivación
3 Modelo físico
4 Topografía

Qué son las PINNs?

- Las redes neuronales basadas en la física son redes neuronales entrenadas para resolver tareas de aprendizaje supervisado respetando cualquier ley física dada descrita por ecuaciones diferenciales parciales no lineales generales [3].
- $\mathcal{L} = \mathcal{L}_{data} + \lambda \mathcal{L}_{physics}$, donde $\mathcal{L}_{data}$ mide el error en los datos y $\mathcal{L}_{physics}$ mide el incumplimiento de las PDEs.

1 Introducción

2 Objetivo general y motivación

3 Modelo físico

4 Topografía

- Obj general
- por que usamos las pinns para esto

Cauces del evento eruptivo del 2015

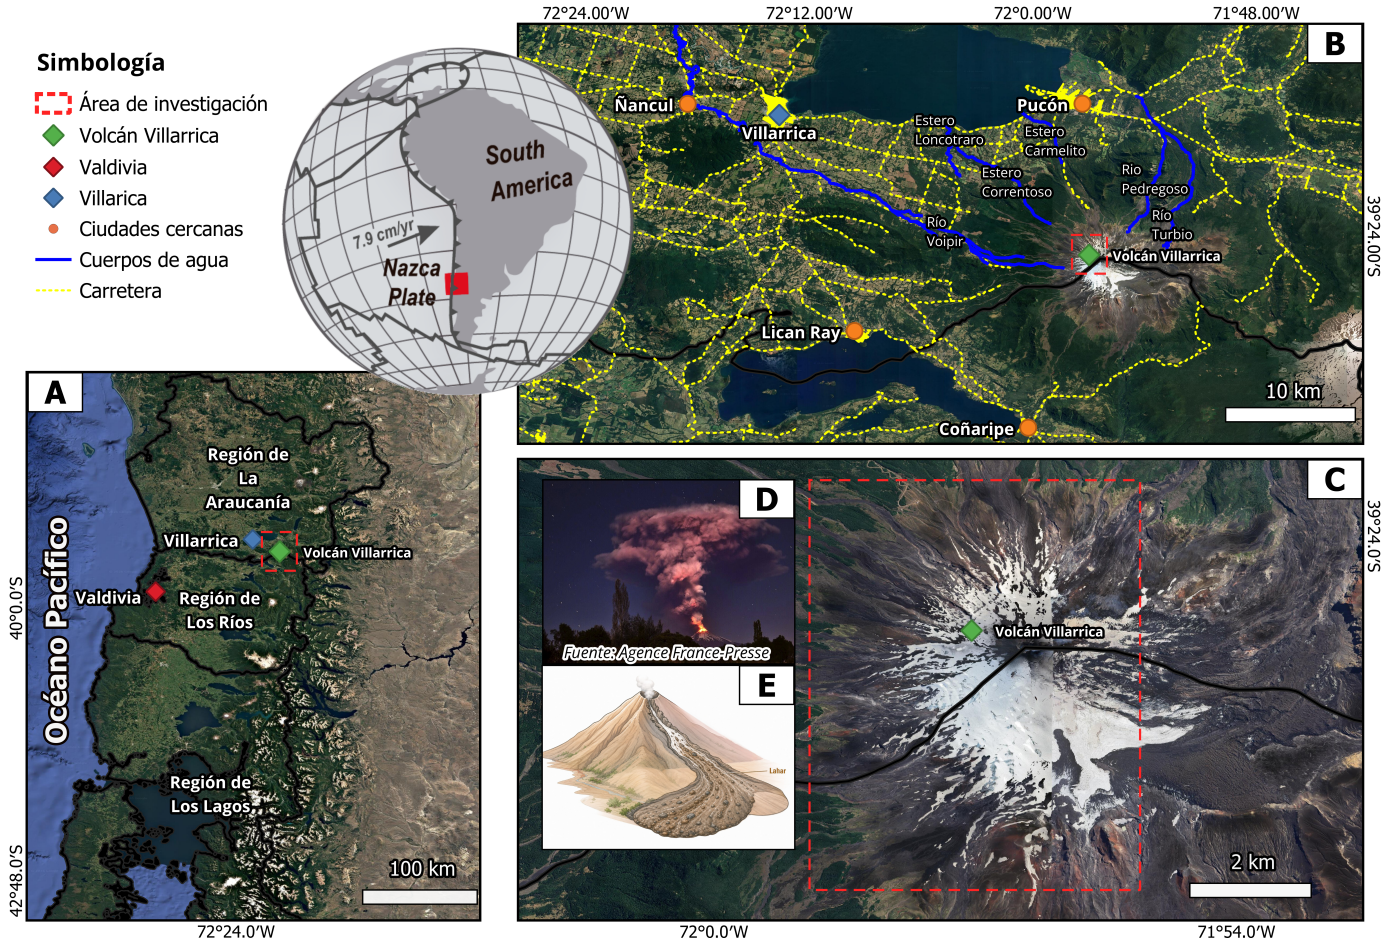

Figura 2: Cauces del evento eruptivo del 2015 en el Volcán Villarrica

Datos de campo de la literatura

1 Introducción

2 Objetivo general y motivación

3 Modelo físico
- Variables y parámetros
- Red neuronal como aproximador

4 Topografía

1 Introducción

2 Objetivo general y motivación

3 Modelo físico
- Variables y parámetros
- Red neuronal como aproximador

4 Topografía

Variables y parámetros

- $h(x, y, t)$: espesor de la mezcla (m),
- $u(x, y, t), v(x, y, t)$: velocidades promediadas en profundidad (m/s),
- $C(x, y, t)$: concentración volumétrica de sólidos (adimensional, $0 \leq C \leq 1$),
- $p(x, y, t)$: presión de poros (Pa),
- $z_b(x, y, t)$: elevación del lecho (m).

1 Introducción

2 Objetivo general y motivación

3 Modelo físico
- Variables y parámetros
- Red neuronal como aproximador

4 Topografía

Arquitectura

- La arquitectura de la red neuronal es un MLP (Multi-Layer Perceptron) con cinco capas ocultas, cada una con 192 neuronas.
- Cada capa oculta utiliza la función de activación $swish$.
- Variables de entrada: $h, C, p, z_b\,(Variable futura)$

Variantes

- Rahaman Spectral Bias
- z_b como variable de entrada
- curriculum learning

trabajos futuros

- Lambda adaptativo
- seqtoseq

1 Introducción

2 Objetivo general y motivación

3 Modelo físico

4 Topografía

DEM ALOS PALSAR 12.5M

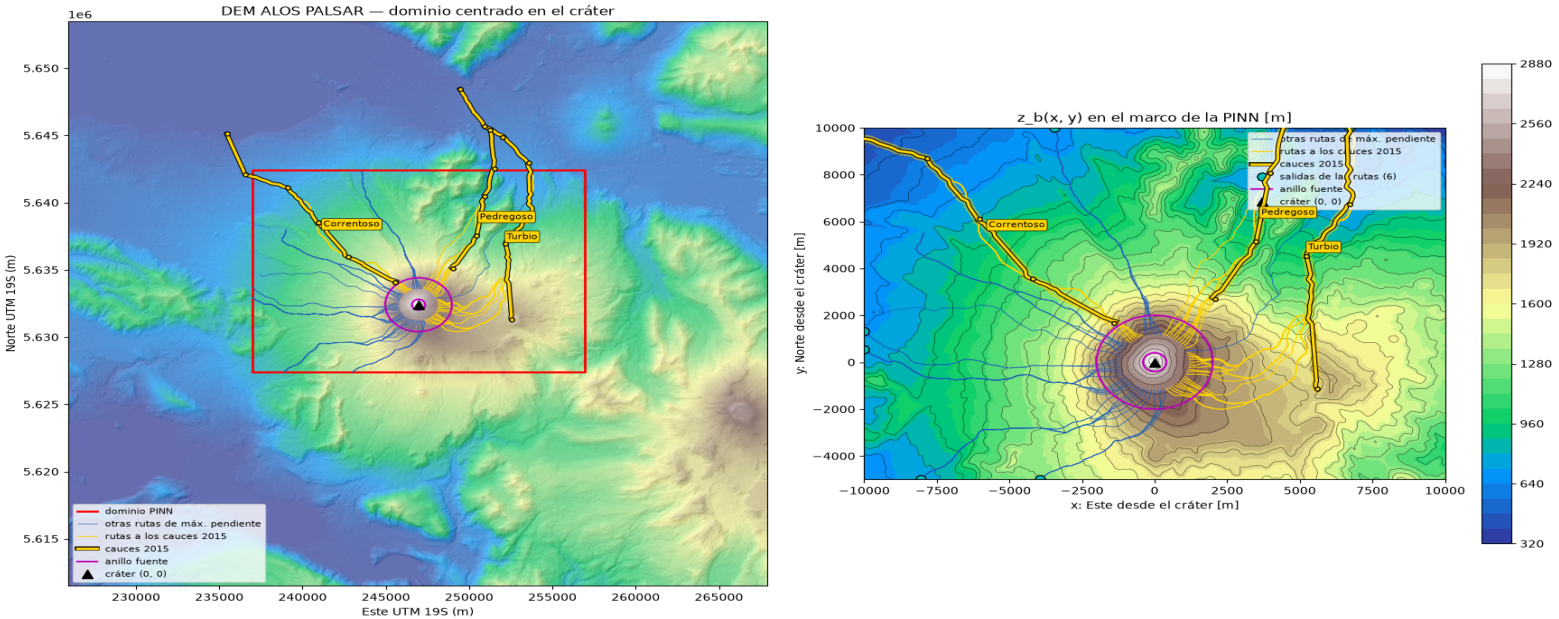

Figura 3: Digital Elevation Model (DEM) ALOS PALSAR 12.5M del Volcán Villarrica

Referencias I

[1] J. W. Vallance, *Lahars: Origins, Behavior and Hazards*, pp. 347–382. Cham: Springer International Publishing, 2024.

[2] L. Jing, F. Kwok, A. Leung, Z. Zhang, and L. Dai, "Runout scaling and deposit morphology of rapid mudflows," *Journal of Geophysical Research: Earth Surface*, vol. 123, 07 2018.

[3] M. Raissi, P. Perdikaris, and G. Karniadakis, "Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations," *Journal of Computational Physics*, vol. 378, pp. 686–707, 2019.

[4] S. Porfido, G. Alessio, G. Gaudiosi, and R. Nappi, "New perspectives in the definition/evaluation of seismic hazard through analysis of the environmental effects induced by earthquakes," 2020.

[5] R. Ortiz, *Riesgo volcánico*, vol. 5. Servicio de Publicaciones, Excmo. Cabildo de Lanzarote, 1996.

[6] S. Cai, Z. Mao, Z. Wang, M. Yin, and G. E. Karniadakis, "Physics-informed neural networks (pinns) for fluid mechanics: A review," *Acta Mechanica Sinica*, vol. 37, no. 12, pp. 1727–1738, 2021.

[7] M. Woodhouse, A. Hogg, and J. Phillips, "A shallow-layer model for lahars: formulation and phenomenology," *JGR-Earth Surface*.

[8] R. Green, *Finite Element Modeling of a Suction Caisson Subject to Monotonic Tensile Loading*. PhD thesis, 03 2019.

[9] S. Schilling, J. Griswold, and R. Iverson, "Using laharz to forecast inundation from lahars, debris flows, and rock avalanches: Confidence limits on prediction," in *AGU Fall Meeting Abstracts*, vol. 2008, pp. H51F–0891, 2008.

Referencias II

[10] D. L. George, K. R. Barnhart, and R. M. Iverson, "D-claw-a library for the simulation of granular-fluid flows, v1. 0.0," *US Geological Survey (USGS) Software*, p. 34, 2025.

[11] A. Krishnapriyan, A. Gholami, S. Zhe, R. Kirby, and M. W. Mahoney, "Characterizing possible failure modes in physics-informed neural networks," *Advances in neural information processing systems*, vol. 34, pp. 26548–26560, 2021.

[12] M. Raissi, P. Perdikaris, N. Ahmadi, and G. E. Karniadakis, "Physics-informed neural networks and extensions," *arXiv preprint arXiv:2408.16806*, 2024.