GAX-Kepler: Clasificador de morfología galáctica mediante el uso de redes neuronales convolucionales

Dylan Jara

Universidad de Santiago de Chile

23 de febrero de 2026

1. Introducción
2. Estado del Arte
3. Modelos, ANN y PINNs
4. Variables y parámetros
5. Physics-Informed Neural Networks (PINNs)
6. Implementación
7. Conclusiones

1 Introducción
Lahares

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación

7 Conclusiones

1 Introducción
Lahares

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación

7 Conclusiones

Qué son los lahares?

- Volcanic debris flows that originate at potentially active volcanoes are called lahars (Vallance, 2024)

Qué son los lahares?

- Volcanic debris flows that originate at potentially active volcanoes are called lahars (Vallance, 2024)
- Lahars are mixtures of water, volcanic ash, tephra, rock fragments, and chunks of ice that can flow like wet concrete. The term comes from the Indonesian word for these destructive mudflows that cause both property damage and loss of life.

Qué son los lahares?

- Volcanic debris flows that originate at potentially active volcanoes are called lahars (Vallance, 2024)
- Lahars are mixtures of water, volcanic ash, tephra, rock fragments, and chunks of ice that can flow like wet concrete. The term comes from the Indonesian word for these destructive mudflows that cause both property damage and loss of life.
- Importancia de su estudio, desastres, etc

Lahares fotos

- Las imágenes astronómicas presentan ruido y estructuras difusas.

Lahares fotos

- Las imágenes astronómicas presentan ruido y estructuras difusas.
- **Pregunta clave:** ¿Cómo saber cuándo el modelo está realmente seguro de su predicción?

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación

7 Conclusiones

Metodos numericos actuales para prediccion

- LAHARZ es un modelo computacional que utiliza descripciones estadísticas de áreas inundadas por eventos pasados de flujo masivo para pronosticar áreas que probablemente serán inundadas por eventos hipotéticos futuros. (Schilling, Griswold, y Iverson, 2008)
- D-Claw es una biblioteca de software para la simulación de flujos granulares densos sobre topografía espacialmente variable. (George, Barnhart, y Iverson, 2025)
- LaharFlow es un software de dinámica de lahares, diseñado en la Universidad de Bristol, que modela el flujo de lahar como una mezcla de agua y granos sólidos, basado en tres principios de conservación. Estos son conservación de la masa, momentum y transporte de material sólido (Woodhouse, Hogg, y Phillips, s.f.)

Estado del Arte: Evolución de los metodos predictivos

La clasificación morfológica ha evolucionado desde la inspección visual hasta el Deep Learning.

- **Dieleman et al. (2015):** El cambio de paradigma. Ganadores del desafío Kaggle Galaxy Zoo, demostraron que las CNNs pueden predecir probabilidades de morfología mejor que los humanos, utilizando rotaciones para invarianza (Dieleman, Willett, y Dambre, 2015).
- **Arquitecturas Híbridas (Actualidad):** Modelos recientes combinan la extracción de características profundas con clasificadores robustos como SVM/SVR o Random Forest para mejorar la generalización en datasets ruidosos (Huertas-Company y cols., 2015).

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación

7 Conclusiones

Ecuaciones Shallow-water

- Son un sistema de PDEs hiperbolicas que describen el flujo de fluidos en oceanos, rios, etc.
- Se caracterizan ya que su dimension vertical es mucho menor que la horizontal, lo que permite simplificar las ecuaciones de Navier-Stokes.
- Se utilizan para modelar fenómenos como tsunamis, mareas, debris flows, etc.
- Provienen de la derivacion de Navier-Stokes, que a su vez provienen de las leyes de conservacion de masa, momentum.

Que son las PINNs?

- pinn
- pin
- pi

Modelo de PINN basada en Shallow-water?

- Laharz
- Otro
- Otro mas

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación

7 Conclusiones

Variables y parámetros

- a
- v
- zb

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)
Sistema acoplado de PDEs

6 Implementación

7 Conclusiones

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)
Sistema acoplado de PDEs

6 Implementación

7 Conclusiones

Sistema acoplado de PDEs

- Masa
- Momentum
- Advección

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación
Arquitectura de la red

7 Conclusiones

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación
Arquitectura de la red

7 Conclusiones

Arquitectura del Modelo CNN

Capa (tipo)	**Forma de salida**	**Parámetros**
Input (Sequential)	$(64, 64, 3)$	0
Conv2D (64 filtros)	$(62, 62, 64)$	1,792
Batch Normalization	$(62, 62, 64)$	256
MaxPooling2D	$(31, 31, 64)$	0
Conv2D (128 filtros)	$(29, 29, 128)$	73,856
Batch Normalization	$(29, 29, 128)$	512
MaxPooling2D	$(14, 14, 128)$	0
Conv2D (256 filtros)	$(12, 12, 256)$	295,168
Batch Normalization	$(12, 12, 256)$	1,024
MaxPooling2D	$(6, 6, 256)$	0

Arquitectura del Modelo CNN II

Capa (tipo)	**Forma de salida**	**Parámetros**
GlobalAveragePooling2D	(None, 256)	0
Dense	(None, 256)	65,792
Dropout	(None, 256)	0
Dense (Output)	(None, 37)	9,509
Total params		**447,909**
Trainable params		447,013
Non-trainable params		896

Métricas asociadas

- Accuracy
- Loss total
- La incertidumbre predictiva se evalúa posteriormente mediante muestreo Monte Carlo

Plataforma de entrenamiento Modelo CNN-SVR

- Hardware: CPU (i7-10700f)
- Uso de GPU: Si (NVIDIA RTX 3070 8gb)
- Lenguaje: Python
- Entrenamiento realizado en entorno local

Proceso de entrenamiento Modelo CNN-SVR

- Número máximo de épocas: 30
- Tamaño de batch: 256
- Optimizador: Adam
- Tasa de aprendizaje inicial: 10^{-3}
- Estrategia de parada temprana:
  - Monitor: `val_loss`
  - Paciencia: 3 épocas

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación

7 Conclusiones

Conclusiones

1. Se anadieron el doble de imagenes para ver mejoria en la convergencia, pero no hubo gran diferencia.
2. Si bien SVM/SVR son mejores para clasificar imagenes, la diferencia entre resultados fue muy poca.

Referencias I

Dieleman, S., Willett, K. W., y Dambre, J. (2015). Rotation-invariant convolutional neural networks for galaxy morphology prediction. *Monthly Notices of the Royal Astronomical Society*.

George, D. L., Barnhart, K. R., y Iverson, R. M. (2025). D-claw-a library for the simulation of granular-fluid flows, v1. 0.0. *US Geological Survey (USGS) Software*, 34.

Huertas-Company, M., y cols. (2015). A catalog of visual morphology for low-redshift galaxies from the sloan digital sky survey. *The Astrophysical Journal Supplement Series*.

Schilling, S., Griswold, J., y Iverson, R. (2008). Using laharz to forecast inundation from lahars, debris flows, and rock avalanches: Confidence limits on prediction. En AGU Fall Meeting Abstracts (Vol. 2008, pp. H51F–0891).

Referencias II

Vallance, J. W. (2024). Lahars: Origins, behavior and hazards. En M. Jakob, S. McDougall, y P. Santi (Eds.), Advances in Debris-flow Science and Practice (pp. 347–382). Cham: Springer International Publishing. Descargado de https://doi.org/10.1007/978-3-031-48691-3_12 doi: 10.1007/978-3-031-48691-3_12

Woodhouse, M., Hogg, A., y Phillips, J. (s.f.). A shallow-layer model for lahars: formulation and phenomenology. *JGR-Earth Surface*.