GAX-Kepler: Clasificador de morfología galáctica mediante el uso de redes neuronales convolucionales

Dylan Jara

Universidad de Santiago de Chile

22 de febrero de 2026

1. Introducción
2. Estado del Arte
3. Modelos, ANN y PINNs
4. Variables y parámetros
5. Physics-Informed Neural Networks (PINNs)
6. Implementación
7. Conclusiones

1 Introducción
Lahares

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación

7 Conclusiones

1 Introducción
Lahares

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación

7 Conclusiones

Qué son los lahares?

- Las Máquinas de Soporte Vectorial fueron introducidas por Cortes y Vapnik (Cortes y Vapnik, 1995)

Qué son los lahares?

- Las Máquinas de Soporte Vectorial fueron introducidas por Cortes y Vapnik (Cortes y Vapnik, 1995)
- Se volvieron populares en los tardios 90, particularmente en la comunidad de machine learing (Vapnik, 2013).

Qué son los lahares?

- Las Máquinas de Soporte Vectorial fueron introducidas por Cortes y Vapnik (Cortes y Vapnik, 1995)
- Se volvieron populares en los tardios 90, particularmente en la comunidad de machine learing (Vapnik, 2013).
- Usaremos un ensamble CNN-SVR para clasificar la morfología de las galaxias.

Lahares fotos

- Las imágenes astronómicas presentan ruido y estructuras difusas.

Lahares fotos

- Las imágenes astronómicas presentan ruido y estructuras difusas.
- Existen casos ambiguos incluso para observadores humanos.

Lahares fotos

- Las imágenes astronómicas presentan ruido y estructuras difusas.
- Existen casos ambiguos incluso para observadores humanos.
- Una predicción puntual puede ser engañosa en estos casos.

Lahares fotos

- Las imágenes astronómicas presentan ruido y estructuras difusas.
- Existen casos ambiguos incluso para observadores humanos.
- Una predicción puntual puede ser engañosa en estos casos.
- **Pregunta clave:** ¿Cómo saber cuándo el modelo está realmente seguro de su predicción?

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación

7 Conclusiones

Metodos numericos actuales para prediccion

- Laharz
- Otro
- Otro mas

Idea central:

Crear una PINN Bayesiana que prediga de mejor manera un lahar

Estado del Arte: Evolución de los metodos predictivos

La clasificación morfológica ha evolucionado desde la inspección visual hasta el Deep Learning.

- **Dieleman et al. (2015):** El cambio de paradigma. Ganadores del desafío Kaggle Galaxy Zoo, demostraron que las CNNs pueden predecir probabilidades de morfología mejor que los humanos, utilizando rotaciones para invarianza (Dieleman, Willett, y Dambre, 2015).
- **Arquitecturas Híbridas (Actualidad):** Modelos recientes combinan la extracción de características profundas con clasificadores robustos como SVM/SVR o Random Forest para mejorar la generalización en datasets ruidosos (Huertas-Company y cols., 2015).

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación

7 Conclusiones

Modelo Shallow-water

- Aa
- Bb
- Cc

Que son las PINNs?

- pinn
- pin
- pi

Modelo de PINN basada en Shallow-water?

- Laharz
- Otro
- Otro mas

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación

7 Conclusiones

Variables y parámetros

- a
- v
- zb

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)
Sistema acoplado de PDEs

6 Implementación

7 Conclusiones

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)
Sistema acoplado de PDEs

6 Implementación

7 Conclusiones

Sistema acoplado de PDEs

- Masa
- Momentum
- Advección

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación
Arquitectura de la red

7 Conclusiones

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación
Arquitectura de la red

7 Conclusiones

Arquitectura del Modelo CNN

Capa (tipo)	Forma de salida	Parámetros
Input (Sequential)	$(64, 64, 3)$	0
Conv2D (64 filtros)	$(62, 62, 64)$	1,792
Batch Normalization	$(62, 62, 64)$	256
MaxPooling2D	$(31, 31, 64)$	0
Conv2D (128 filtros)	$(29, 29, 128)$	73,856
Batch Normalization	$(29, 29, 128)$	512
MaxPooling2D	$(14, 14, 128)$	0
Conv2D (256 filtros)	$(12, 12, 256)$	295,168
Batch Normalization	$(12, 12, 256)$	1,024
MaxPooling2D	$(6, 6, 256)$	0

Arquitectura del Modelo CNN II

Capa (tipo)	**Forma de salida**	**Parámetros**
GlobalAveragePooling2D	(None, 256)	0
Dense	(None, 256)	65,792
Dropout	(None, 256)	0
Dense (Output)	(None, 37)	9,509
Total params		**447,909**
Trainable params		447,013
Non-trainable params		896

Métricas asociadas

- Accuracy
- Loss total
- La incertidumbre predictiva se evalúa posteriormente mediante muestreo Monte Carlo

Plataforma de entrenamiento Modelo CNN-SVR

- Hardware: CPU (i7-10700f)
- Uso de GPU: Si (NVIDIA RTX 3070 8gb)
- Lenguaje: Python
- Entrenamiento realizado en entorno local

Proceso de entrenamiento Modelo CNN-SVR

- Número máximo de épocas: 30
- Tamaño de batch: 256
- Optimizador: Adam
- Tasa de aprendizaje inicial: 10^{-3}
- Estrategia de parada temprana:
  - Monitor: `val_loss`
  - Paciencia: 3 épocas

1 Introducción

2 Estado del Arte

3 Modelos, ANN y PINNs

4 Variables y parámetros

5 Physics-Informed Neural Networks (PINNs)

6 Implementación

7 Conclusiones

Conclusiones

1. Se anadieron el doble de imagenes para ver mejoria en la convergencia, pero no hubo gran diferencia.
2. Si bien SVM/SVR son mejores para clasificar imagenes, la diferencia entre resultados fue muy poca.

Referencias I

Cortes, C., y Vapnik, V. (1995). Support-vector networks. *Machine learning*, *20*(3), 273–297.

Dieleman, S., Willett, K. W., y Dambre, J. (2015). Rotation-invariant convolutional neural networks for galaxy morphology prediction. *Monthly Notices of the Royal Astronomical Society*.

Huertas-Company, M., y cols. (2015). A catalog of visual morphology for low-redshift galaxies from the sloan digital sky survey. *The Astrophysical Journal Supplement Series*.

Vapnik, V. (2013). The nature of statistical learning theory. Springer science & business media.