

GAX-Kepler: Clasificador de morfología galáctica mediante el uso de redes neuronales convolucionales

Brian Gonzalez, Dylan Jara

Universidad de Santiago de Chile

15 de enero de 2026



- 1 Estado del Arte
- 2 Fundamentos Teóricos: SVR
- 3 Implementación
- 4 Entrenamiento del modelo de estudio
- 5 validación
- 6 Conclusiones

- 1 Estado del Arte
- 2 Fundamentos Teóricos: SVR
- 3 Implementación
- 4 Entrenamiento del modelo de estudio
- 5 validación
- 6 Conclusiones

Estado del Arte: Evolución de la Clasificación

La clasificación morfológica ha evolucionado desde la inspección visual hasta el Deep Learning.

- **Dieleman et al. (2015):** El cambio de paradigma. Ganadores del desafío Kaggle Galaxy Zoo, demostraron que las CNNs pueden predecir probabilidades de morfología mejor que los humanos, utilizando rotaciones para invarianza (Dieleman, Willett, y Dambre, 2015).
- **Arquitecturas Híbridas (Actualidad):** Modelos recientes combinan la extracción de características profundas con clasificadores robustos como SVM/SVR o Random Forest para mejorar la generalización en datasets ruidosos (Huertas-Company y cols., 2015).

- 1 Estado del Arte
- 2 Fundamentos Teóricos: SVR
- 3 Implementación
- 4 Entrenamiento del modelo de estudio
- 5 validación
- 6 Conclusiones

Support Vector Regression (SVR)

A diferencia de la clasificación tradicional, la SVR busca predecir valores continuos (probabilidades).

- **Objetivo:** Encontrar una función $f(x)$ que tenga, a lo sumo, una desviación ϵ de los objetivos reales y_i .
- **Margen de Tolerancia:** Ignora errores menores a ϵ (zona insensible), lo que la hace muy robusta ante el ruido (Drucker, Burges, Kaufman, Smola, y Vapnik, 1996).
- **Kernel Trick:** Permite mapear datos a dimensiones superiores para resolver problemas no lineales (Vapnik, 1995).

- 1 Estado del Arte
- 2 Fundamentos Teóricos: SVR
- 3 Implementación**
Arquitectura de la red
- 4 Entrenamiento del modelo de estudio
- 5 validación
- 6 Conclusiones

- 1 Estado del Arte
- 2 Fundamentos Teóricos: SVR
- 3 Implementación**
Arquitectura de la red
- 4 Entrenamiento del modelo de estudio
- 5 validación
- 6 Conclusiones

Arquitectura del Modelo CNN

Capa (tipo)	Forma de salida	Parámetros
Input (Sequential)	(64, 64, 3)	0
Conv2D (64 filtros)	(62, 62, 64)	1,792
Batch Normalization	(62, 62, 64)	256
MaxPooling2D	(31, 31, 64)	0
Conv2D (128 filtros)	(29, 29, 128)	73,856
Batch Normalization	(29, 29, 128)	512
MaxPooling2D	(14, 14, 128)	0
Conv2D (256 filtros)	(12, 12, 256)	295,168
Batch Normalization	(12, 12, 256)	1,024
MaxPooling2D	(6, 6, 256)	0

Arquitectura del Modelo CNN II

Capa (tipo)	Forma de salida	Parámetros
GlobalAveragePooling2D	(None, 256)	0
Dense	(None, 256)	65,792
Dropout	(None, 256)	0
Dense (Output)	(None, 37)	9,509
Total params		447,909
Trainable params		447,013
Non-trainable params		896

- 1 Estado del Arte
- 2 Fundamentos Teóricos: SVR
- 3 Implementación
- 4 Entrenamiento del modelo de estudio
- 5 validación
- 6 Conclusiones




Figure 1. Flowchart of the classification tasks for GZ2, beginning at the top centre. Tasks are colour-coded by their relative depths in the decision tree. Tasks outlined in brown are asked of every galaxy. Tasks outlined in green, blue, and purple are (respectively) one, two or three steps below branching points in the decision tree. Table 2 describes the responses that correspond to the icons in this diagram.

- 1 Estado del Arte
- 2 Fundamentos Teóricos: SVR
- 3 Implementación
- 4 Entrenamiento del modelo de estudio
- 5 validación
- 6 Conclusiones

- 1 Estado del Arte
- 2 Fundamentos Teóricos: SVR
- 3 Implementación
- 4 Entrenamiento del modelo de estudio
- 5 validación
- 6 Conclusiones

Conclusiones

- 1 Las CNN son una herramienta poderosa para la clasificación de imágenes
- 2 Con ayuda de un buen entendimiento en la teoría del problema, se pueden lograr muy buenos resultados.
- 3 La clasificación automática de galaxias puede acelerar significativamente el análisis de grandes conjuntos de datos astronómicos.

Referencias I

- Dieleman, S., Willett, K. W., y Dambre, J. (2015). Rotation-invariant convolutional neural networks for galaxy morphology prediction. *Monthly Notices of the Royal Astronomical Society*.
- Drucker, H., Burges, C. J., Kaufman, L., Smola, A., y Vapnik, V. (1996). Support vector regression machines. En *Advances in neural information processing systems*.
- Huertas-Company, M., y cols. (2015). A catalog of visual morphology for low-redshift galaxies from the sloan digital sky survey. *The Astrophysical Journal Supplement Series*.
- Vapnik, V. (1995). The nature of statistical learning theory. Springer.